大家都在搜 换一换
- 患癌妻子申请销毁婚外胚… 449 万 热
- 鸿蒙智行回应「竹知了」… 400 万 新
- 同济大学取消教师长期聘任 352 万 热
- 瑞幸对嘴喷奶油员工已被… 351 万 热
- 人生选择模拟器 339 万 活
- 竹知了视频被投诉下架 326 万 热
- 宗馥莉同父异母兄弟成立… 312 万
- DeepSeek 被称为大模型… 307 万 热
- 美国制裁洽洽瓜子思念水饺 294 万 热
- 妈妈罚男孩一次性吃 30 袋… 294 万 热

Vision Transformer 超详细解读 (原理分析+代码解读) (一)

科技猛兽
清华大学 自动化系硕士

收录于 · Transformer和MLP日积月累

4565 人赞同了该文章

本系列已授权极市平台，未经允许不得二次转载，如有需要请私信作者。

考虑到每篇文章字数的限制，每一篇文章将按照目录的编排包含三个小节，而且这个系列会随着Vision Transformer的发展而长期更新。

目录

Transformer 是 Google 的团队在 2017 年提出的一种 NLP 经典模型，现在比较火热的 Bert 也是基于 Transformer。Transformer 模型使用了 Self-Attention 机制，不采用 RNN 的顺序结构，使得模型可以并行化训练，而且能够拥有全局信息。

1 一切从Self-attention开始

- 1.1 处理Sequence数据的模型：

Transformer是一个Sequence to Sequence model，特别之处在于它大量用到了self-attention。

要处理一个Sequence，最常想到的就是使用RNN，它的输入是一串vector sequence，输出是另一串vector sequence，如下图1左所示。

如果假设是一个single directional的RNN，那当输出 b_4 时，默认 a_1,a_2,a_3,a_4 都已经看过了。如果假设是一个bi-directional的RNN，那当输出 $b_{任意}$ 时，默认 a_1,a_2,a_3,a_4 都已经看过了。RNN非常擅长于处理input是一个sequence的状况。

那RNN有什么样的问题呢？它的问题就在于：RNN很不容易并行化 (hard to parallel)。

为什么说RNN很不容易并行化呢？假设在single directional的RNN的情形下，你今天要算出 b_4 ，就必须要先看 a_1 再看 a_2 再看 a_3 再看 a_4 ，所以这个过程很难平行处理。

所以今天就有人提出把CNN拿来取代RNN，如下图1右所示。其中，橘色的三角形表示一个filter，每次扫过3个向量 a ，扫过一轮以后，就输出了一排结果，使用橘色的小圆点表示。

这是第一个橘色的filter的过程，还有其他的filter，比如图2中的黄色的filter，它经历着与橘色的filter相似的过程，又输出一排结果，使用黄色的小圆点表示。

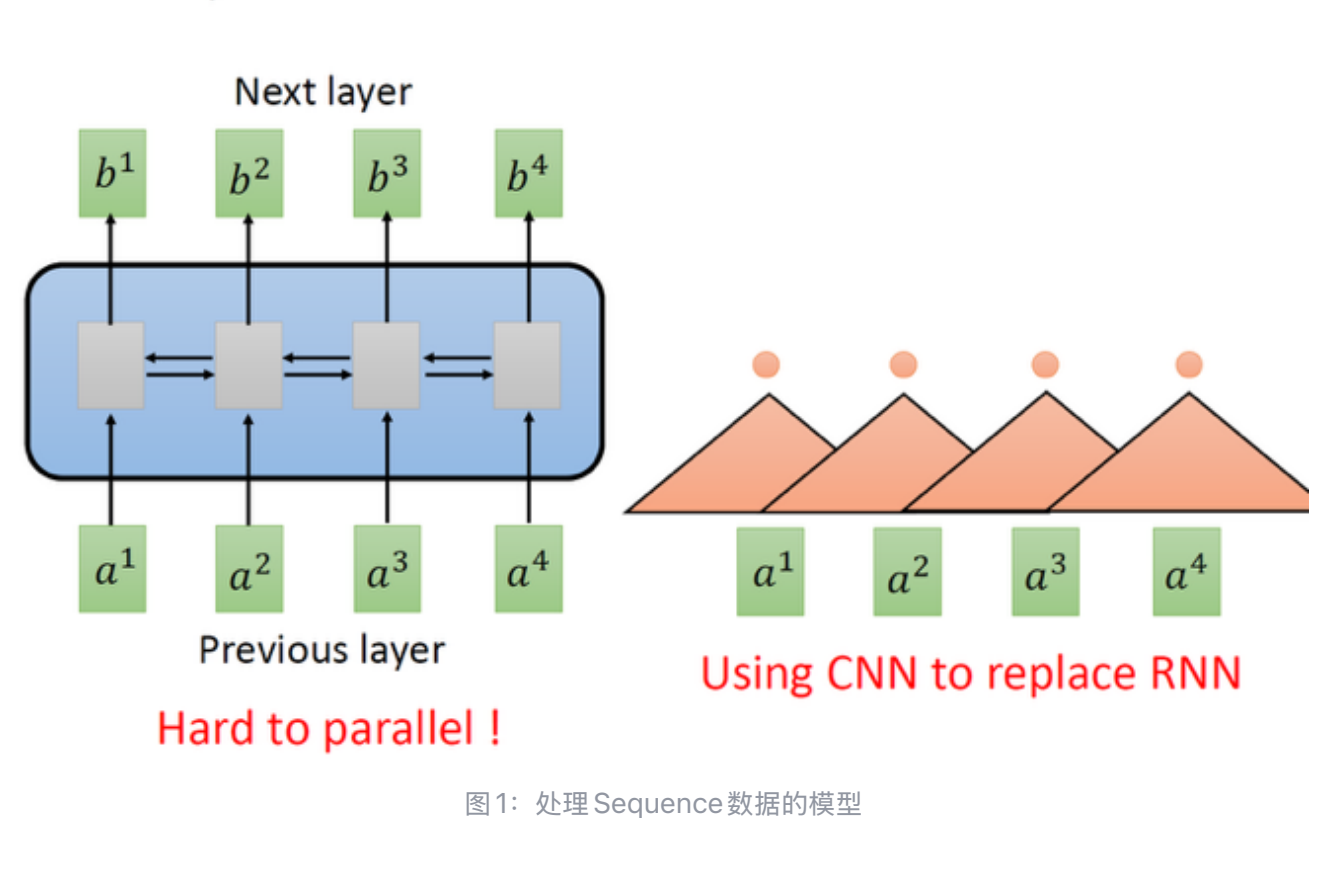
Sequence
Next layer
b^1 b^2 b^3 b^4
a^1 a^2 a^3 a^4
Previous layer
Hard to parallel !
Using CNN to replace RNN

图1：处理Sequence数据的模型

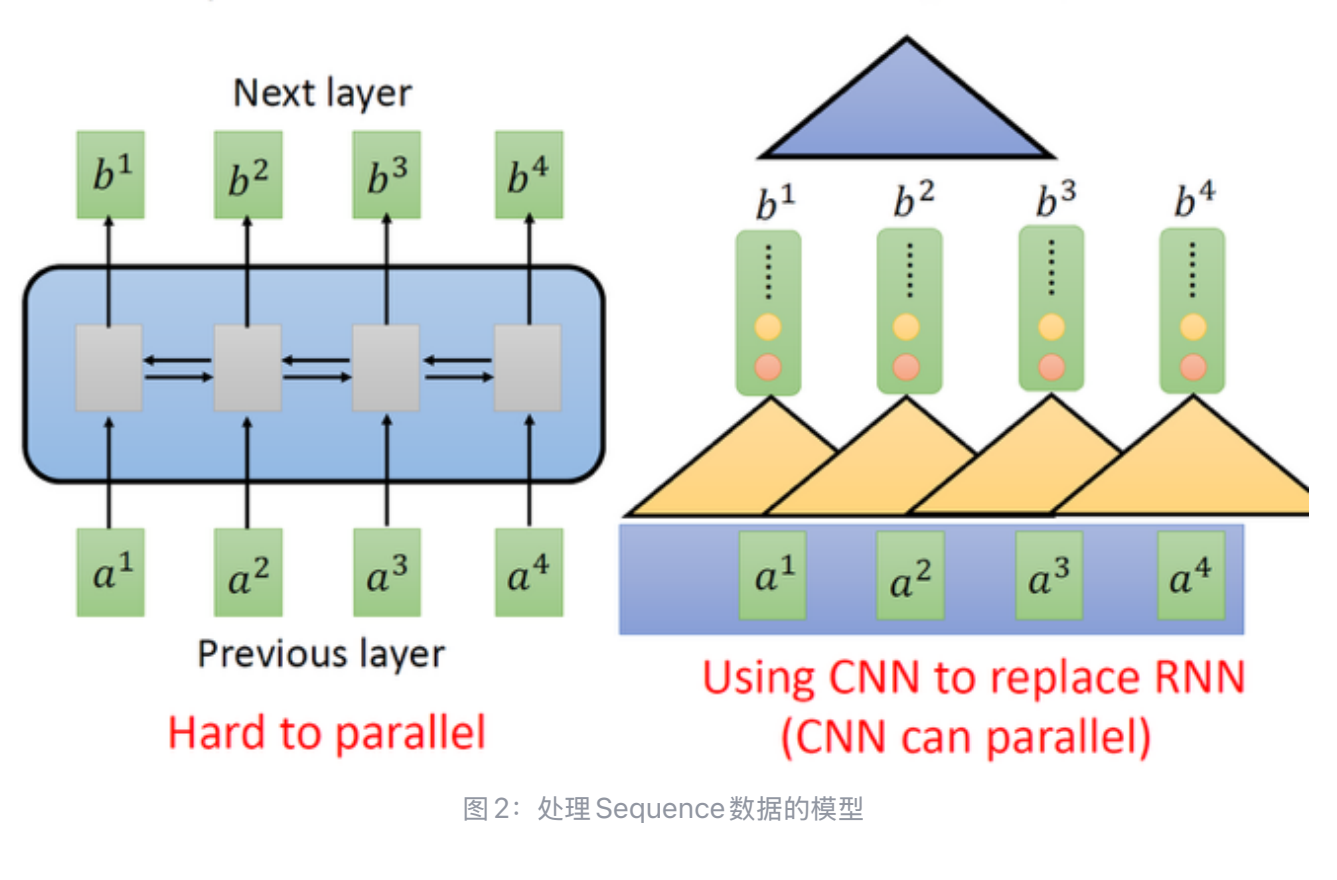
Sequence
Next layer
Previous layer
Hard to parallel
Filters in higher layer can consider longer sequence
Using CNN to replace RNN (CNN can parallel)

图2：处理Sequence数据的模型

所以，用CNN，你确实也可以做到跟RNN的输入输出类似的关系，也可以做到输入是一个sequence，输出是另外一个sequence。

但是，表面上CNN和RNN可以做到相同的输入和输出，但是CNN只能考虑非常有限的内容。比如在我们右侧的图中CNN的filter只考虑了3个vector，不像RNN可以考虑之前的所有vector。但是CNN也不是没有办法考虑很长时间的dependency的，你只需要堆叠filter，多堆叠几层，上层的filter就可以考虑比较多的资讯，比如，第二层的filter (蓝色的三角形)看了6个vector，所以，只要叠很多层，就能够看很长时间的资讯。

而CNN的一个好处是：它是可以并行化的 (can parallel)，不需要等待红色的filter算完，再算黄色的filter。但是必须要叠很多层filter，才可以看到长时的资讯。所以今天有一个想法：self-attention，如下图3所示，目的是使用self-attention layer取代RNN所做的事情。

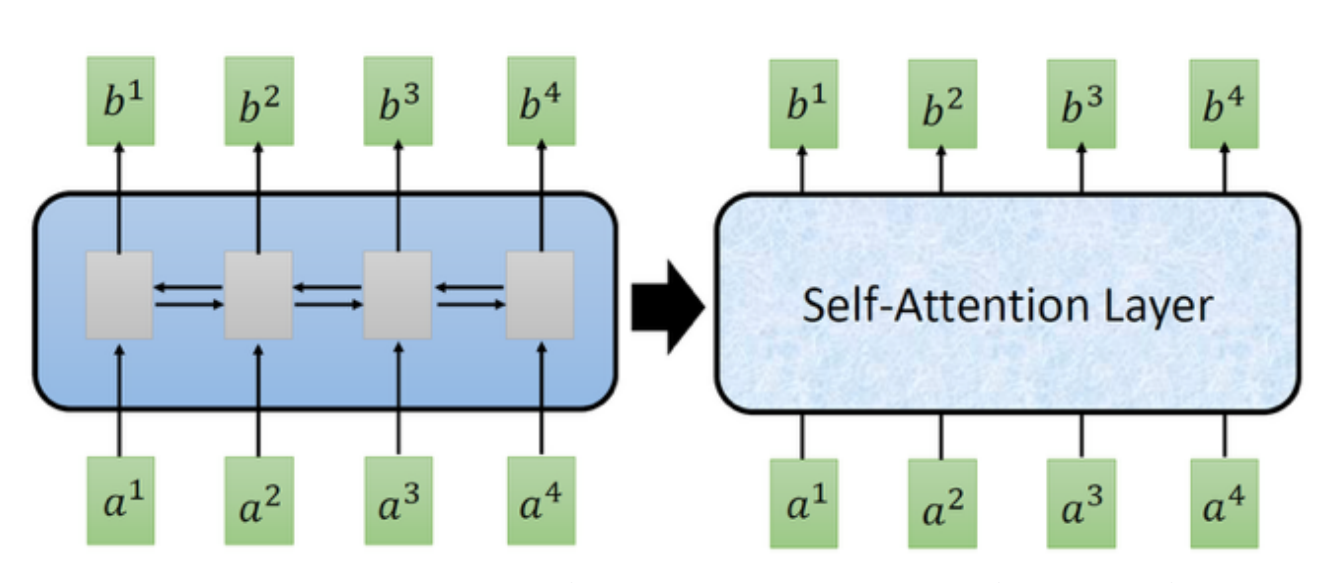
b^1 b^2 b^3 b^4
Self-Attention Layer
a^1 a^2 a^3 a^4

图3：You can try to replace any thing that has been done by RNNwith self attention

所以重点是：我们有一种新的layer，叫self-attention，它的输入和输出和RNN是一模一样的，输入一个sequence，输出一个sequence，它的每一个输出 b_1-b_4 都看过了整个的输入sequence，这一点与bi-directional RNN相同。但是神奇的地方是：它的每一个输出 b_1-b_4 可以并行化计算。

- 1.2 Self-attention：

那么self-attention具体是怎么做的呢？

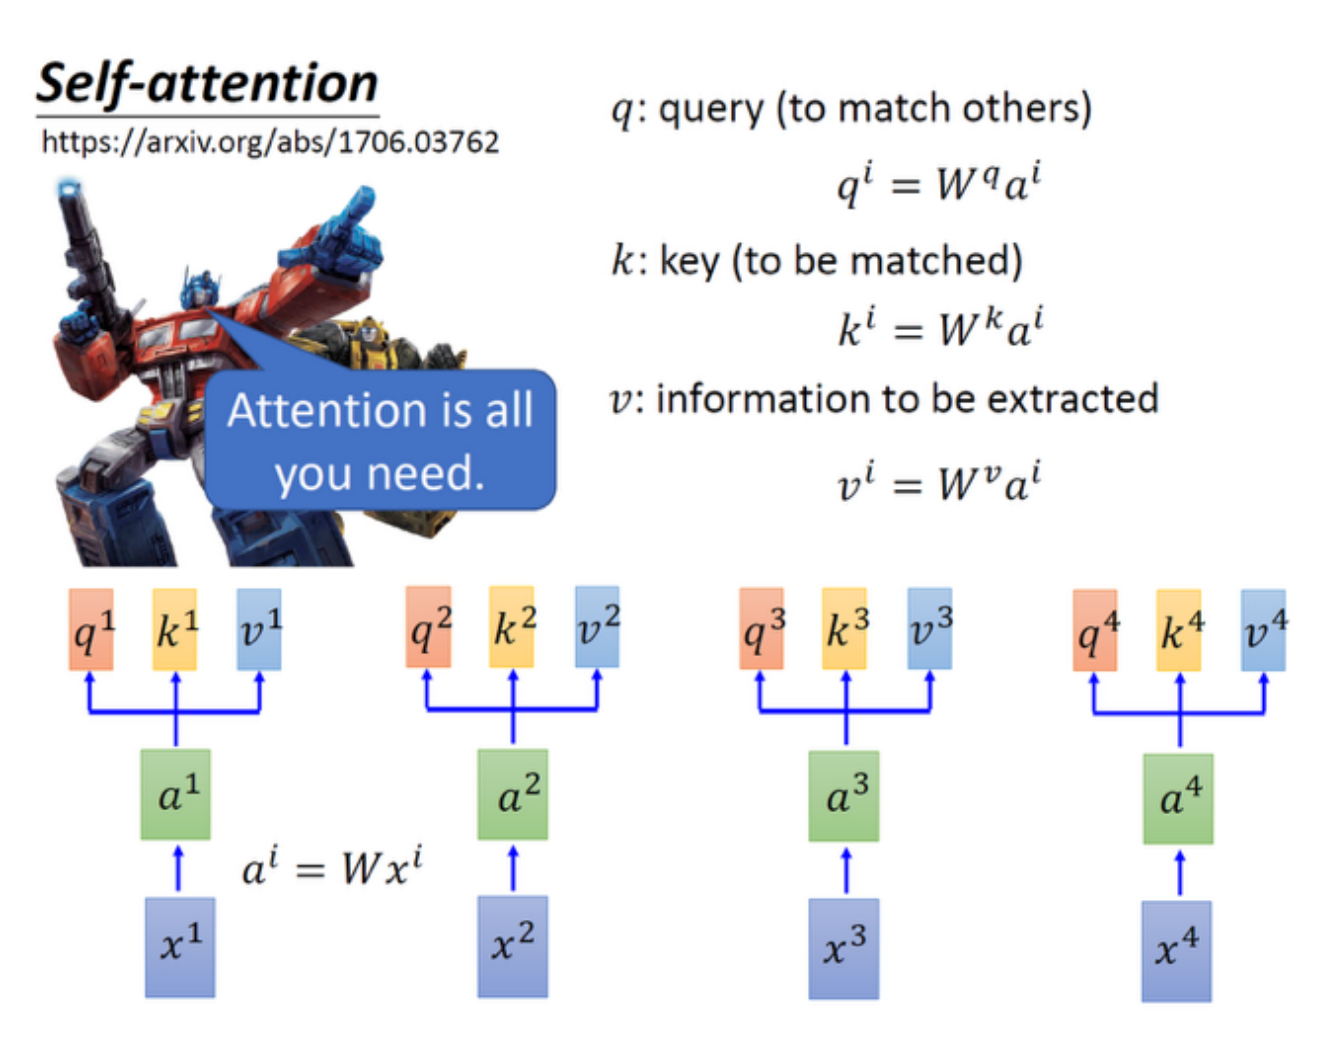
Self-attention
https://arxiv.org/abs/1706.03762
Attention is all you need.
q: query (to match others)
$q^i = W^q a^i$
k: key (to be matched)
$k^i = W^k a^i$
v: information to be extracted
$v^i = W^v a^i$
$a^i = Wx^i$

图4：self-attention具体是怎么做的？

首先假设我们的input是图4的 x_1-x_4 ，是一个sequence，每一个input (vector)先乘上一个矩阵 W 得到embedding，即向量 a_1-a_4 。接着这个embedding进入self-attention层，每一个向量 a_1-a_4 分别乘上3个不同的transformation matrix W_q,W_k,W_v ，以向量 a_1 为例，分别得到3个不同的向量 q_1,k_1,v_1 。

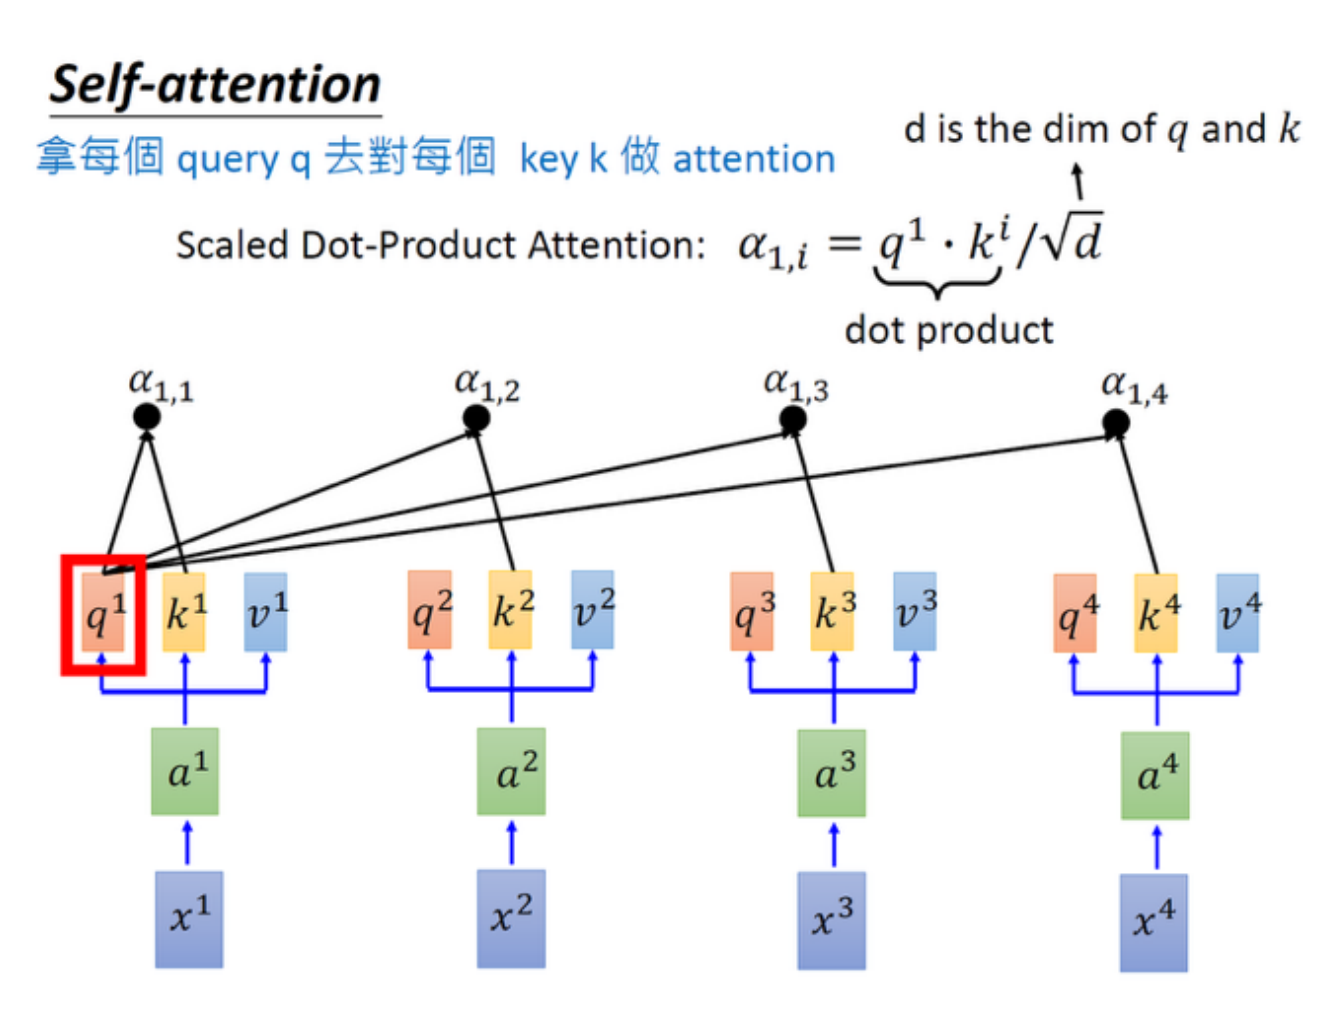
Self-attention
拿每個 query q 去對每個 key k 做 attention
Scaled Dot-Product Attention: $\alpha_{1,i} = q^1 \cdot k^i / \sqrt{d}$
d is the dim of q and k
dot product
$\alpha_{1,1}$ $\alpha_{1,2}$ $\alpha_{1,3}$ $\alpha_{1,4}$

图5：self-attention具体是怎么做的？

接下来使用每个query q 去对每个key k 做attention，attention就是匹配这2个向量有多接近，比如我现在要对 q^1 和 k^1 做attention，我就可以把这2个向量做scaled inner product，得到 $\alpha_{1,1}$ 。接下来你再拿 q^1 和 k^2 做attention，得到 $\alpha_{1,2}$ ，你再拿 q^1 和 k^3 做attention，得到 $\alpha_{1,3}$ ，你再拿 q^1 和 k^4 做attention，得到 $\alpha_{1,4}$ 。那么这个scaled inner product具体是怎么计算的呢？

$$\alpha_{1,i} = q^1 \cdot k^i / \sqrt{d} \tag{1}$$

式中， d 是 q 跟 k 的维度。因为 $q \cdot k$ 的数值会随着dimension的增大而增大，所以要除以 $\sqrt{\text{dimension}}$ 的值，相当于归一化的效果。

接下来要做的事如图6所示，把计算得到的所有 $\alpha_{1,i}$ 值取 softmax 操作。

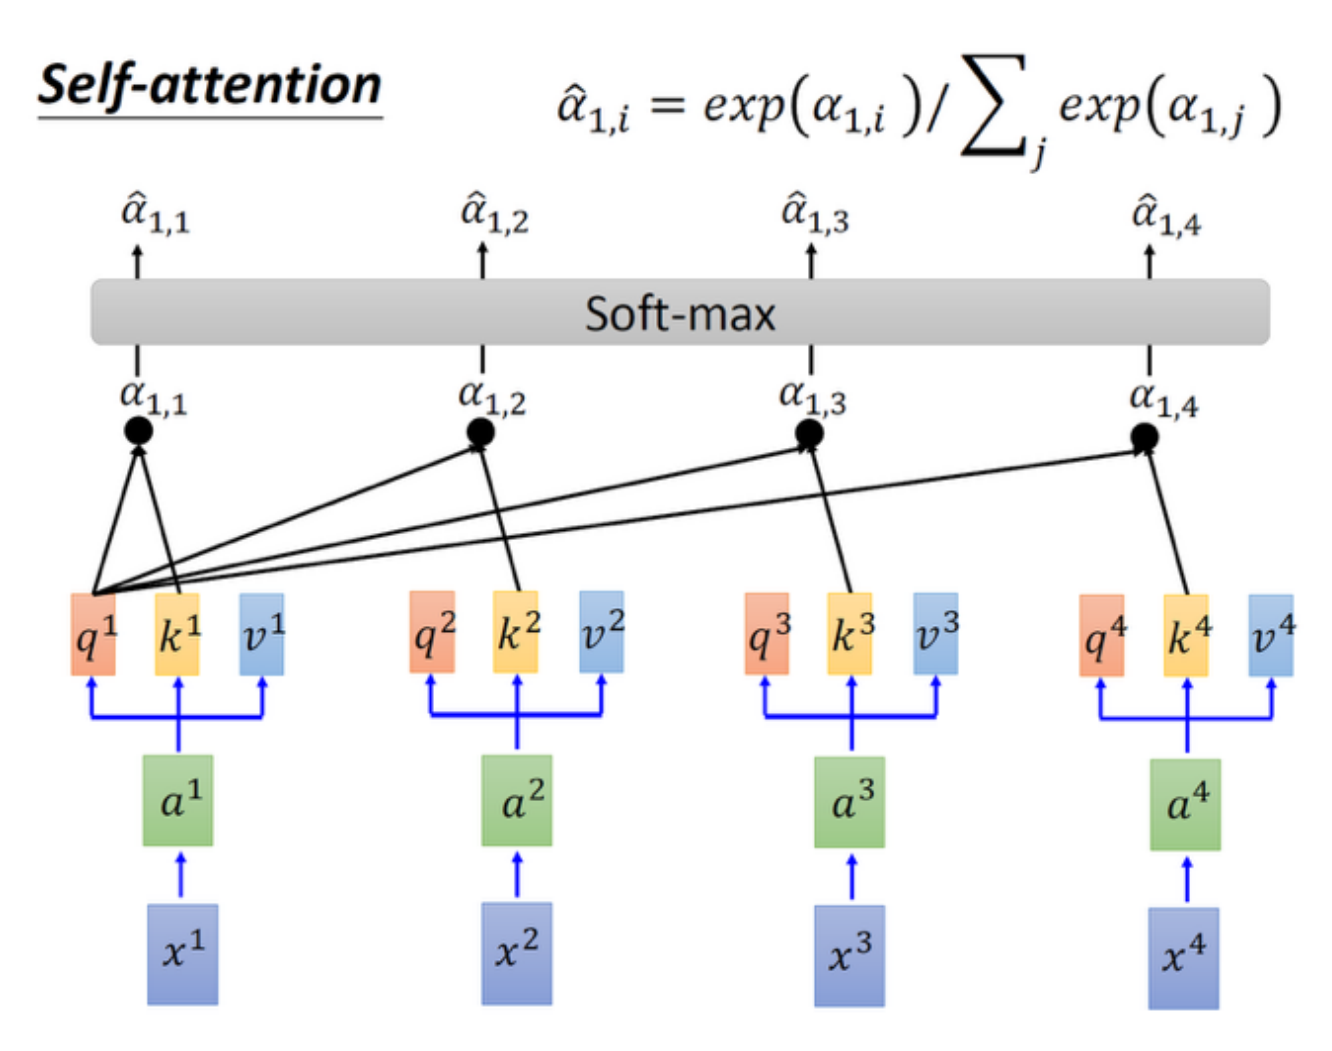
Self-attention
$\hat{\alpha}_{1,i} = exp(\alpha_{1,i}) / \sum_j exp(\alpha_{1,j})$
Soft-max
$\hat{\alpha}_{1,1}$ $\hat{\alpha}_{1,2}$ $\hat{\alpha}_{1,3}$ $\hat{\alpha}_{1,4}$

图6：self-attention具体是怎么做的？

取完 softmax 操作以后，我们得到了 $\hat{\alpha}_{1,i}$ ，我们用它和所有的 v^i 值进行相乘。具体来讲，把 $\hat{\alpha}_{1,1}$ 乘上 v^1 ，把 $\hat{\alpha}_{1,2}$ 乘上 v^2 ，把 $\hat{\alpha}_{1,3}$ 乘上 v^3 ，把 $\hat{\alpha}_{1,4}$ 乘上 v^4 ，把结果通通加起来得到 b^1 ，所以，今天在产生 b^1 的过程中用了整个sequence的资讯 (Considering the whole sequence)。如果要考虑local的information，则只需要学习出相应的 $\hat{\alpha}_{1,i}=0$ ， b^1 就不再带有那个对应分支的信息了；如果要考虑global的information，则只需要学习出相应的 $\hat{\alpha}_{1,i} \neq 0$ ， b^1 就带有全部的对应分支的信息了。

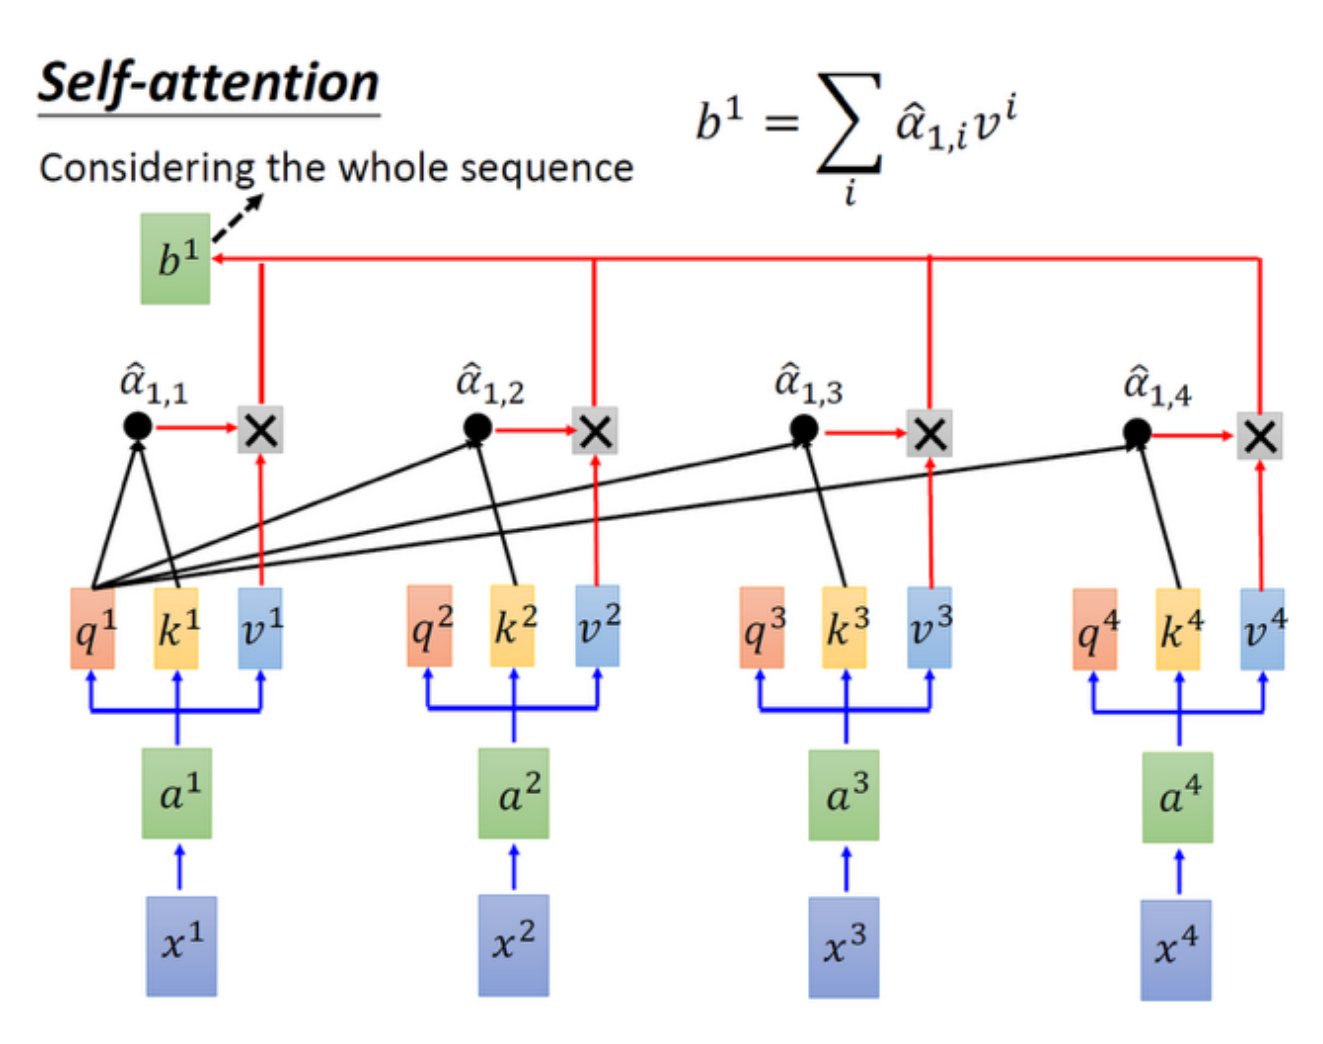
Self-attention
Considering the whole sequence
$b^1 = \sum_i \hat{\alpha}_{1,i} v^i$

图7：self-attention具体是怎么做的？

同样的方法，也可以计算出 b^2,b^3,b^4 ，如下图8所示， b^2 就是拿query q^2 去对其他的 k 做attention，得到 $\hat{\alpha}_{2,i}$ ，再与value值 v^i 相乘取weighted sum得到的。

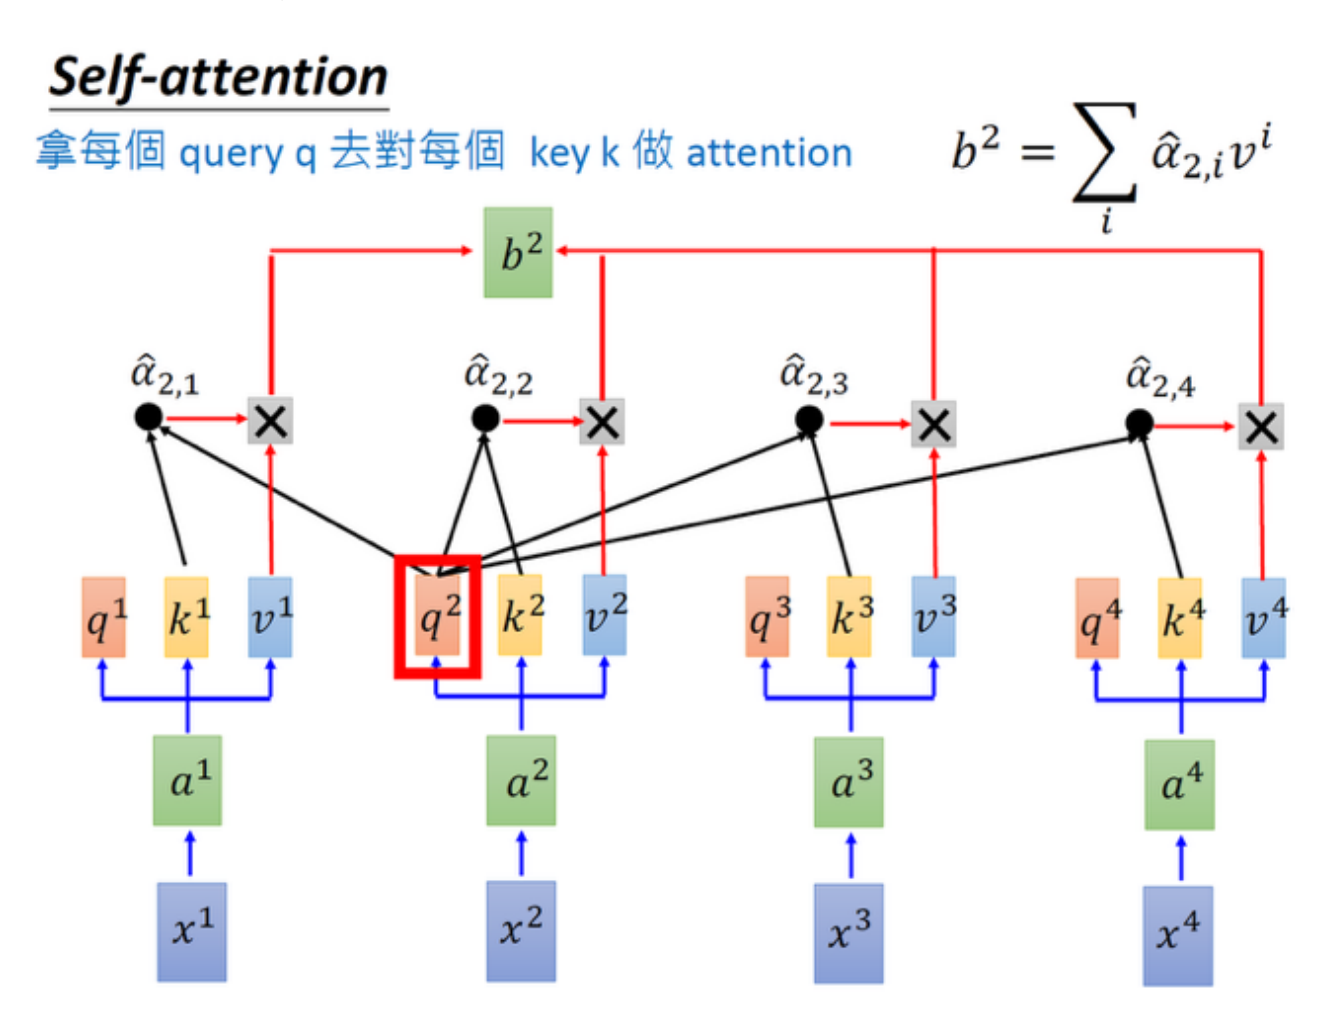
Self-attention
拿每個 query q 去對每個 key k 做 attention
$b^2 = \sum_i \hat{\alpha}_{2,i} v^i$
$\hat{\alpha}_{2,1}$ $\hat{\alpha}_{2,2}$ $\hat{\alpha}_{2,3}$ $\hat{\alpha}_{2,4}$

图8：self-attention具体是怎么做的？

经过了以上一连串计算，self-attention layer做的事情跟RNN是一样的，只是它可以并行的得到layer输出的结果，如图9所示。现在我们要用矩阵表示上述的计算过程。

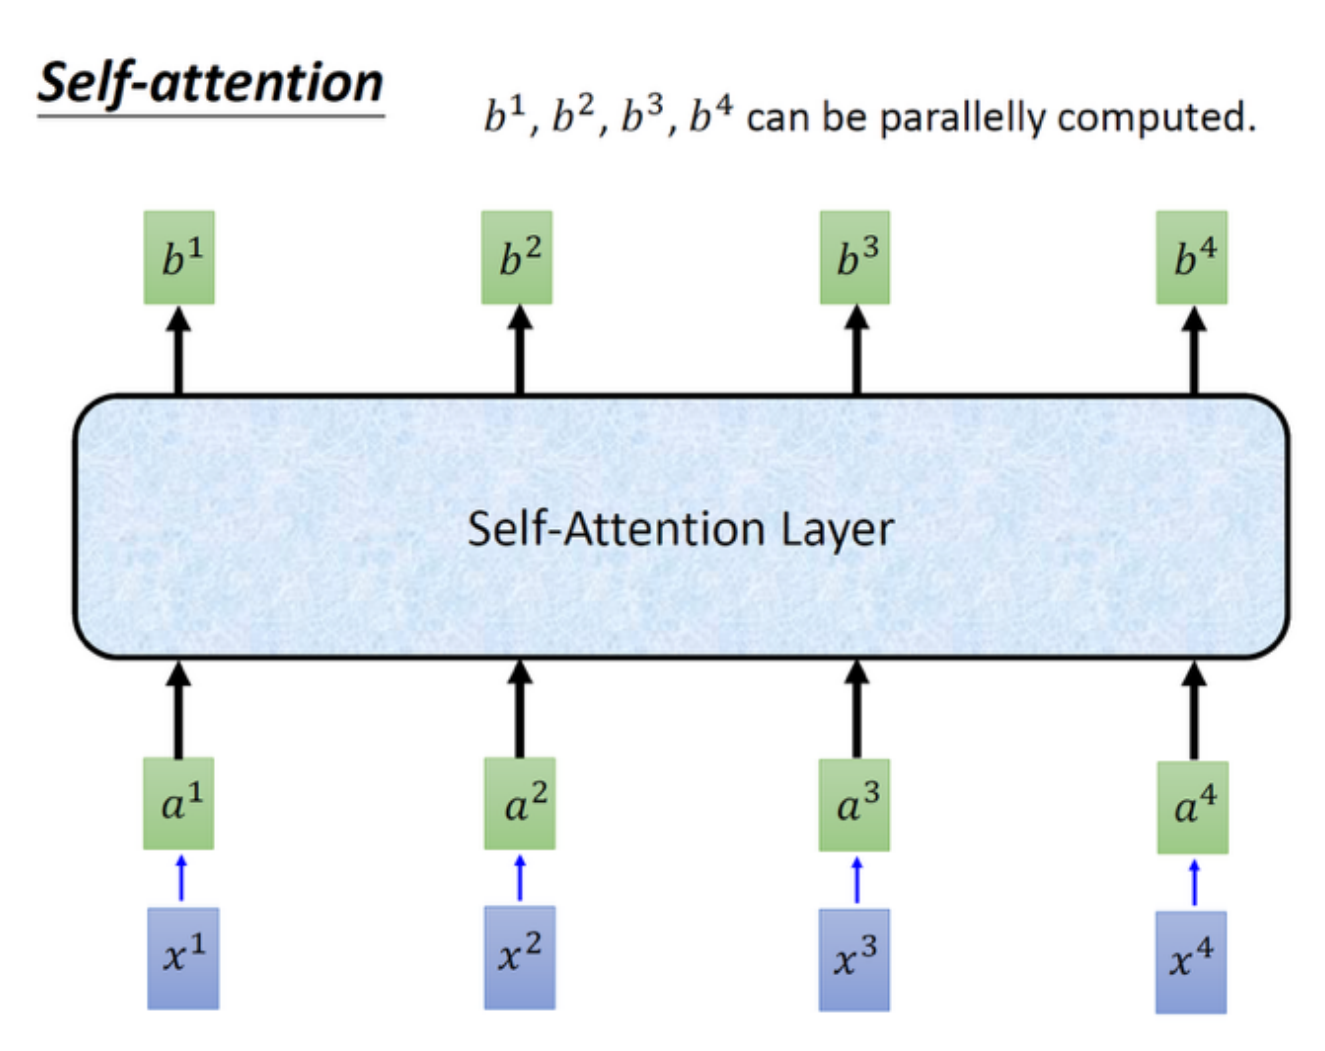
Self-attention
b^1, b^2, b^3, b^4 can be parallelly computed.
Self-Attention Layer

图9：self-attention的效果

首先输入的embedding是 $I=[a^1,a^2,a^3,a^4]$ ，然后用 I 乘以transformation matrix W^q 得到 $Q=[q^1,q^2,q^3,q^4]$ ，它的每一列代表着一个vector q 。同理，用 I 乘以transformation matrix W^k 得到 $K=[k^1,k^2,k^3,k^4]$ ，它的每一列代表着一个vector k 。用 I 乘以transformation matrix W^v 得到 $V=[v^1,v^2,v^3,v^4]$ ，它的每一列代表着一个vector v 。

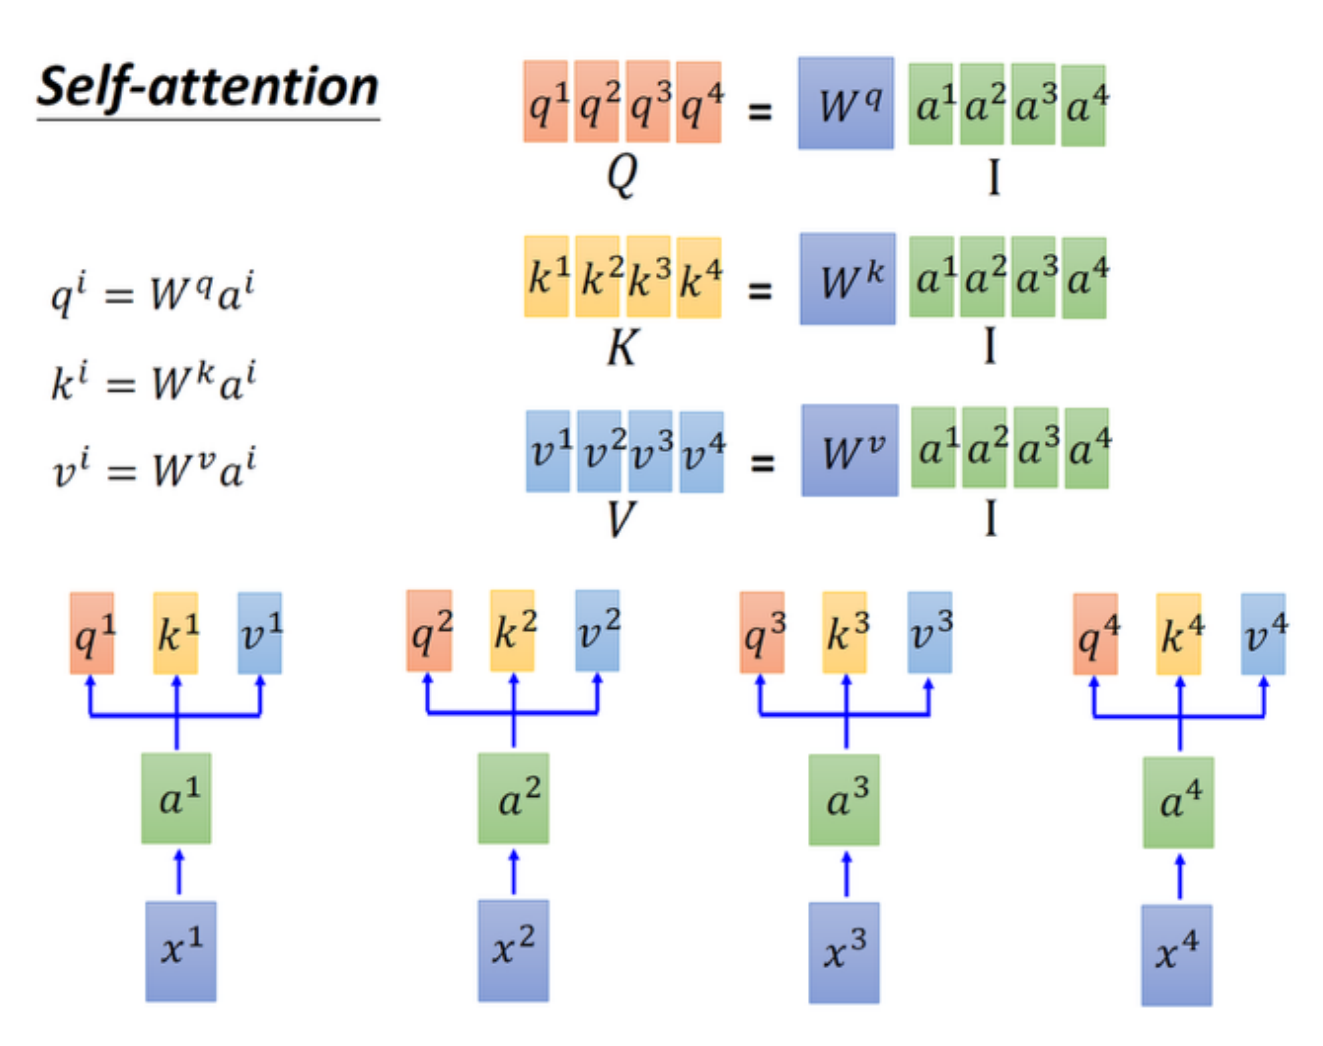
Self-attention
$q^i = W^q a^i$
$k^i = W^k a^i$
$v^i = W^v a^i$
$q^1q^2q^3q^4 = W^q\ a^1a^2a^3a^4$
Q I
$k^1k^2k^3k^4 = W^k\ a^1a^2a^3a^4$
K I
$v^1v^2v^3v^4 = W^v\ a^1a^2a^3a^4$
V I

图10：self-attention的矩阵计算过程

接下来是 k 与 q 的attention过程，我们可以把vector k 横过来变成行向量，与列向量 q 做内积，这里省略了 $\sqrt{d}$ 。这样， α 就成为了 4×4 的矩阵，它由4个行向量拼成的矩阵和4个列向量拼成的矩阵做内积得到，如图11所示。

在得到 $\hat{A}$ 以后，如上文所述，要得到 b^1 ，就要使用 $\hat{\alpha}_{1,i}$ 分别与 v^i 相乘再求和得到，所以 $\hat{A}$ 要再左乘 V 矩阵。

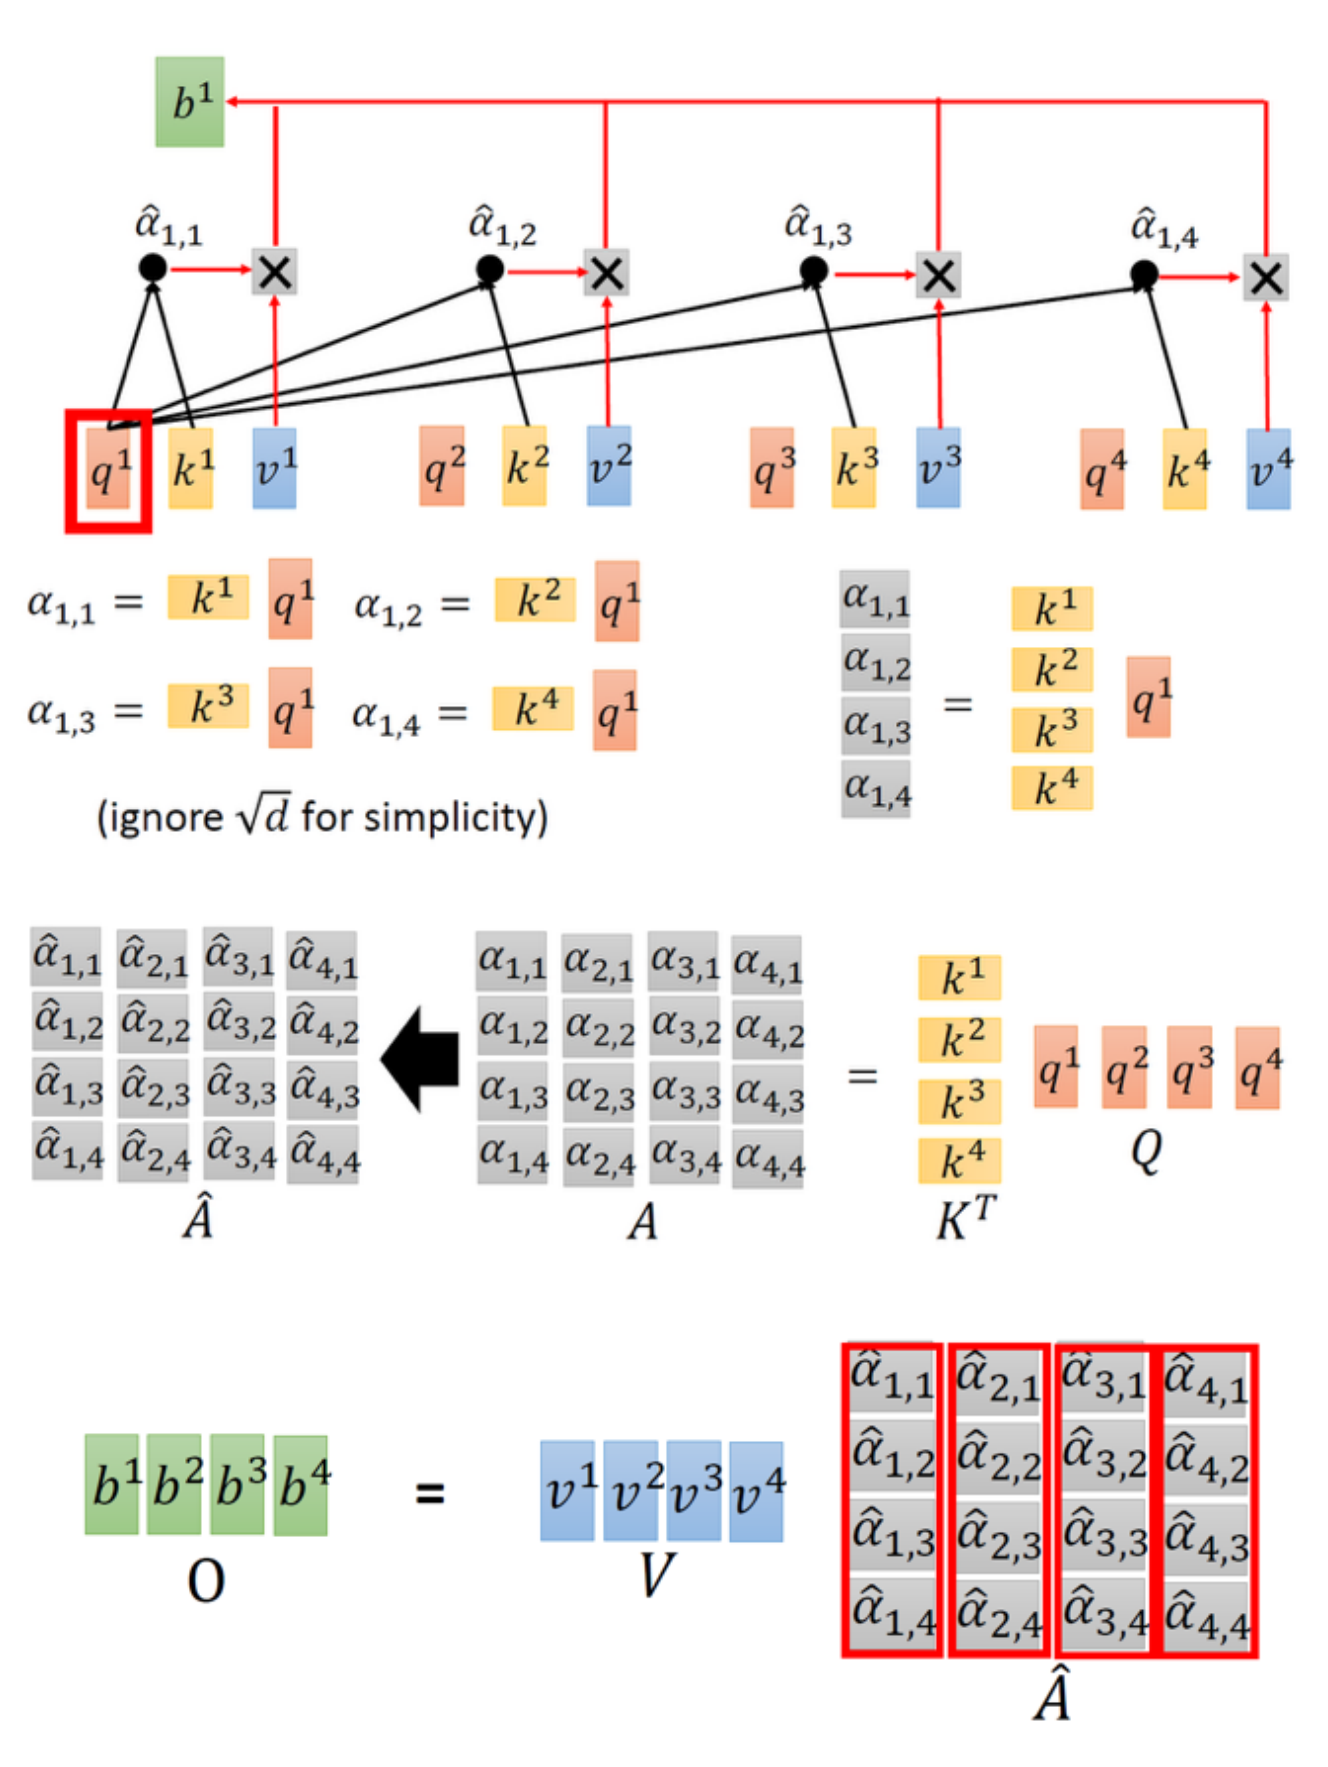
$\alpha_{1,1} = k^1\ q^1$ $\alpha_{1,2} = k^2\ q^1$
$\alpha_{1,3} = k^3\ q^1$ $\alpha_{1,4} = k^4\ q^1$
(ignore $\sqrt{d}$ for simplicity)
$\hat{A}$ A K^T Q
O V $\hat{A}$

图11：self-attention的矩阵计算过程

到这里你会发现这个过程可以被表示为，如图12所示：输入矩阵 $I \in R(d,N)$ 分别乘上3个不同的矩阵 $W_q,W_k,W_v \in R(d,d)$ 得到3个中间矩阵 $Q,K,V \in R(d,N)$ 。它们的维度是相同的。把 K 转置之后与 Q 相乘得到Attention矩阵 $A \in R(N,N)$ ，代表每一个位置两两之间的attention。再将它取 softmax 操作得到 $\hat{A} \in R(N,N)$ ，最后将它乘以 V 矩阵得到输出vector $O \in R(d,N)$ 。

$$\hat{A} = \text{softmax}(A) = K^T \cdot Q \tag{2}$$

$$O = V \cdot \hat{A} \tag{3}$$

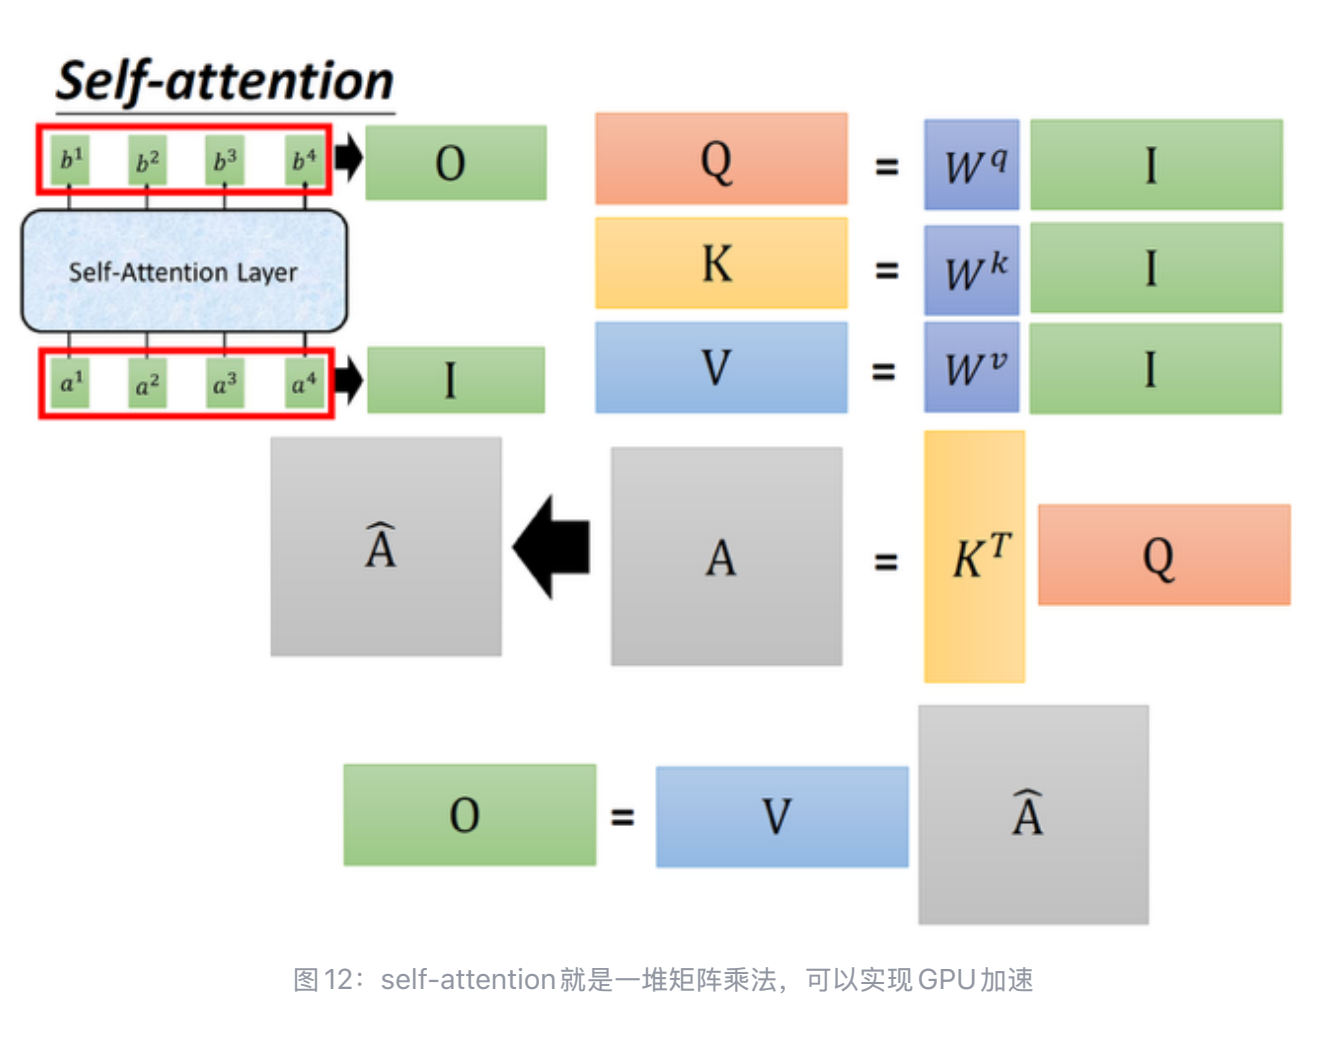
Self-attention
Self-Attention Layer
O I
Q = W^q I
K = W^k I
V = W^v I
$\hat{A}$ A = K^T Q
O = V $\hat{A}$

图12：self-attention就是一堆矩阵乘法，可以实现GPU加速

- 1.3 Multi-head Self-attention：

还有一种multi-head的self-attention，以2个head的情况为例：由 a^i 生成的 q^i 进一步乘以2个转移矩阵变为 $q^{i,1}$ 和 $q^{i,2}$ ，同理由 a^i 生成的 k^i 进一步乘以2个转移矩阵变为 $k^{i,1}$ 和 $k^{i,2}$ ，由 a^i 生成的 v^i 进一步乘以2个转移矩阵变为 $v^{i,1}$ 和 $v^{i,2}$ 。接下来 $q^{i,1}$ 再与 $k^{i,1}$ 做attention，得到weighted sum的权重 α ，再与 $v^{i,1}$ 做weighted sum得到最终的 $b^{i,1}(i=1,2,\ldots,N)$ 。同理得到 $b^{i,2}(i=1,2,\ldots,N)$ 。现在我们有了 $b^{i,1}(i=1,2,\ldots,N) \in R(d,1)$ 和 $b^{i,2}(i=1,2,\ldots,N) \in R(d,1)$ ，可以把它们concat起来，再通过一个transformation matrix调整维度，使之与刚才的 $b^i(i=1,2,\ldots,N) \in R(d,1)$ 维度一致(这步如图13所示)。

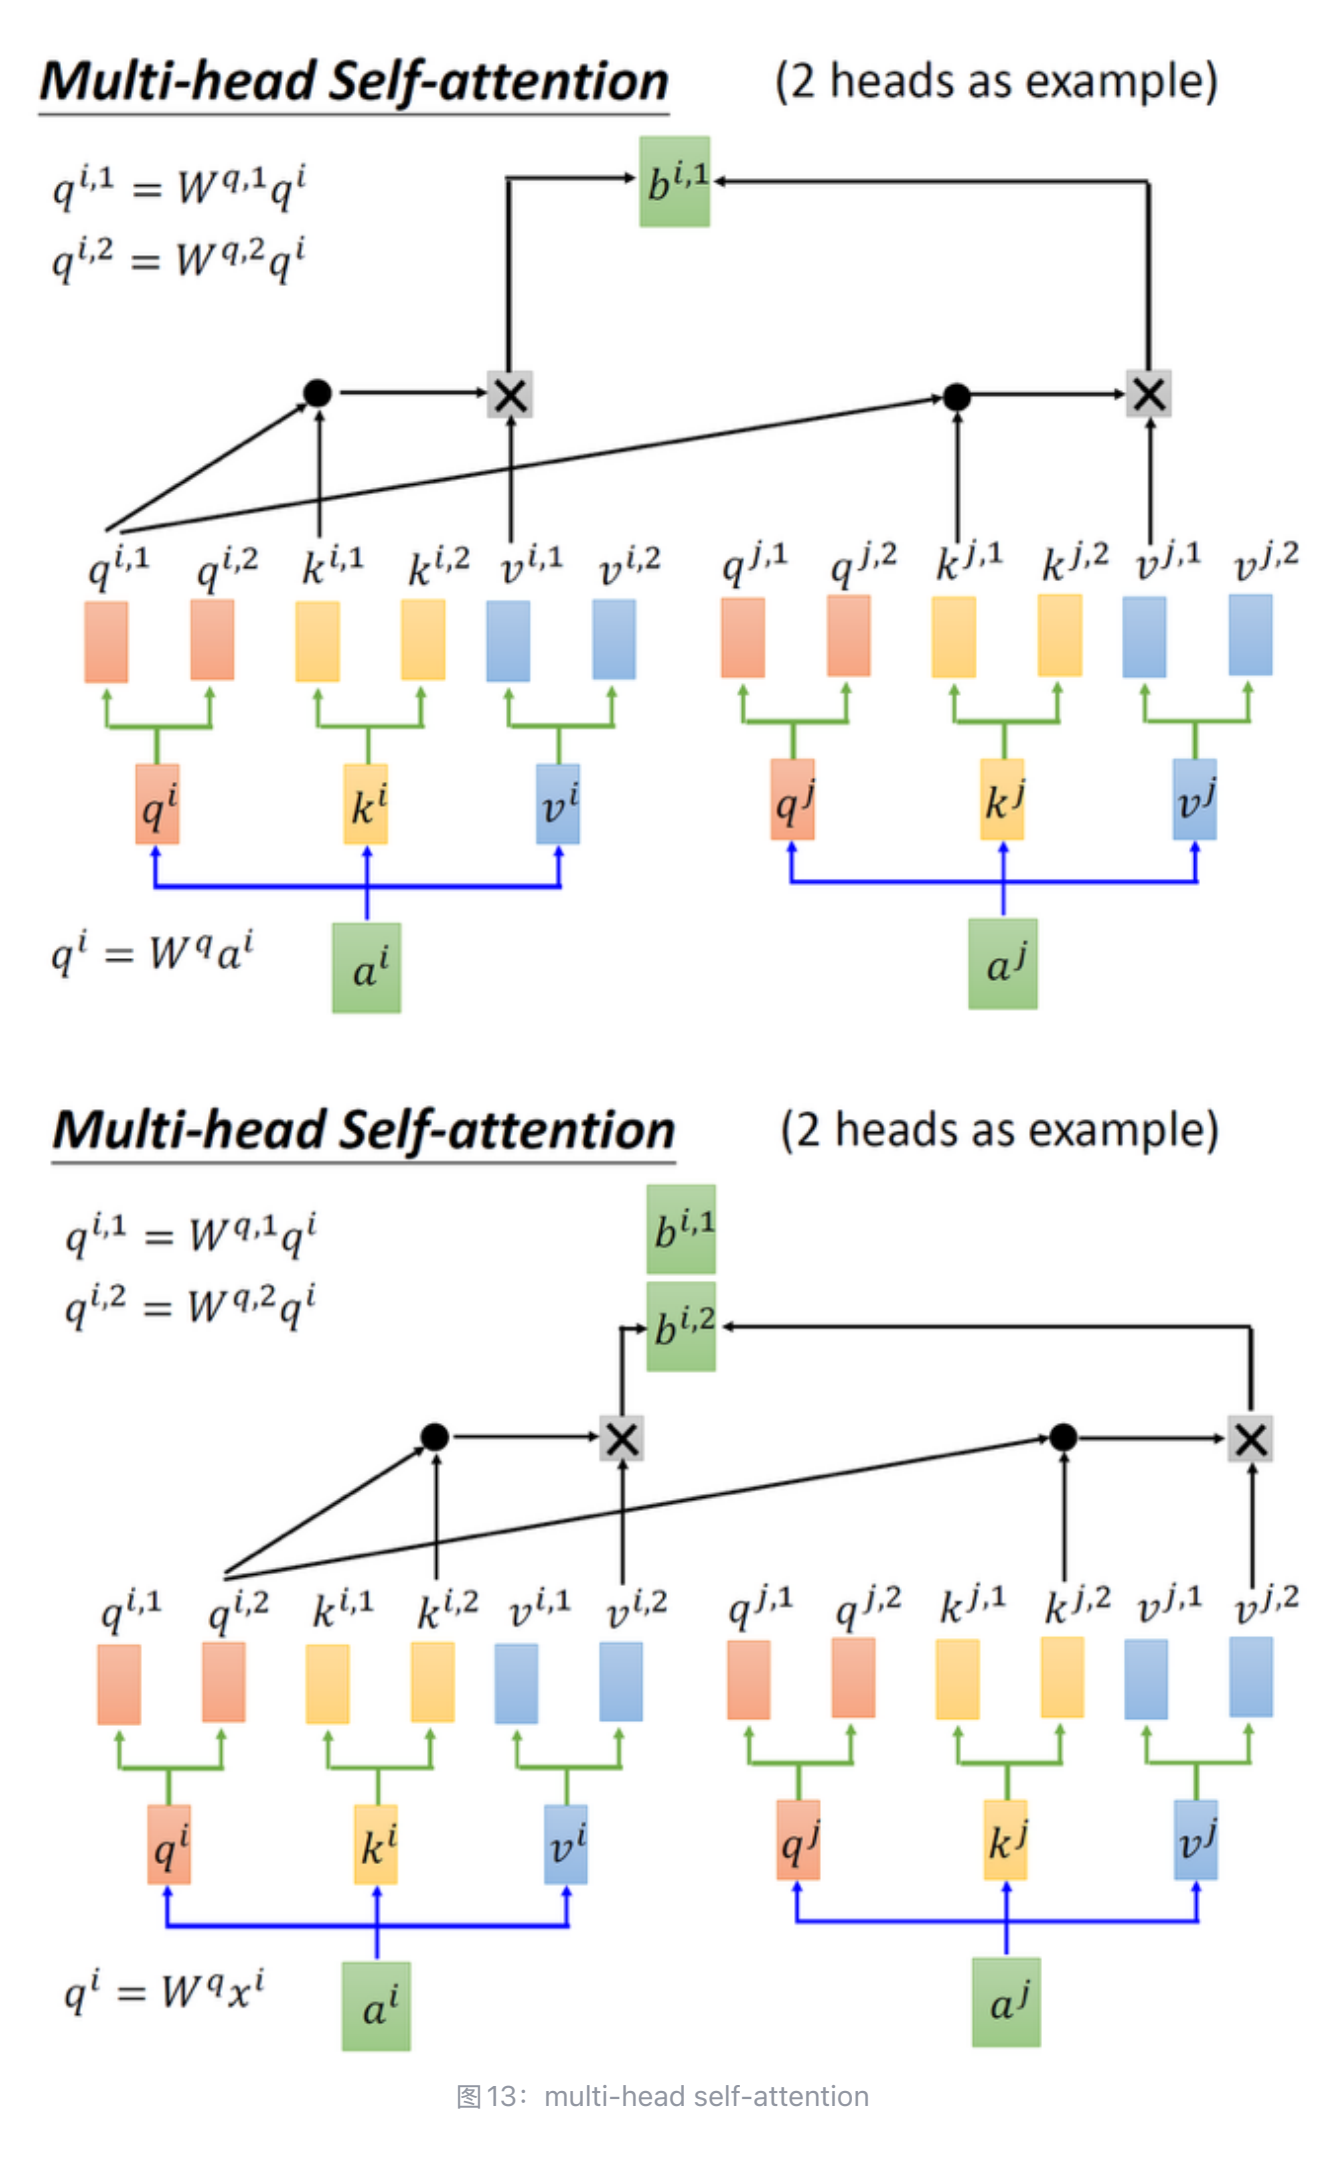
Multi-head Self-attention
(2 heads as example)
$q^{i,1} = W^{q,1} q^i$
$q^{i,2} = W^{q,2} q^i$
$q^i = W^q a^i$
$q^i = W^q x^i$
$b^{i,1}$ $b^{i,2}$

图13：multi-head self-attention

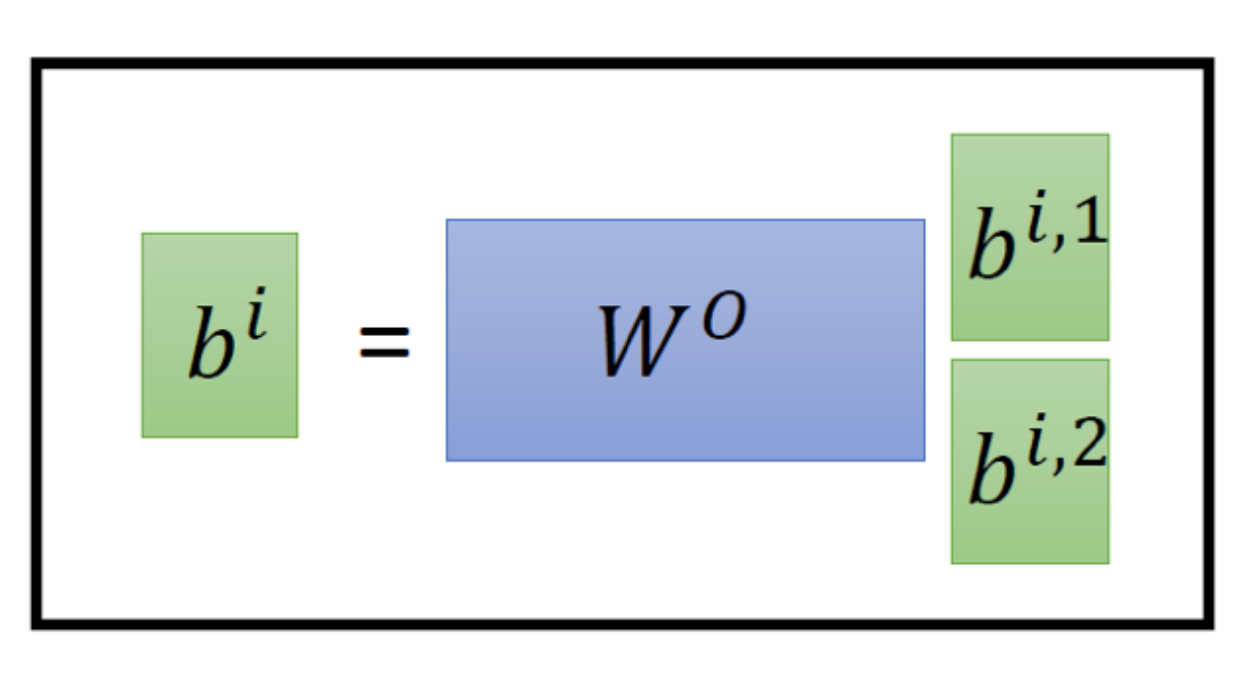
b^i = W^O $b^{i,1}$ $b^{i,2}$

图13：调整b的维度

从下图14可以看到 Multi-Head Attention 包含多个 Self-Attention 层，首先将输入 X 分别传递到 2 个不同的 Self-Attention 中，计算得到 2 个输出结果。得到2个输出矩阵之后，Multi-Head Attention 将它们拼接在一起 (Concat)，然后传入一个Linear层，得到 Multi-Head Attention 最终的输出 Z 。可以看到 Multi-Head Attention 输出的矩阵 Z 与其输入的矩阵 X 的维度是一样的。

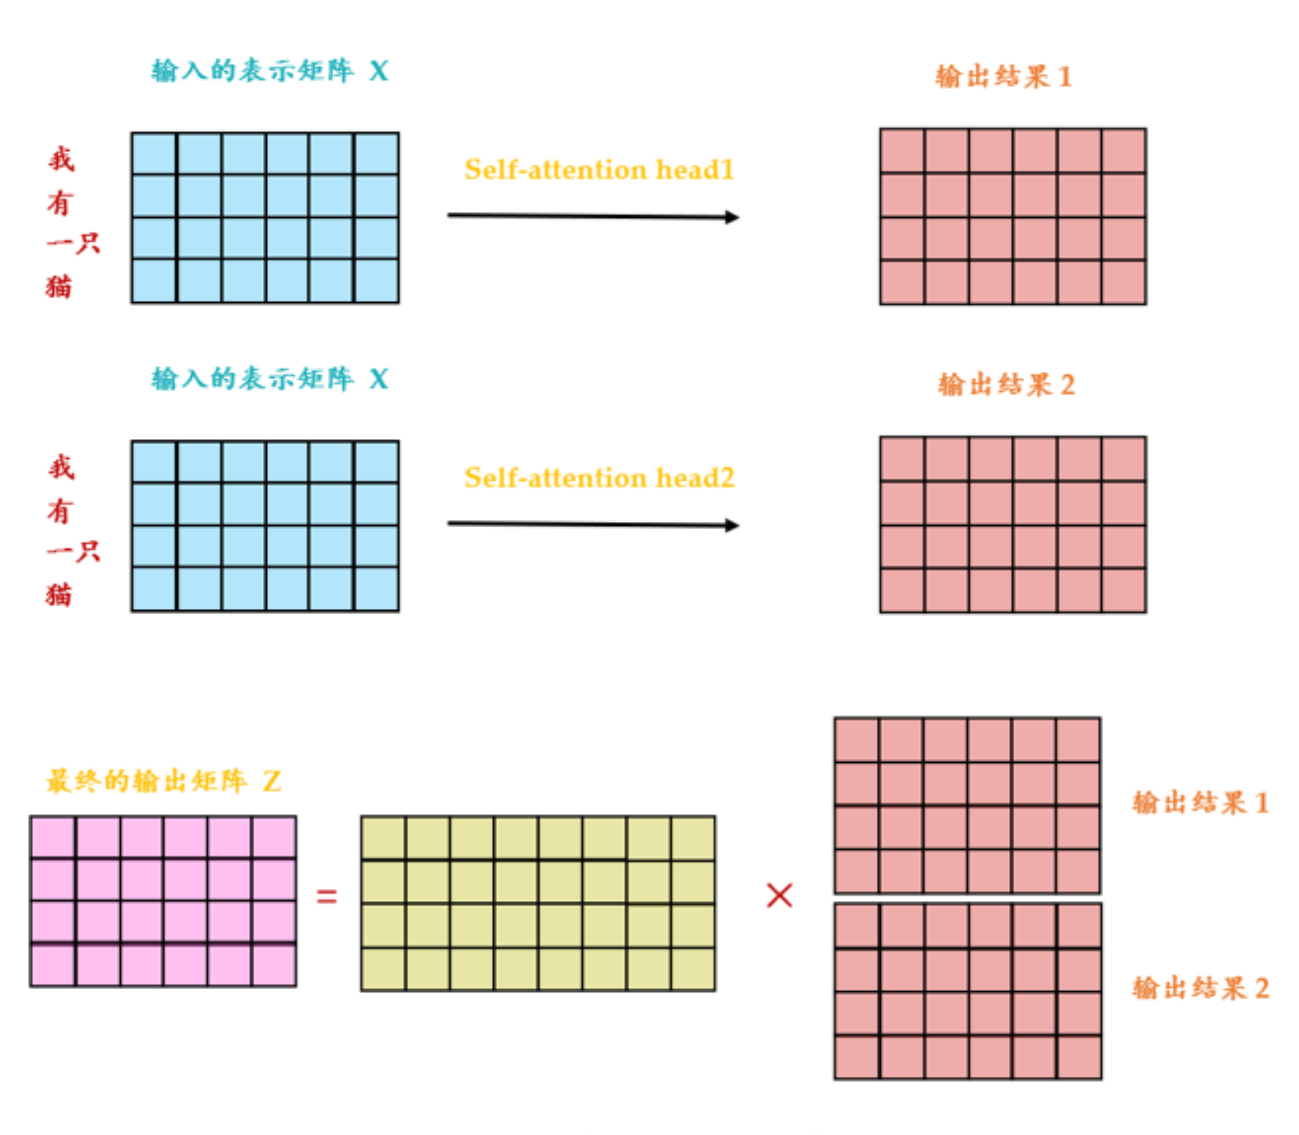
输入的表示矩阵 X
我有一只猫
Self-attention head1
输出结果 1
输入的表示矩阵 X
我有一只猫
Self-attention head2
输出结果 2
最终的输出矩阵 Z
输出结果 1
输出结果 2

图14：multi-head self-attention

这里有一组Multi-head Self-attention的解果，其中绿色部分是一组query和key，红色部分是另外一组query和key，可以发现绿色部分其实更关注global的信息，而红色部分其实更关注local的信息。

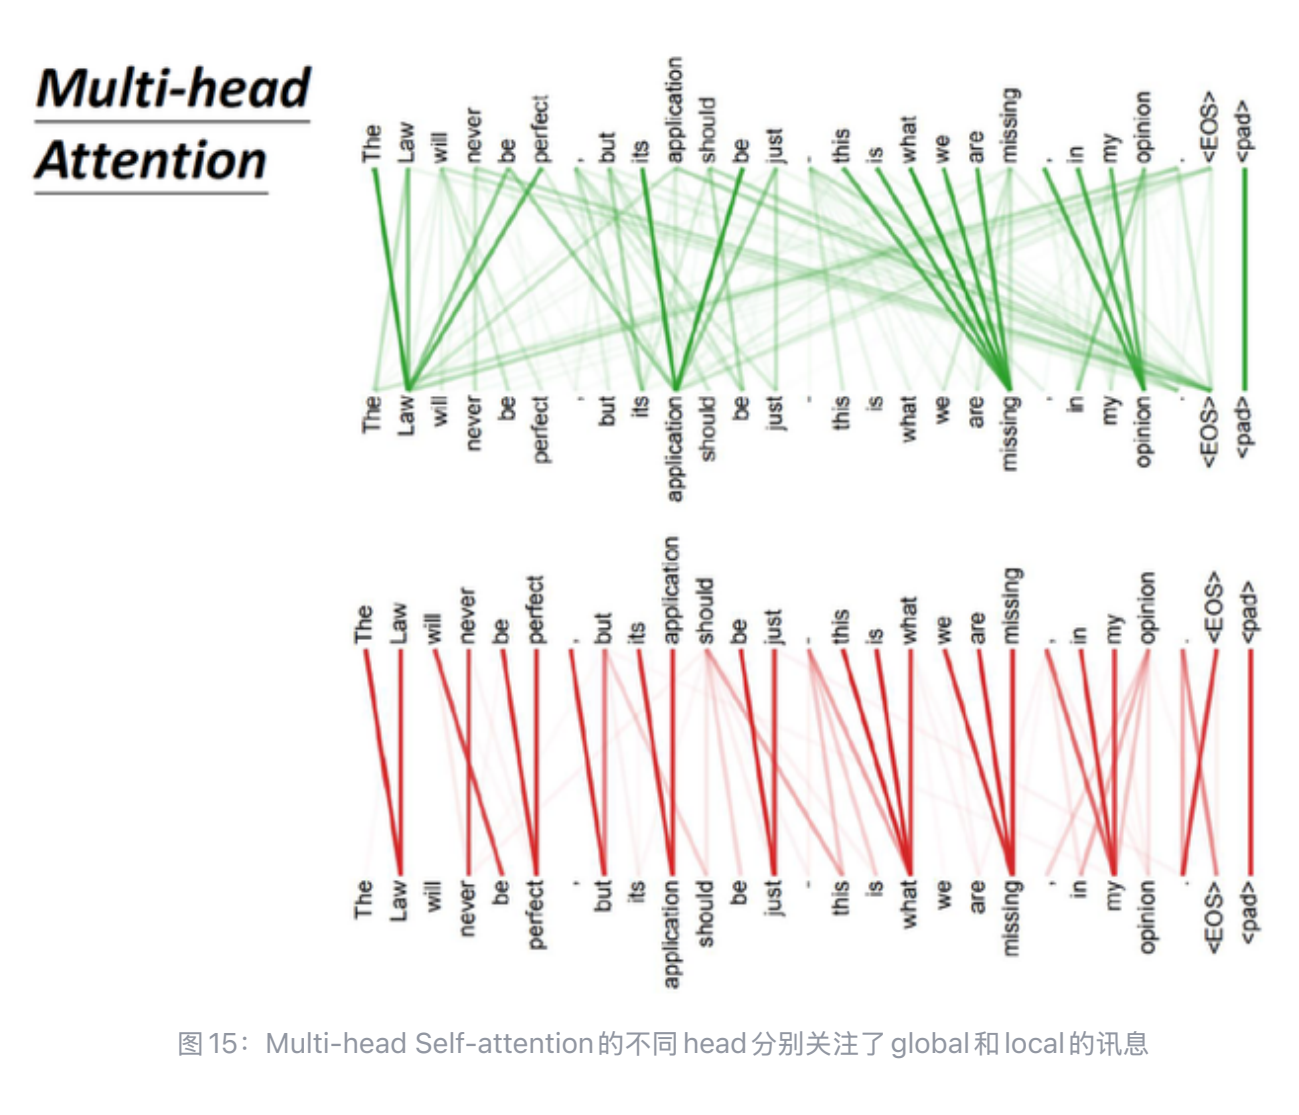

图15：Multi-head Self-attention的不同head分别关注了global和local的讯息

- 1.4 Positional Encoding：

以上是multi-head self-attention的原理，但是还有一个问题是：现在的self-attention中没有位置的信息，一个单词向量的“近在咫尺”位置的单词向量和“远在天涯”位置的单词向量效果是一样的，没有表示位置的信息(No position information in self attention)。所以你输入"A打了B"或者"B打了A"的效果其实是一样的，因为并没有考虑位置的信息。所以在self-attention原来的paper中，作者为了解决这个问题所做的事情是如下图16所示：

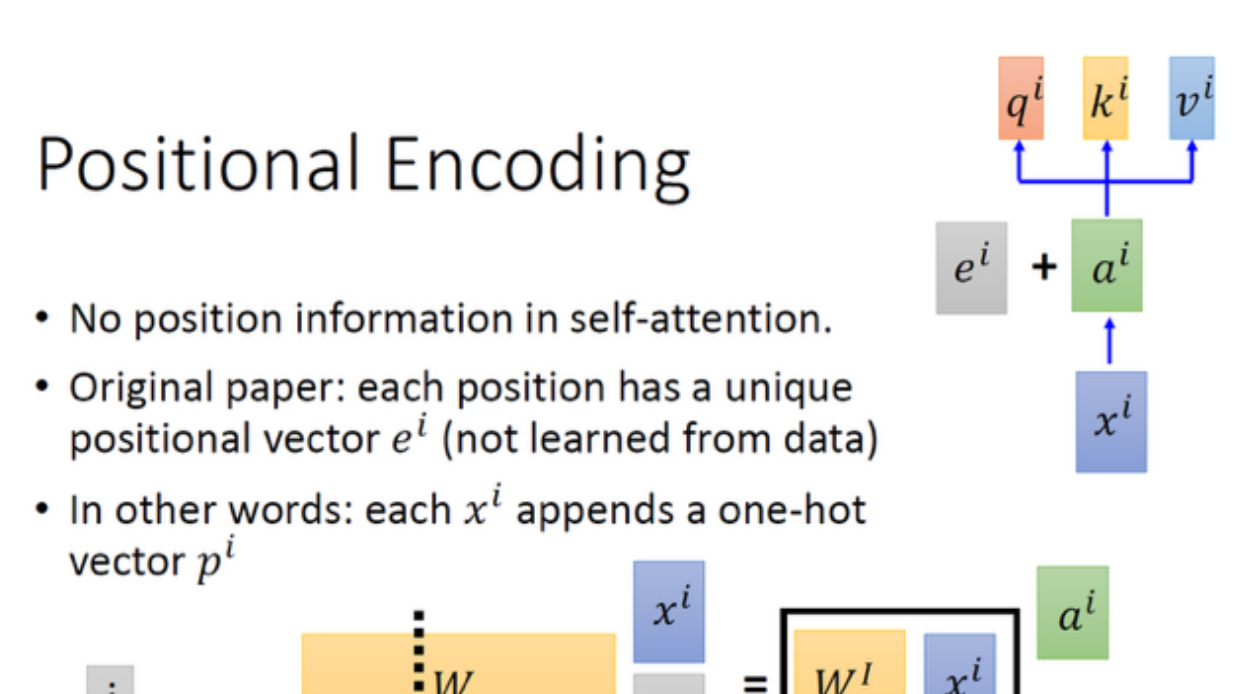

Positional Encoding

- No position information in self-attention.
- Original paper: each position has a unique positional vector e^i (not learned from data)
- In other words: each x^i appends a one-hot vector p^i

q^i k^i v^i
e^i + a^i
x^i
W^I x^i a^i

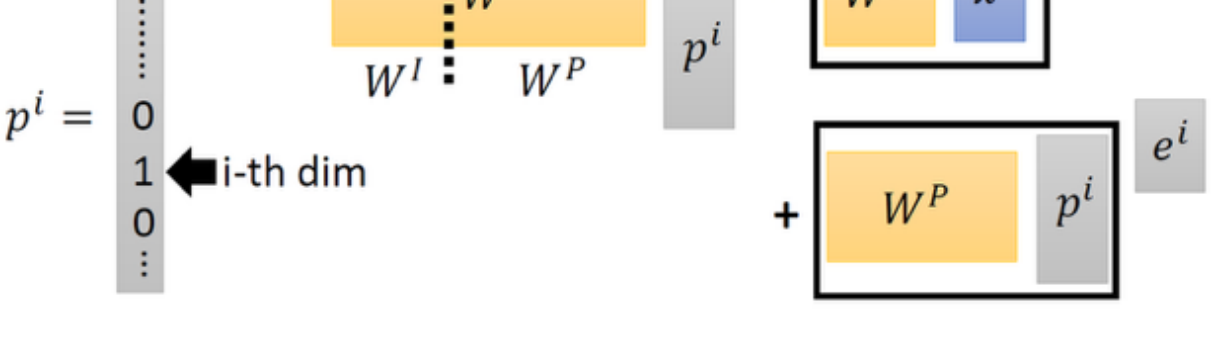
W^I
W^P
p^i
$p^i =$
0
1
0
i-th dim
+
W^P
p^i
e^i

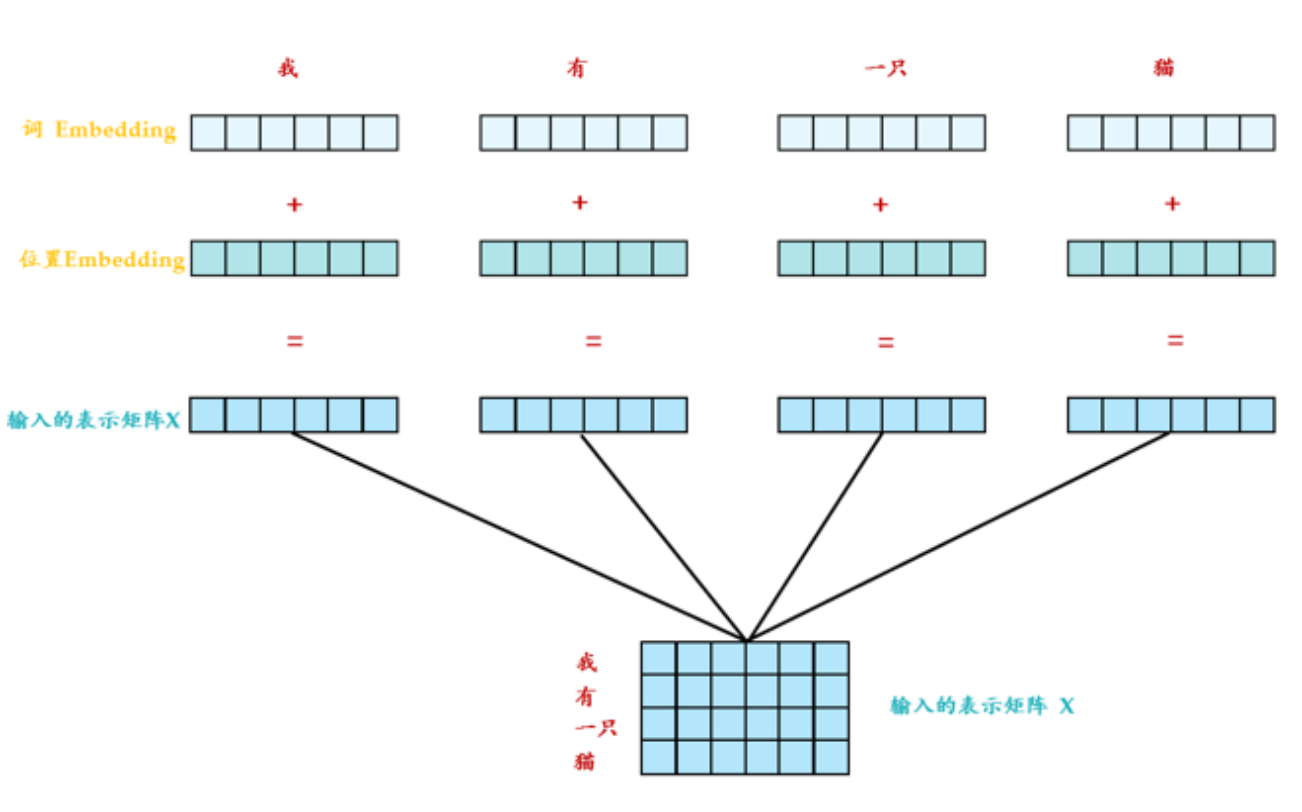
我
有
一只
猫
词 Embedding
位置Embedding
输入的表示矩阵X
输入的表示矩阵 X

图16：self-attention中的位置编码

具体的做法是：给每一个位置规定一个表示位置信息的向量 e^i ，让它与 a^i 加在一起之后作为新的 a^i 参与后面的运算过程，但是这个向量 e^i 是由人工设定的，而不是神经网络⁺学习出来的。每一个位置都有一个不同的 e^i 。

那到这里一个自然而然的问题是：为什么是 e^i 与 a^i 相加？为什么不是concatenate？加起来以后，原来表示位置的资讯不就混到 a^i 里面去了吗？不就很难被找到了吗？

这里提供一种解答这个问题的思路：

如图15所示，我们先给每一个位置的 $x^i \in R(d,1)$ append一个one-hot编码⁺的向量 $p^i \in R(N,1)$ ，得到一个新的输入向量 $x_p^i \in R(d+N,1)$ ，这个向量作为新的输入，乘以一个transformation matrix $W = [W^I, W^P] \in R(d, d+N)$ 。那么：

$$W \cdot x_p^i = [W^I, W^P] \cdot \begin{bmatrix} x^i \\ p^i \end{bmatrix} = W^I \cdot x^i + W^P \cdot p^i = a^i + e^i \tag{4}$$

所以，e^i 与 a^i 相加就等同于把原来的输入 x^i concat一个表示位置的独热编码 p^i ，再做transformation。

这个与位置编码乘起来的矩阵 W^P 是手工设计的，如图17所示（黑色框代表一个位置的编码）。

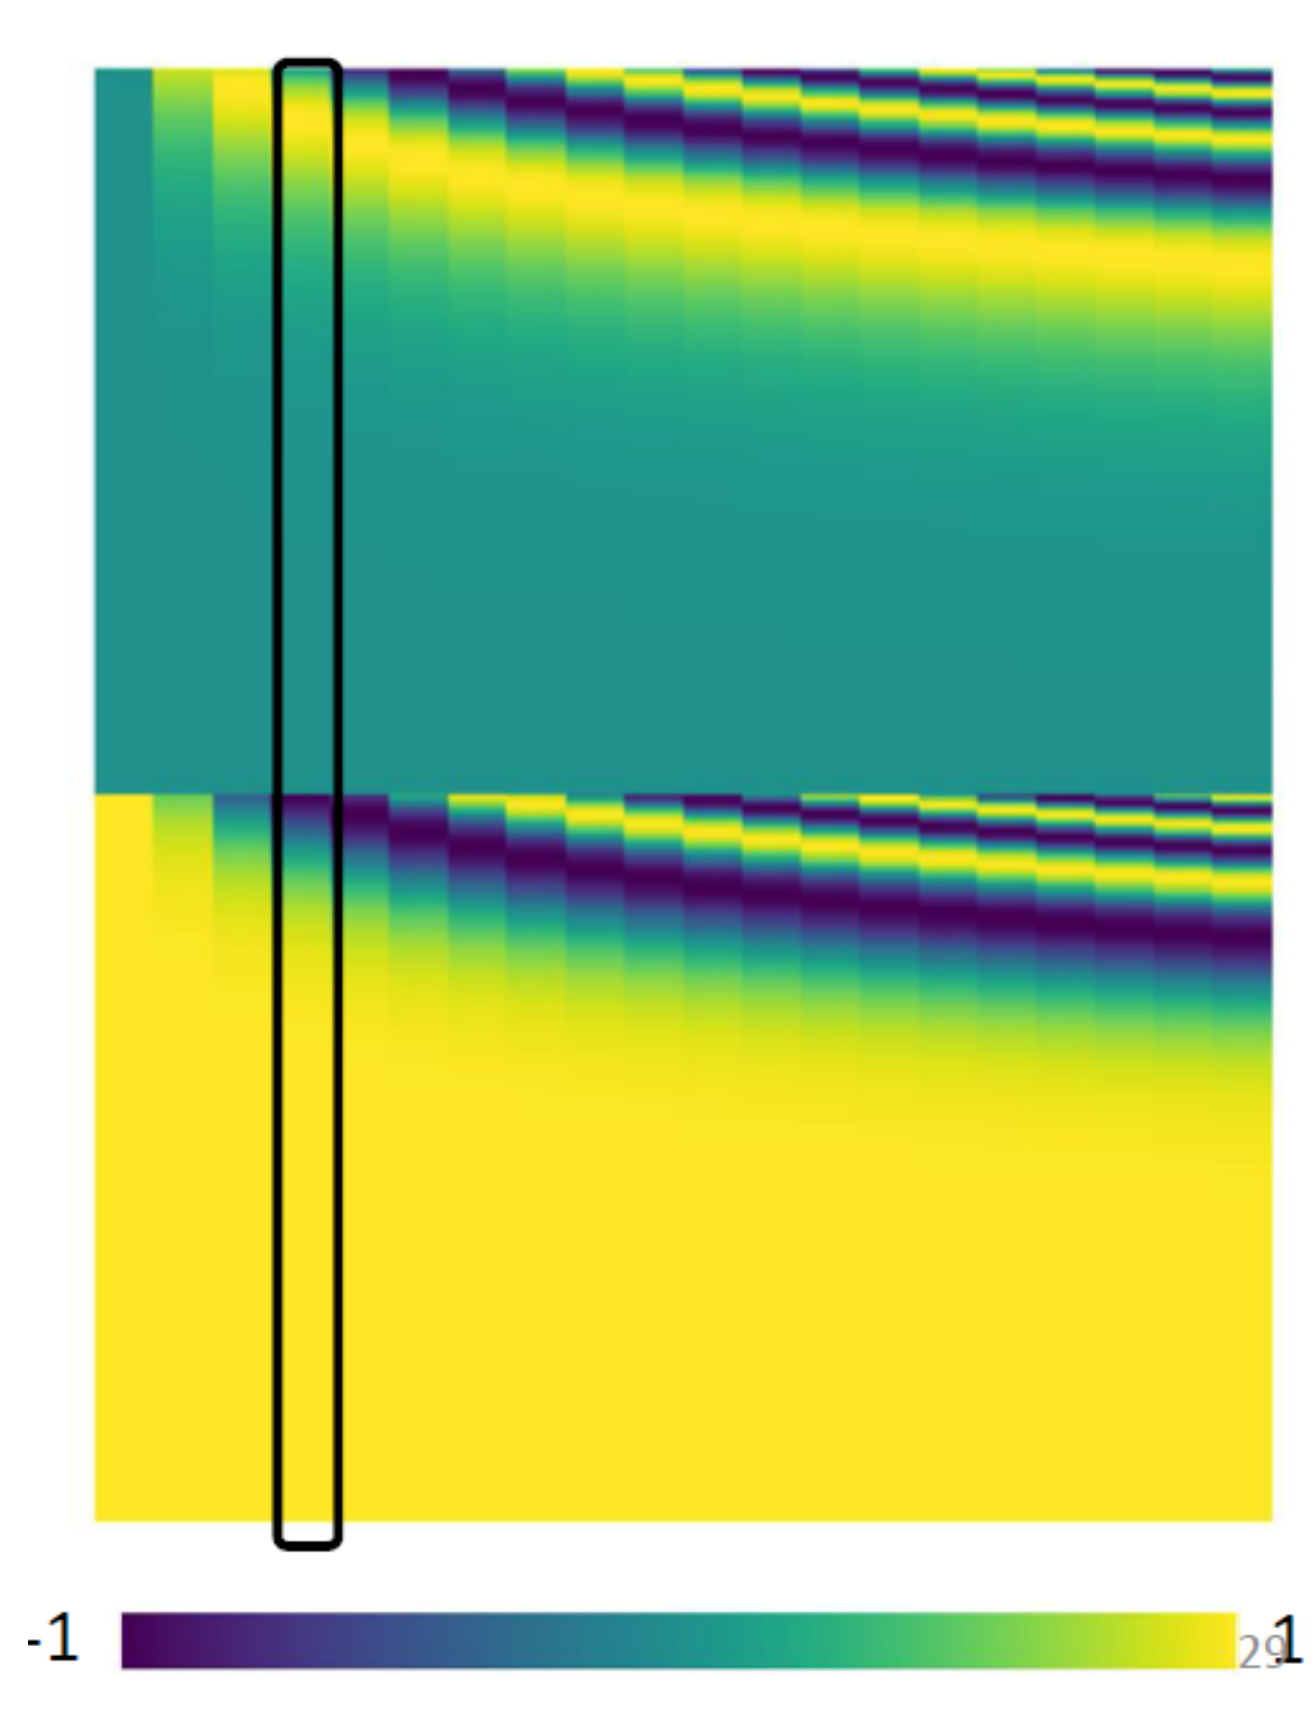

图17：与位置编码乘起来的转移矩阵 WP

Transformer 中除了单词的 Embedding，还需要使用位置 Embedding 表示单词出现在句子中的位置。因为 Transformer 不采用 RNN 的结构，而是使用全局信息，不能利用单词的顺序信息，而这部分信息对于 NLP 来说非常重要。所以 Transformer 中使用位置 Embedding 保存单词在序列中的相对或绝对位置。

位置 Embedding 用 PE表示，PE 的维度与单词 Embedding 是一样的。PE 可以通过训练得到，也可以使用某种公式计算得到。在 Transformer 中采用了后者，计算公式如下：

\begin{align}PE_{(pos, 2i)} = sin(pos/10000^{2i/d_{model}}) \\ PE_{(pos, 2i+1)} = cos(pos/10000^{2i/d_{model}}) \end{align}\tag{5}

式中， pos 表示token在sequence中的位置，例如第一个token "我" 的 pos=0 。

i ，或者准确意义上是 2i 和 2i+1 表示了Positional Encoding的维度，i 的取值范围是： \left[0,\ldots ,{{{d}_{model}}}/{2}\; \right) 。所以当 pos 为1时，对应的Positional Encoding可以写成：

PE\left(1 \right)=\left[\sin \left({1}/{{{10000}^{{0}/{512}\;}}}\; \right),\cos \left({1}/{{{10000}^{{0}/{512}\;}}}\; \right),\sin \left({1}/{{{10000}^{{2}/{512}\;}}}\; \right),\cos \left({1}/{{{10000}^{{2}/{512}\;}}}\; \right),\ldots \right]

式中， {{d}_{model}}=512。底数是10000。为什么要使用10000呢，这个就类似于玄学了，原论文中完全没有提啊，这里不得不说说论文的readability的问题，即便是很多高引的文章，最基本的内容都讨论不清楚，所以才出现像上面提问里的讨论，说实话这些论文还远远没有做到easy to follow。这里我给出一个假想：{{10000}^{{1}/{512}}}是一个比较接近1的数（1.018），如果用100000，则是1.023。这里只是猜想一下，其实大家应该完全可以使用另一个底数。

这个式子的好处是：

- 每个位置有一个唯一的positional encoding。
- 使 PE 能够适应比训练集里面所有句子更长的句子，假设训练集里面最长的句子是有 20 个单词，突然来了一个长度为 21 的句子，则使用公式计算的方法可以计算出第 21 位的 Embedding。
- 可以让模型容易地计算出相对位置，对于固定长度的间距 k ，任意位置的 PE_{pos+k} 都可以被 PE_{pos} 的线性函数表示，因为三角函数⁺特性：

cos(\alpha+\beta) = cos(\alpha)cos(\beta)-sin(\alpha)sin(\beta) \\

sin(\alpha+\beta) = sin(\alpha)cos(\beta) + cos(\alpha)sins(\beta) \\

除了以上的固定位置编码以外，还有其他的很多表示方法：

比如下图18a就是sin-cos的固定位置编码。图b就是可学习的位置编码。图c和d分别FLOATER和RNN模型学习的位置编码。

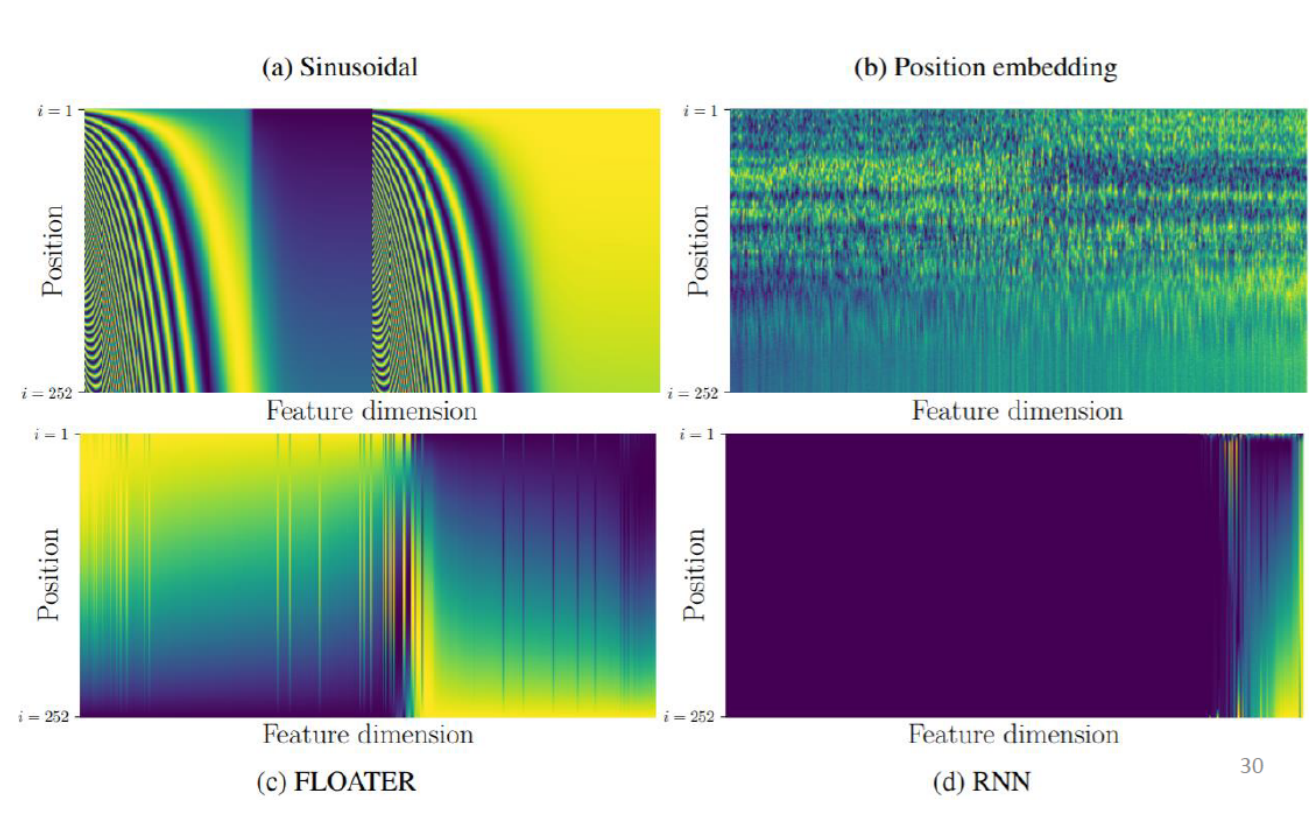

图18：其他的很多位置编码方法

接下来我们看看self-attention在sequence2sequence model里面是怎么使用的，我们可以把Encoder-Decoder中的RNN用self-attention取代掉。

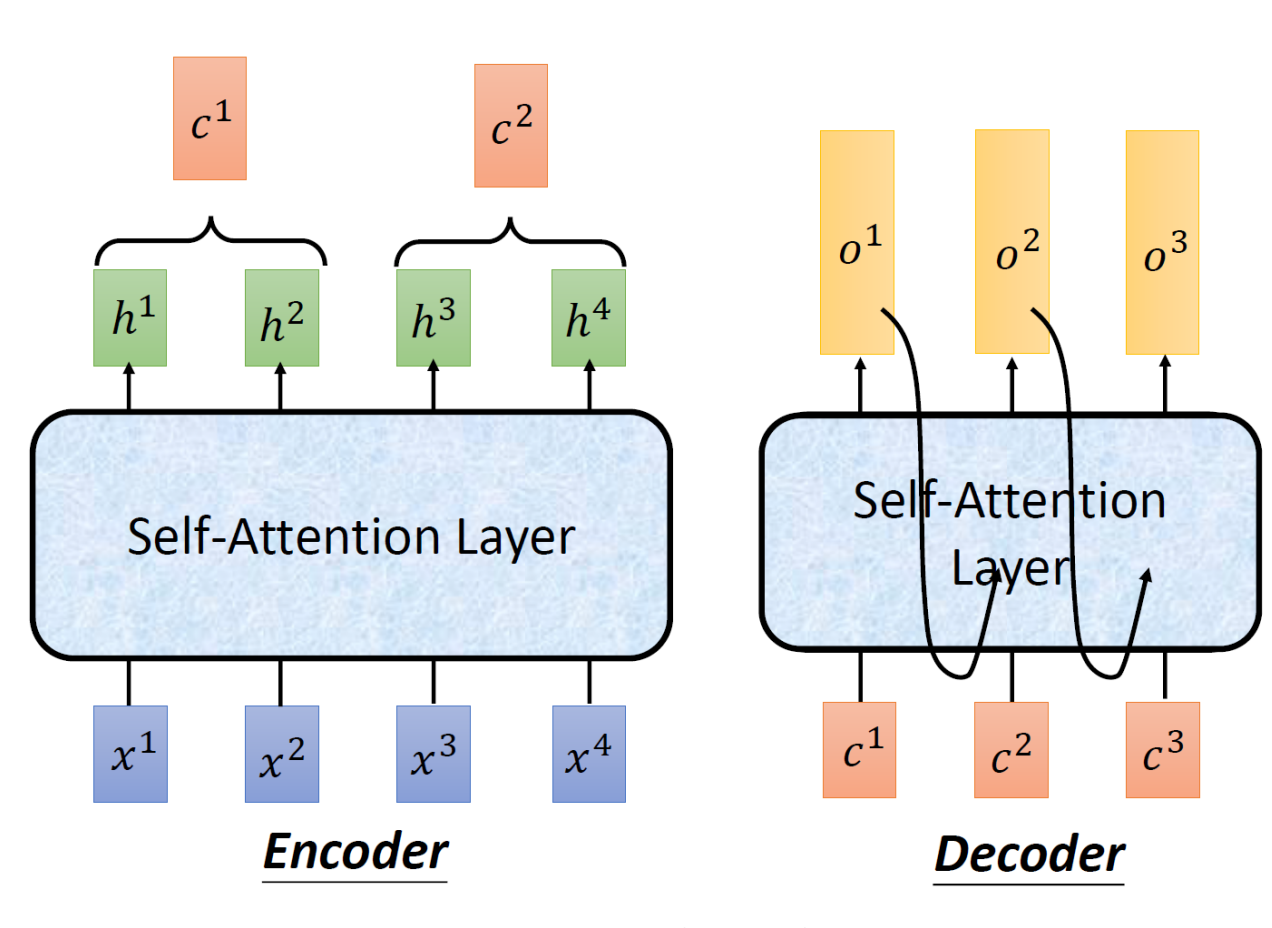
c^1
c^2
h^1
h^2
h^3
h^4
Self-Attention Layer
x^1
x^2
x^3
x^4
Encoder
o^1
o^2
o^3
Self-Attention Layer
c^1
c^2
c^3
Decoder

图18：Seq2seq with Attention

在self-attention的最后一部分我们来对比下self-attention和CNN的关系。如图19，今天在使用self-attention去处理一张图片的时候，1的那个pixel产生query，其他的各个pixel产生key。在做inner-product的时候，考虑的不是一个小的范围，而是一整张图片。

但是在做CNN的时候是只考虑感受野红框里面的资讯，而不是图片的全局信息。所以CNN可以看作是一种简化版本的self-attention。

或者可以反过来说，self-attention是一种复杂化的CNN，在做CNN的时候是只考虑感受野红框里面的资讯，而感受野的范围和大小是由人决定的。但是self-attention由attention找到相关的pixel，就好像是感受野的范围和大小是自动被学出来的，所以CNN可以看做是self-attention的特例，如图20所示。

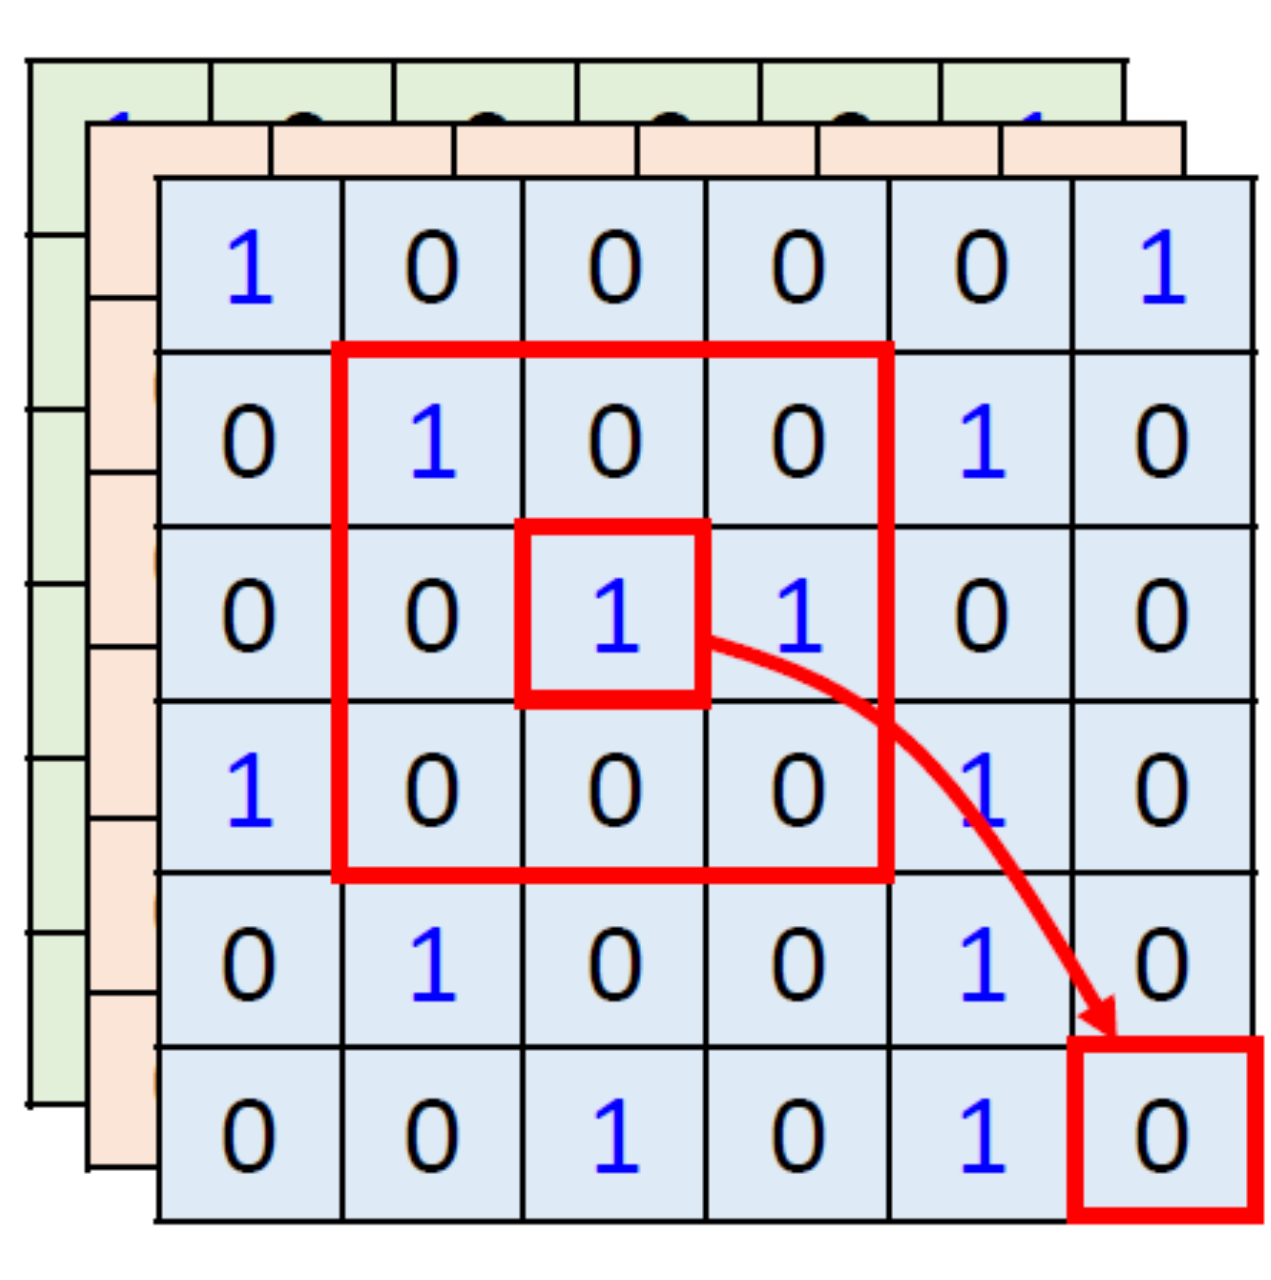
1 0 0 0 0 1
0 1 0 0 1 0
0 0 1 1 0 0
1 0 0 0 1 0
0 1 0 0 1 0
0 0 1 0 1 0

图19：CNN考虑感受野范围，而self-attention考虑的不是一个小的范围，而是一整张图片

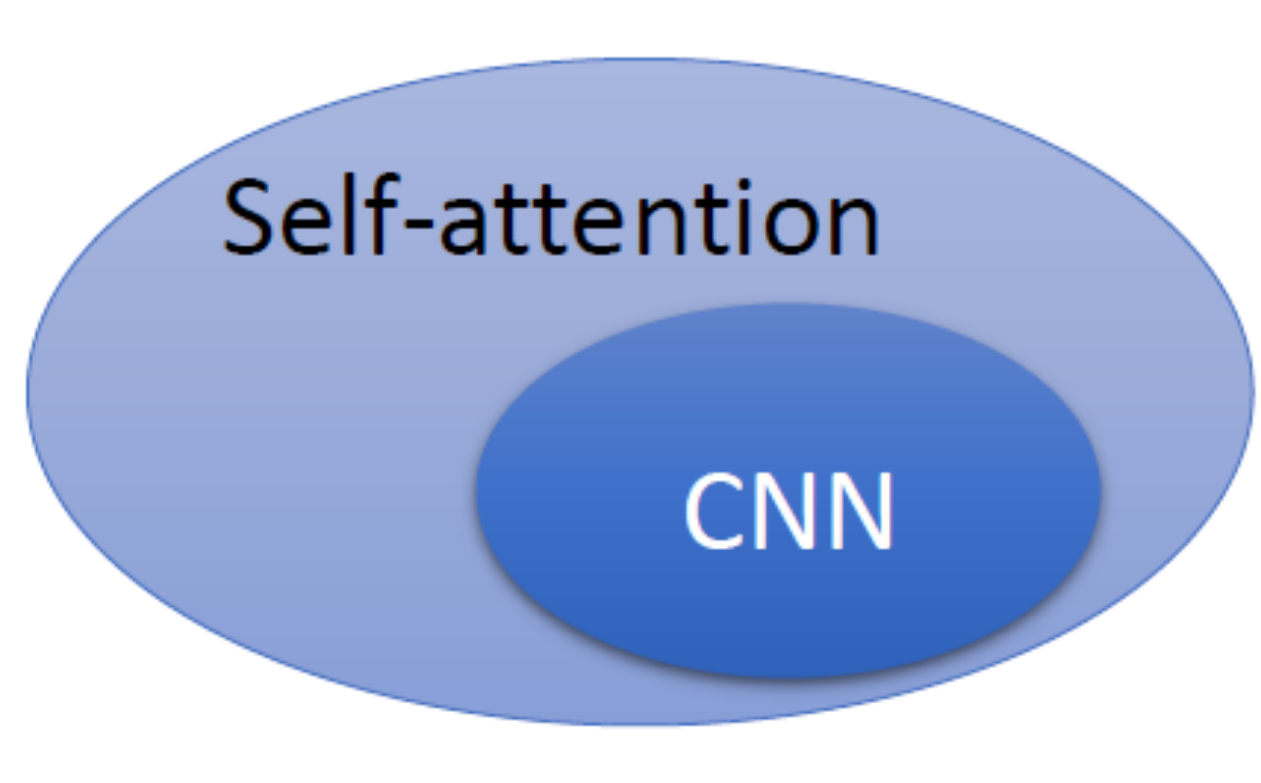
Self-attention
CNN

图20：CNN可以看做是self-attention的特例

既然self-attention是更广义的CNN，则这个模型更加flexible。而我们认为，一个模型越flexible，训练它所需要的数据量就越多，所以在训练self-attention模型时就需要更多的数据，这一点在下面介绍的论文 ViT⁺ 中有印证，它需要的数据集是有3亿张图片的JFT-300⁺，而如果不使用这么多数据而只使用ImageNet，则性能不如CNN。

---

2 Transformer的实现和代码解读

- 2.1 Transformer原理分析：

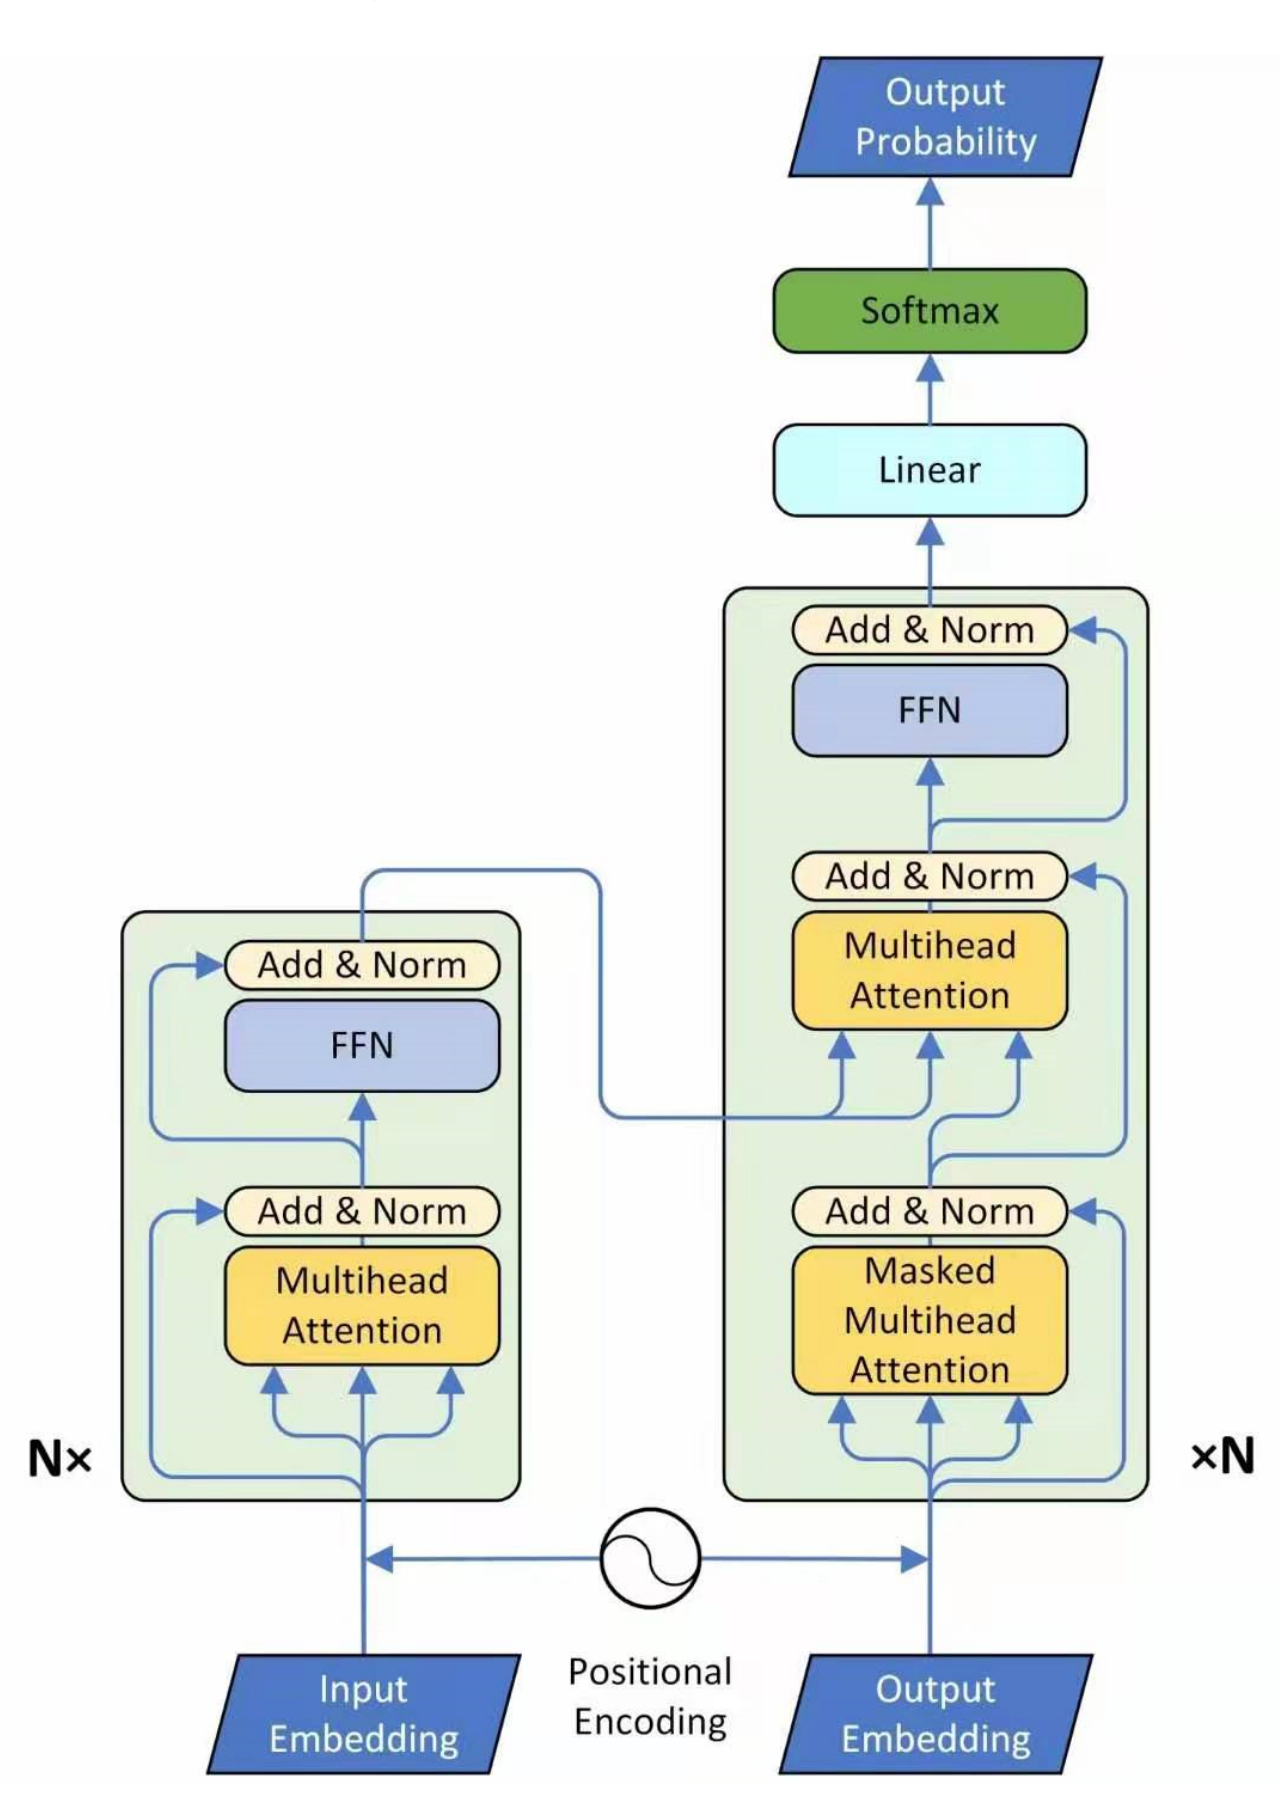
Output Probability
Softmax
Linear
Add & Norm
FFN
Add & Norm
Multihead Attention
Add & Norm
Masked Multihead Attention
Add & Norm
FFN
Add & Norm
Multihead Attention
N×
×N
Input Embedding
Positional Encoding
Output Embedding

图21：Transformer

> Encoder：

这个图21讲的是一个seq2seq的model，左侧为 Encoder block，右侧为 Decoder block。红色圈中的部分为Multi-Head Attention，是由多个Self-Attention组成的，可以看到 Encoder block 包含一个 Multi-Head Attention，而 Decoder block 包含两个 Multi-Head Attention (其中有一个用到 Masked)。Multi-Head Attention 上方还包括一个 Add & Norm 层，Add 表示残差连接 (Residual Connection) 用于防止网络退化，Norm 表示 Layer Normalization，用于对每一层的激活值进行归一化。比如说在Encoder Input处的输入是机器学习，在Decoder Input处的输入是<BOS>，输出是machine。再下一个时刻在Decoder Input处的输入是machine，输出是learning。不断重复知道输出是句点(.)代表翻译结束。

接下来我们看看这个Encoder和Decoder里面分别都做了什么事情，先看左半部分的Encoder：首先输入 X\in R (n_x,N) 通过一个Input Embedding的转移矩阵 W^X\in R (d,n_x) 变为了一个张量，即上文所述的 I\in R (d,N) ，再加上一个表示位置的Positional Encoding E\in R (d,N) ，得到一个张量，去往后面的操作。

它进入了这个绿色的block，这个绿色的block会重复 N 次。这个绿色的block里面有什么呢？它的第1层是一个上文讲的multi-head的attention。你现在一个sequence I\in R (d,N) ，经过一个multi-head的attention，你会得到另外一个sequence O\in R (d,N) 。

下一个Layer是Add & Norm，这个意思是说：把multi-head的attention的layer的输入 I\in R (d,N) 和输出 O\in R (d,N) 进行相加以后，再做Layer Normalization，至于Layer Normalization和我们熟悉的Batch Normalization的区别是什么，请参考图20和21。

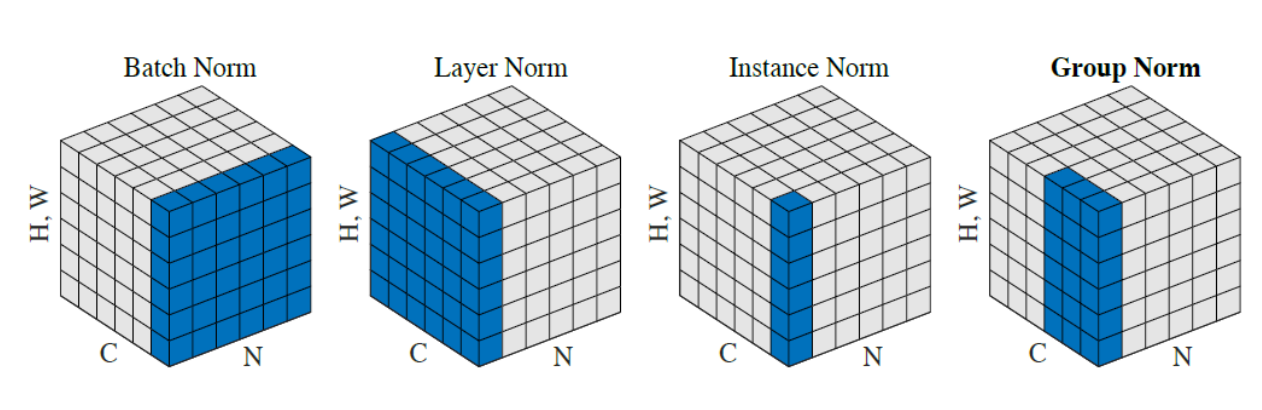
Batch Norm
Layer Norm
Instance Norm
Group Norm
H, W
C
N

图22：不同Normalization方法的对比

其中，Batch Normalization和Layer Normalization的对比可以概括为图22，Batch Normalization强行让一个batch的数据的某个channel的 \mu=0,\sigma=1 ，而Layer Normalization让一个数据的所有channel的 \mu=0,\sigma=1 。

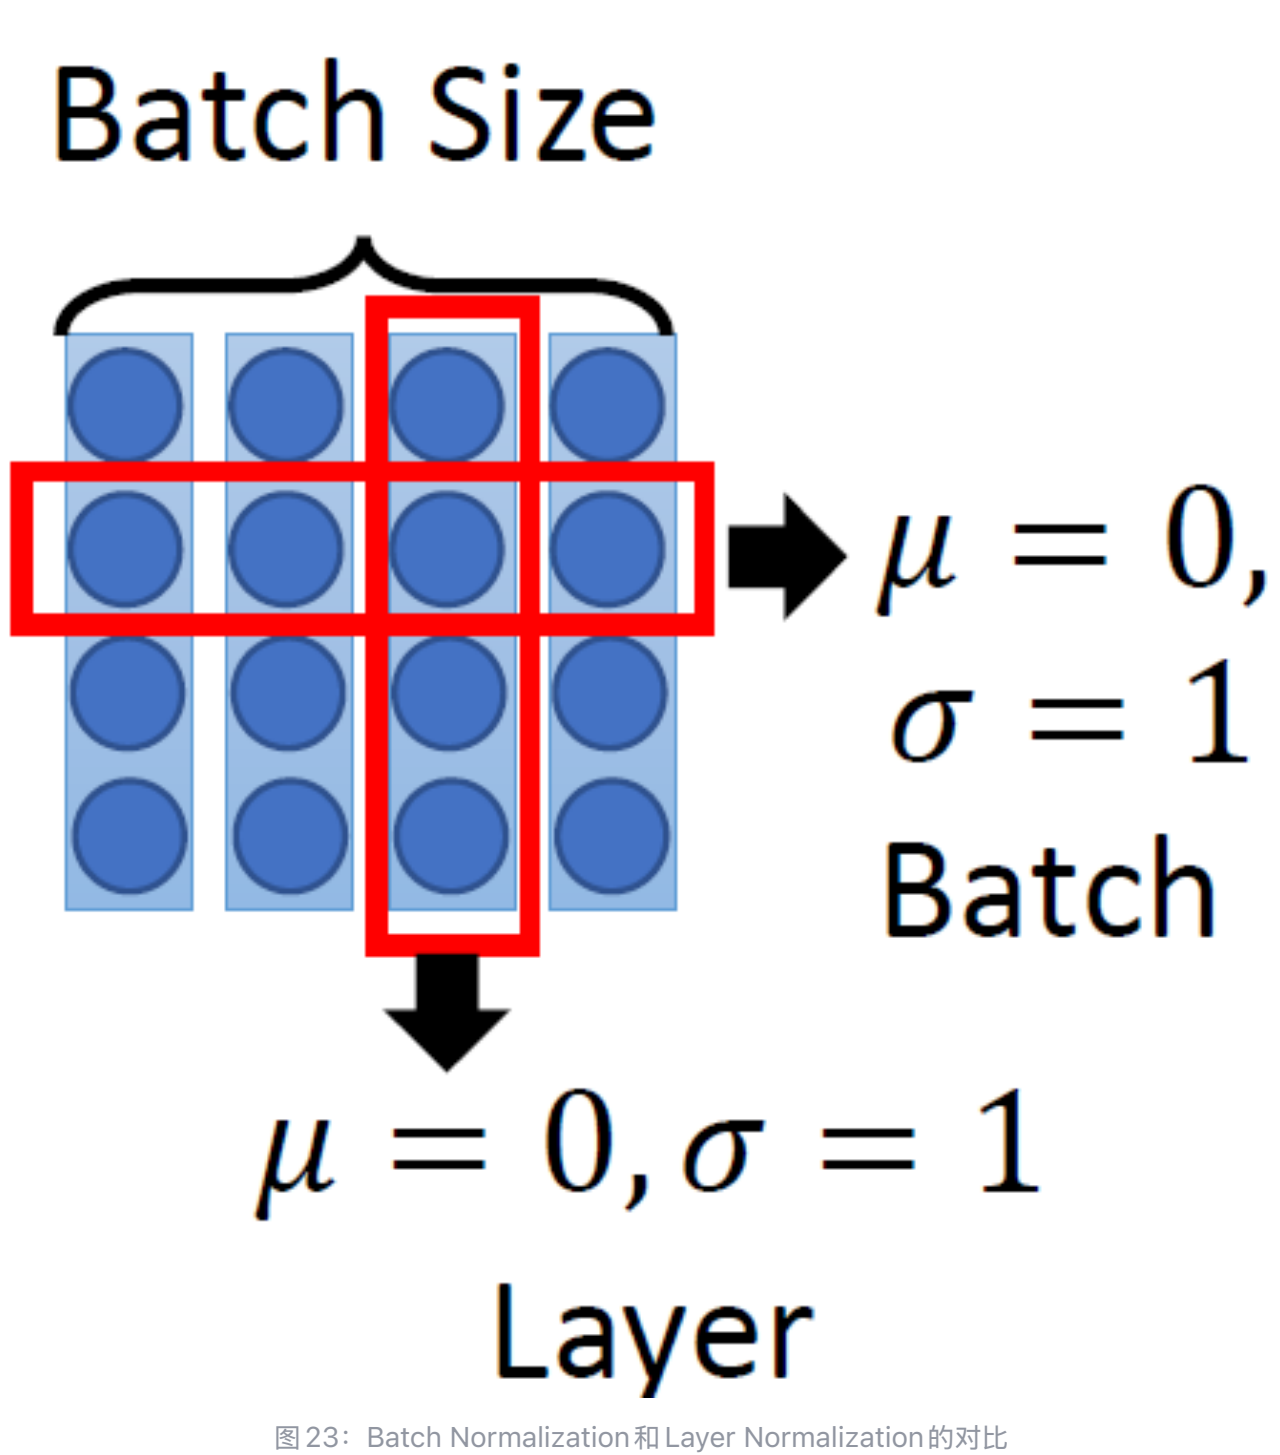
Batch Size
$\mu = 0,$
$\sigma = 1$
Batch
$\mu = 0, \sigma = 1$
Layer

图23：Batch Normalization和Layer Normalization的对比

接着是一个Feed Forward的前馈网络和一个Add & Norm Layer。

所以，这一个绿色的block的前2个Layer操作的表达式⁺为：

\color{darkgreen}{O_1}=\color{green}{\text{Layer Normalization}}(\color{teal}{I}+\color{crimson}{\text{Multi-head Self-Attention}}(\color{teal}{I}))\tag{6}

这一个绿色的block的后2个Layer操作的表达式为：

\color{darkgreen}{O_2}=\color{green}{\text{Layer Normalization}}(\color{teal}{O_1}+\color{crimson}{\text{Feed Forward Network}}(\color{teal}{O_1}))\tag{7}

\color{green}{\text{Block}}(\color{teal}{I})=\color{green}{O_2} \tag{8}

所以Transformer的Encoder的整体操作为：

\color{purple}{\text{Encoder}}(\color{darkgreen}{I})=\color{darkgreen}{\text{Block}}(...\color{darkgreen}{\text{Block}}(\color{darkgreen}{\text{Block}})(\color{teal}{I}))\\\quad N\;times \tag{9}

> Decoder：

现在来看Decoder的部分，输入包括2部分，下方是前一个time step的输出的embedding，即上文所述的 I\in R (d,N) ，再加上一个表示位置的Positional Encoding E\in R (d,N) ，得到一个张量，去往后面的操作。它进入了这个绿色的block，这个绿色的block会重复 N 次。这个绿色的block里面有什么呢？

首先是Masked Multi-Head Self-attention，masked的意思是使attention只会attend on已经产生的sequence，这个很合理，因为还没有产生出来的东西不存在，就无法做attention。

输出是：对应 \color{crimson}{i} 位置的输出词的概率分布⁺。

输入是： \color{purple}{Encoder} 的输出 和 对应 \color{crimson}{i-1} 位置decoder的输出。所以中间的attention不是self-attention，它的Key和Value来自encoder，Query来自上一位置 \color{crimson}{Decoder} 的输出。

解码：这里要特别注意一下，编码可以并行计算⁺，一次性全部Encoding出来，但解码不是一次把所有序列解出来的，而是像 RNN 一样一个一个解出来的，因为要用上一个位置的输入当作attention的query。

明确了解码过程之后最上面的图就很好懂了，这里主要的不同就是新加的另外要说一下新加的attention多加了一个mask，因为训练时的output都是Ground Truth，这样可以确保预测第 \color{crimson}{i} 个位置时不会接触到未来的信息。

- 包含两个 Multi-Head Attention 层。
- 第一个 Multi-Head Attention 层采用了 Masked 操作。
- 第二个 Multi-Head Attention 层的Key，Value矩阵使用 Encoder 的编码信息矩阵 C 进行计算，而Query使用上一个 Decoder block 的输出计算。
- 最后有一个 Softmax 层计算下一个翻译单词的概率。

下面详细介绍下Masked Multi-Head Self-attention的具体操作，**Masked在Scale操作之后，softmax操作之前。**

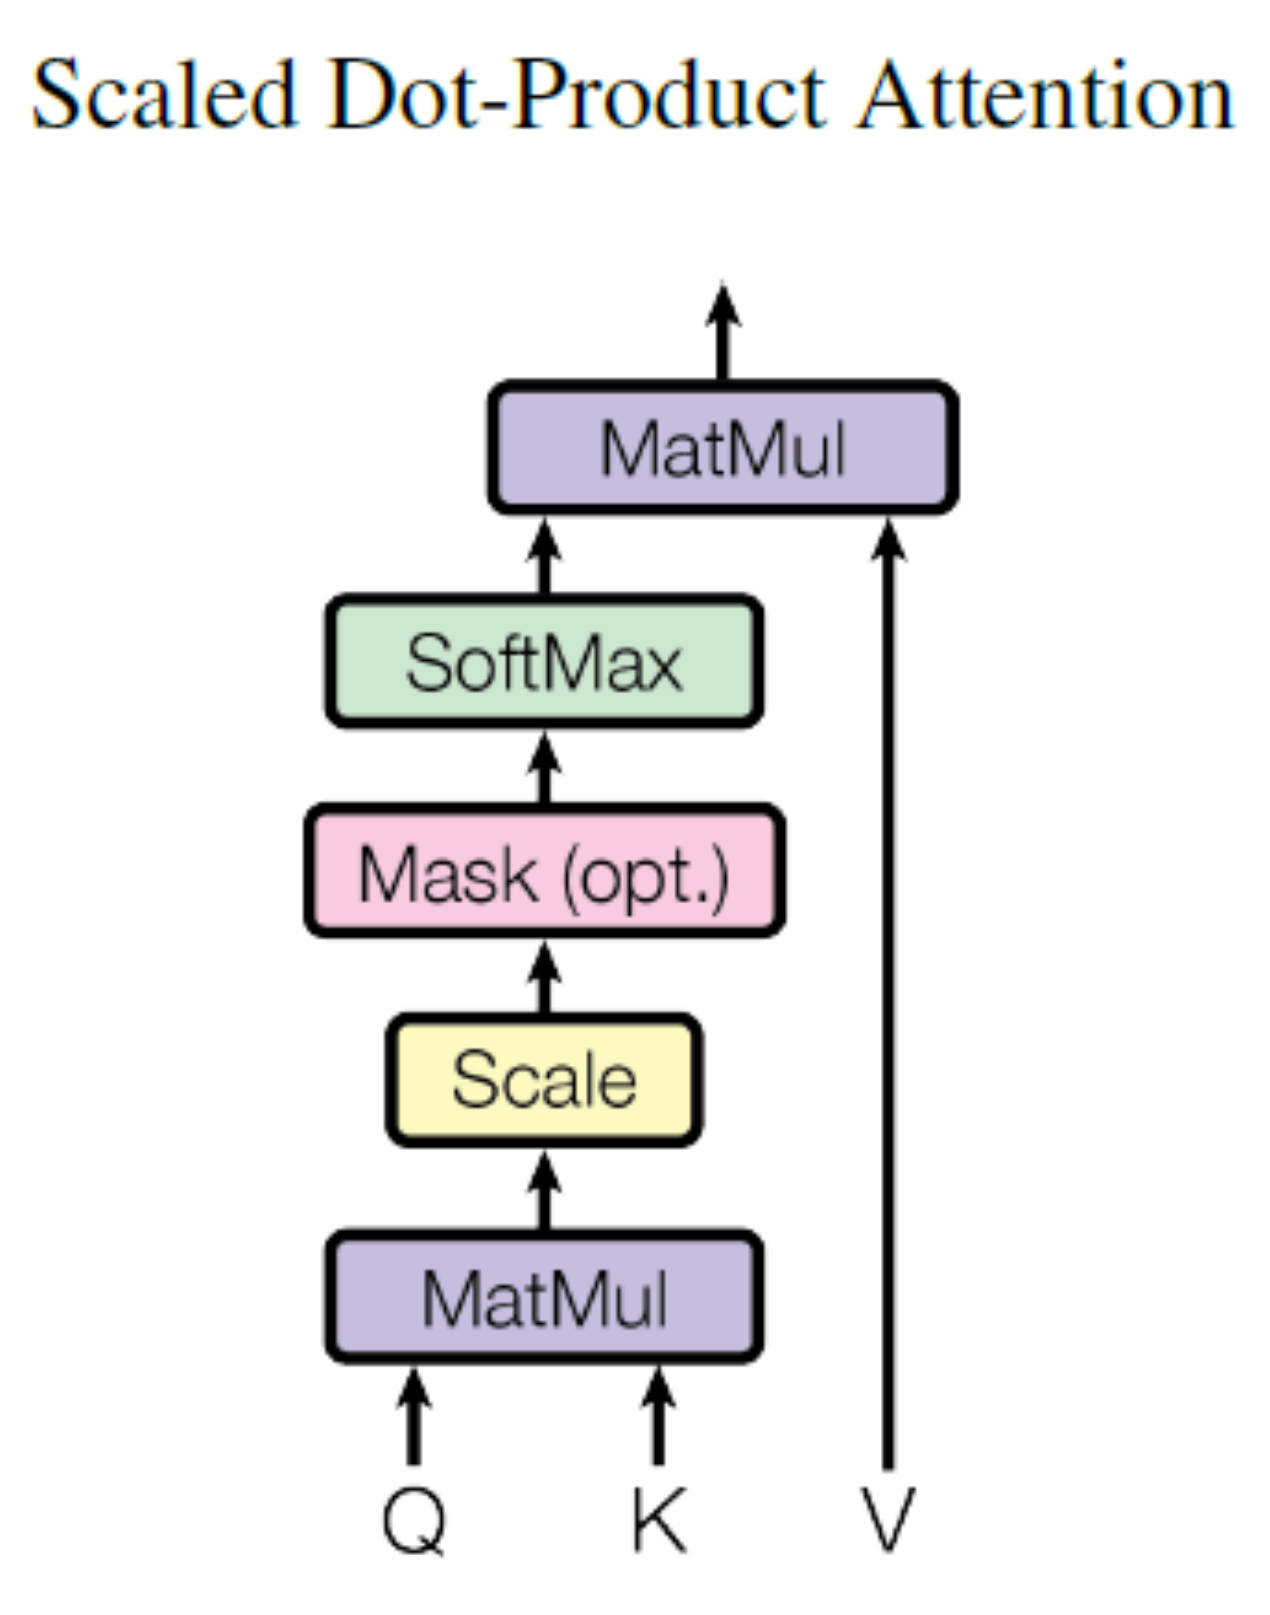
Scaled Dot-Product Attention
MatMul
SoftMax
Mask (opt.)
Scale
MatMul
Q
K
V

图24：Masked在Scale操作之后，softmax操作之前

因为在翻译的过程中是顺序翻译的，即翻译完第 i 个单词，才可以翻译第 i+1 个单词。通过 Masked 操作可以防止第 i 个单词知道第 i+1 个单词之后的信息。下面以 "我有一只猫" 翻译成 "I have a cat" 为例，了解一下 Masked 操作。在 Decoder 的时候，是需要根据之前的翻译，求解当前最有可能的翻译，如下图所示。首先根据输入 "<Begin>" 预测出第一个单词为 "I"，然后根据输入 "<Begin> I" 预测下一个单词 "have"。

Decoder 可以在训练的过程中使用 Teacher Forcing **并且并行化训练，即将正确的单词序列 (<Begin> I have a cat) 和对应输出 (I have a cat <end>) 传递到 Decoder。那么在预测第 i 个输出时，就要将第 i+1 之后的单词掩盖住，**注意 Mask 操作是在 Self-Attention 的 Softmax 之前使用的，下面用 0 1 2 3 4 5 分别表示 "<Begin> I have a cat <end>"。

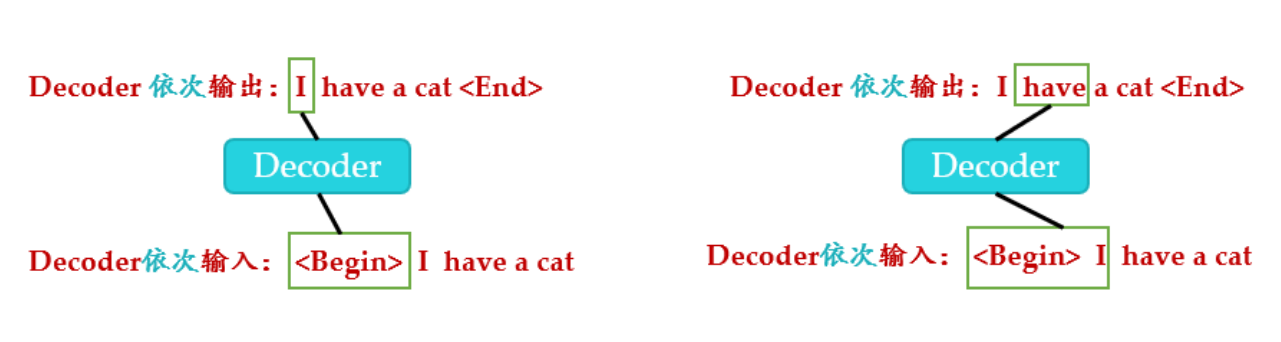
Decoder 依次输出：I have a cat <End>
Decoder
Decoder依次输入：<Begin> I have a cat
Decoder 依次输出：I have a cat <End>
Decoder
Decoder依次输入：<Begin> I have a cat

图25：Decoder过程

注意这里transformer模型训练和测试的方法不同：

测试时：

1. 输入<Begin>，解码器输出 I 。
2. 输入前面已经解码的<Begin>和 I，解码器输出have。
3. 输入已经解码的<Begin>，I, have, a, cat，解码器输出解码结束标志位<end>，每次解码都会利用前面已经解码输出的所有单词嵌入信息。

Transformer测试时的解码过程：

训练时：

不采用上述类似RNN的方法一个一个目标单词嵌入向量顺序输入训练，想采用类似编码器中的矩阵并行算法⁺，一步就把所有目标单词预测出来。要实现这个功能就可以参考编码器的操作，把目标单词嵌入向量组成矩阵一次输入即可。即：**并行化训练。**

但是在解码have时候，不能利用到后面单词a和cat的目标单词嵌入向量信息，否则这就是作弊(测试时候不可能能未卜先知)。为此引入mask。具体是：在解码器中，self-attention层只被允许处理输出序列中更靠前的那些位置，在softmax步骤前，它会把后面的位置给隐去。

Masked Multi-Head Self-attention的具体操作如图26所示。

Step1：输入矩阵包含 "<Begin> I have a cat" (0, 1, 2, 3, 4) 五个单词的表示向量，Mask是一个 5×5 的矩阵。在Mask可以发现单词 0 只能使用单词 0 的信息，而单词 1 可以使用单词 0, 1 的信息，即只能使用之前的信息。输入矩阵 X\in R_{N,d_x} 经过transformation matrix变为3个矩阵：Query Q\in R_{N,d} ，Key K\in R_{N,d} 和 Value V\in R_{N,d} 。

Step2： Q^T\cdot K 得到 Attention矩阵 A\in R_{N,N} ，此时先不急于做softmax的操作，而是先于一个 \text{Mask}\in R_{N,N} 矩阵相乘，使得attention矩阵的有些位置 归0，得到Masked Attention矩阵 \text{Mask Attention}\in R_{N,N} 。 \text{Mask}\in R_{N,N} 矩阵是个下三角矩阵⁺，为什么这样设计？是因为想在计算 Z 矩阵的某一行时，只考虑它前面token的作用。即：在计算 Z 的第一行时，刻意地把 \text{Attention} 矩阵第一行的后面几个元素屏蔽掉，只考虑 \text{Attention}_{0,0} 。在产生have这个单词时，只考虑 I，不考虑之后的have a cat，即只会attend on已经产生的sequence，这个很合理，因为还没有产生出来的东西不存在，就无法做attention。

Step3：Masked Attention矩阵进行 Softmax，每一行的和都为 1。但是单词 0 在单词 1, 2, 3, 4 上的 attention score 都为 0。得到的结果再与 V 矩阵相乘得到最终的self-attention层的输出结果 Z_1\in R_{N,d} 。

Step4： Z_1\in R_{N,d} 只是某一个head的结果，将多个head的结果concat在一起之后再最后进行Linear Transformation得到最终的Masked Multi-Head Self-attention的输出结果 Z\in R_{N,d} 。

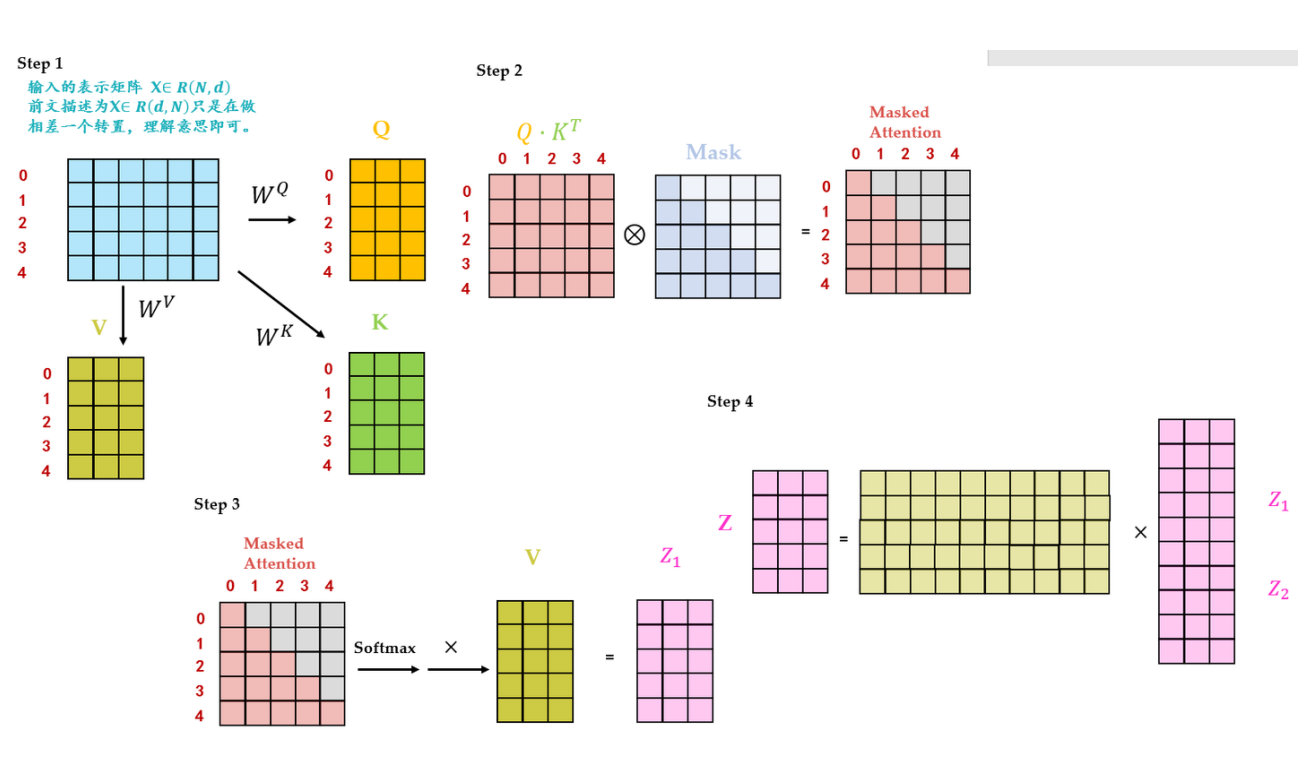
Step 1
输入的表示矩阵 X∈R(N,d)
Step 2
Step 3
Step 4
W^Q
W^K
W^V
Q
K
V
$Q \cdot K^T$
Mask
Masked Attention
0 1 2 3 4
Softmax
Z_1
Z
Z_2

图26：Masked Multi-Head Self-attention的具体操作

第1个Masked Multi-Head Self-attention的 \text{Query, Key, Value} 均来自Output Embedding。

第2个Multi-Head Self-attention的 \text{Query} 来自第1个Self-attention layer的输出，\text{Key, Value} 来自Encoder的输出。

为什么这么设计？这里提供一种个人的理解：

\text{Key, Value} 来自Transformer Encoder的输出，所以可以看做**句子(Sequence)/图片(image)的内容信息(content，比如句意是："我有一只猫"，图片内容是："有几辆车，几个人等等")。**

\text{Query} 表达了一种诉求：希望得到什么，可以看做**引导信息(guide)。**

通过Multi-Head Self-attention结合在一起的过程就相当于是**把我们需要的内容信息指导表达出来。**

Decoder的最后是Softmax 预测输出单词。因为 Mask 的存在，使得单词 0 的输出 Z(0,) 只包含单词 0 的信息。Softmax 根据输出矩阵的每一行预测下一个单词，如下图27所示。

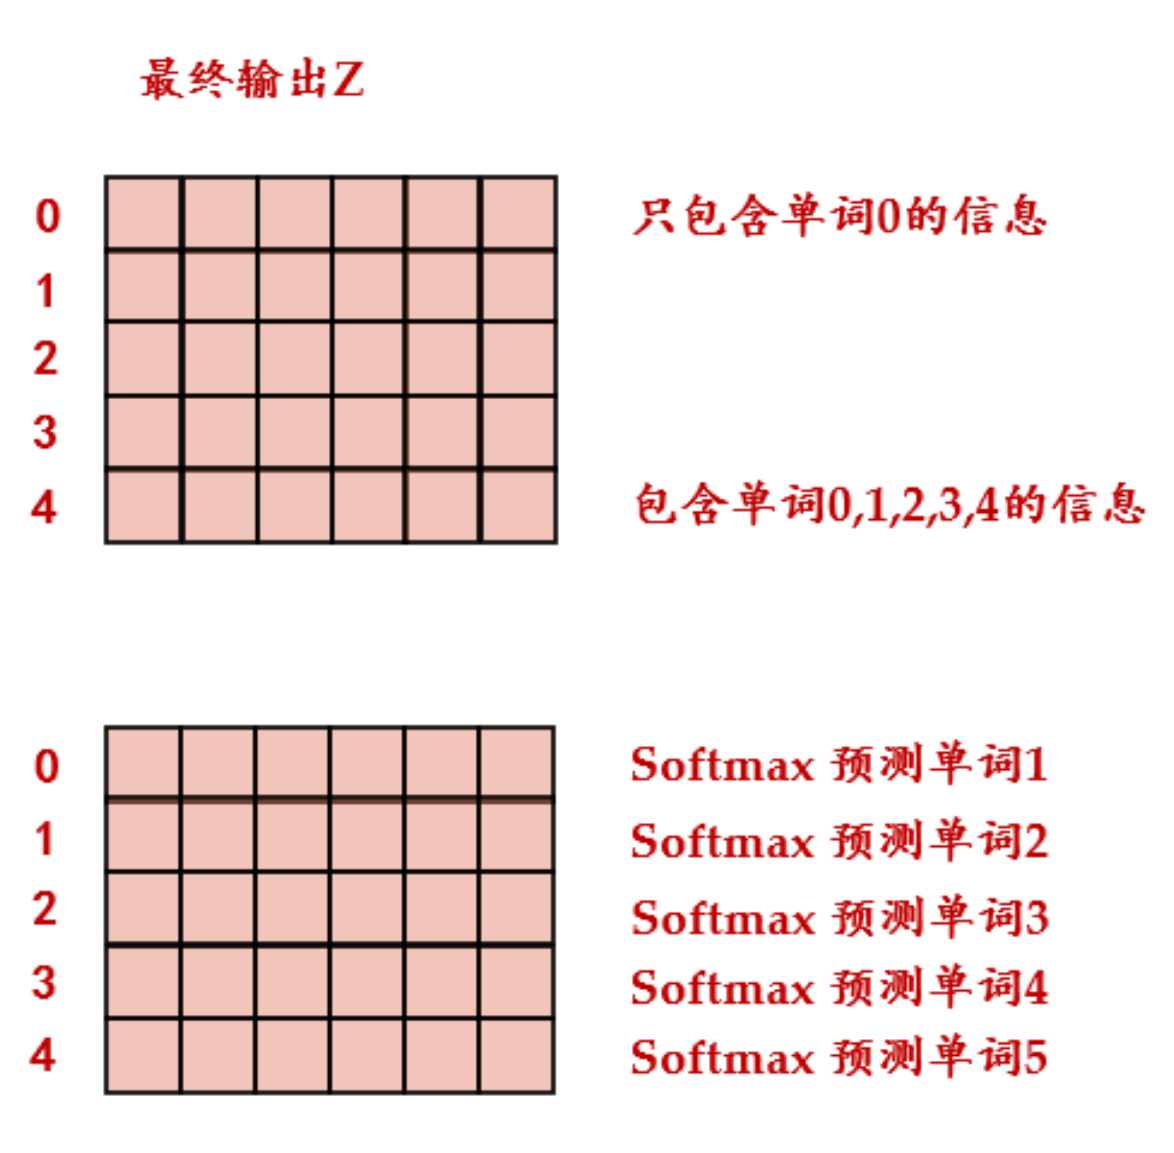
最终输出Z
0
1
2
3
4
只包含单词0的信息
包含单词0,1,2,3,4的信息
Softmax 预测单词1
Softmax 预测单词2
Softmax 预测单词3
Softmax 预测单词4
Softmax 预测单词5

图27：Softmax 根据输出矩阵的每一行预测下一个单词

如下图28所示为Transformer的整体结构。

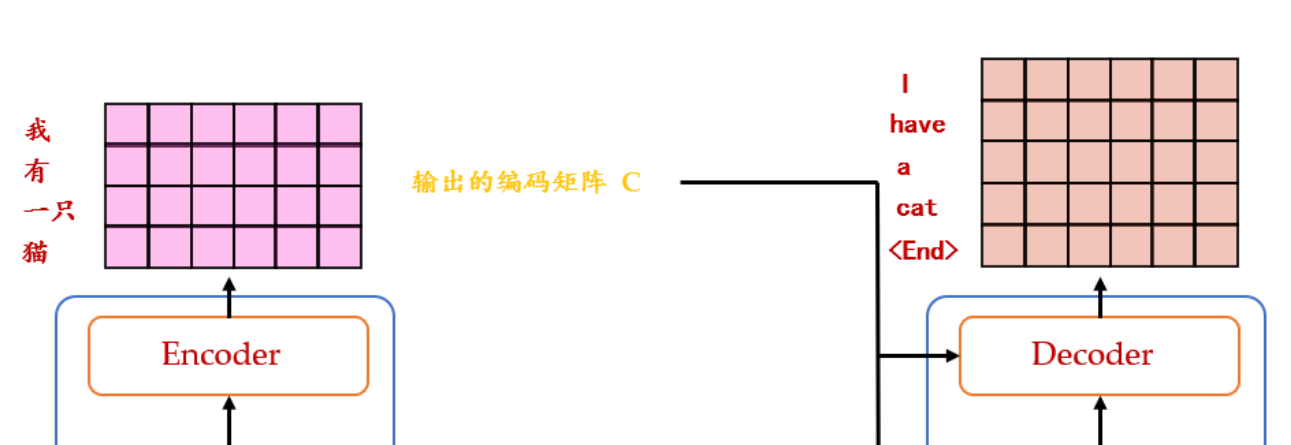
我
有
一只
猫
输出的编码矩阵 C
I
have
a
cat
<End>
Encoder
Decoder

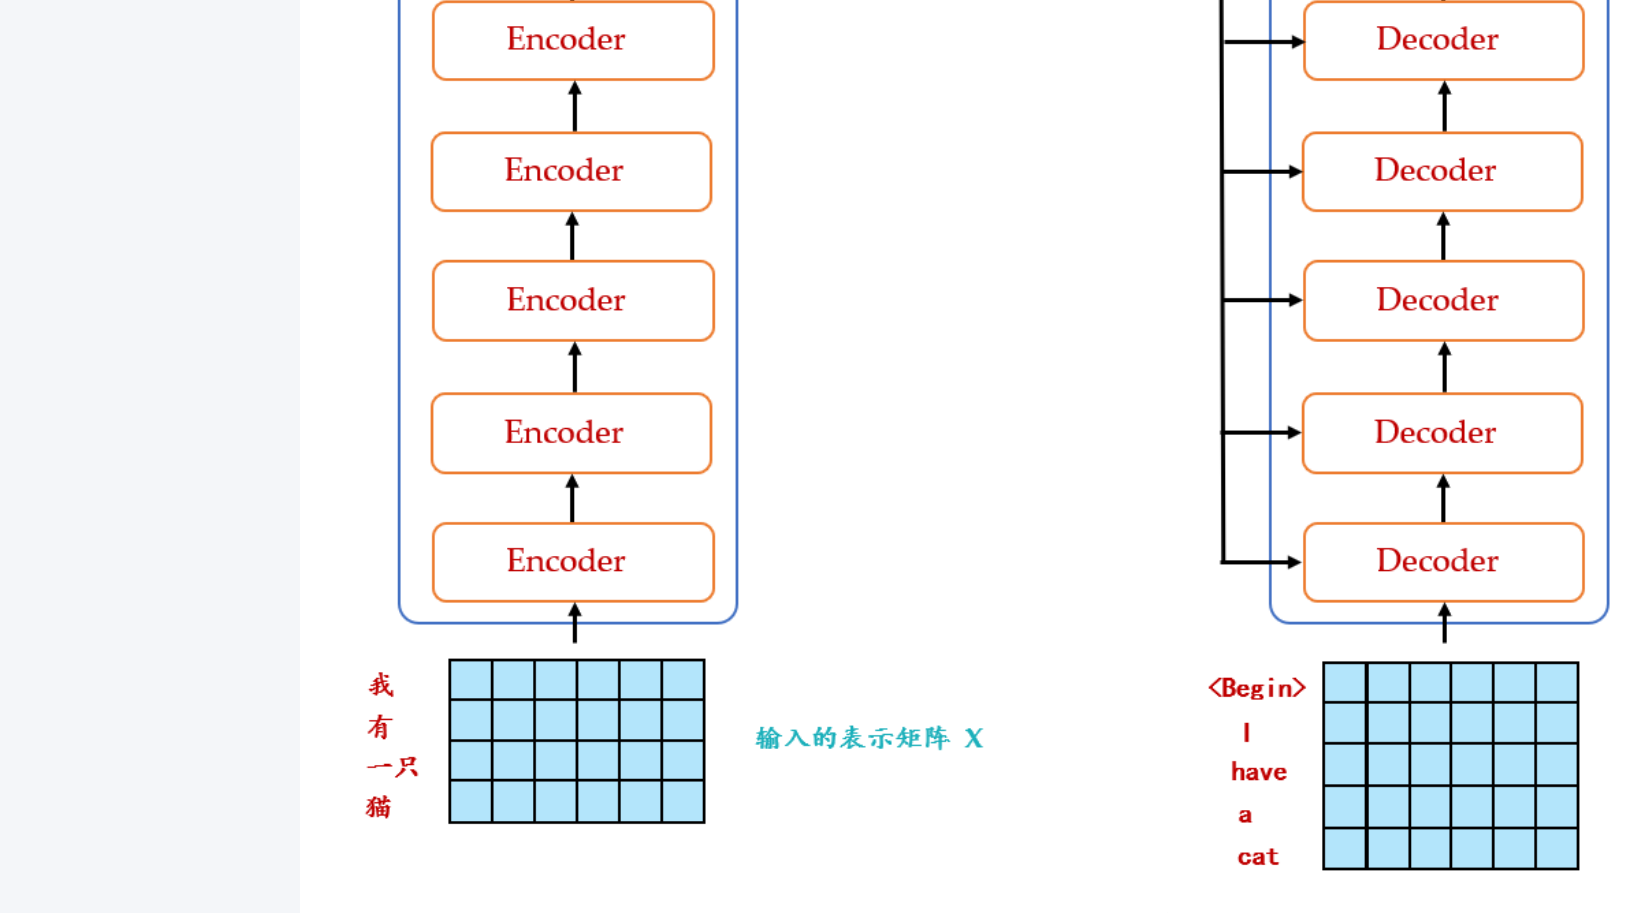

图 28：Transformer的整体结构

- 2.2 Transformer代码解读：

代码来自：

> ScaledDotProductAttention：
> 实现的是图 22 的操作，先令 Q\cdot K^T，再对结果按位乘以 \text{Mask} 矩阵，再做 \text{Softmax} 操作，最后的结果与 V 相乘，得到 self-attention 的输出。

```
class ScaledDotProductAttention(nn.Module):
    ''' Scaled Dot-Product Attention '''

    def __init__(self, temperature, attn_dropout=0.1):
        super().__init__()
        self.temperature = temperature
        self.dropout = nn.Dropout(attn_dropout)

    def forward(self, q, k, v, mask=None):

        attn = torch.matmul(q / self.temperature, k.transpose(2, 3))

        if mask is not None:
            attn = attn.masked_fill(mask == 0, -1e9)

        attn = self.dropout(F.softmax(attn, dim=-1))
        output = torch.matmul(attn, v)

        return output, attn
```

> 位置编码 PositionalEncoding：
> 实现的是式(5)的位置编码。

```
class PositionalEncoding(nn.Module):

    def __init__(self, d_hid, n_position=200):
        super(PositionalEncoding, self).__init__()

        # Not a parameter
        self.register_buffer('pos_table', self._get_sinusoid_encoding_tabl

    def _get_sinusoid_encoding_table(self, n_position, d_hid):
        ''' Sinusoid position encoding table '''
        # TODO: make it with torch instead of numpy

        def get_position_angle_vec(position):
            return [position / np.power(10000, 2 * (hid_j // 2) / d_hid) f

        sinusoid_table = np.array([get_position_angle_vec(pos_i) for pos_i
        sinusoid_table[:, 0::2] = np.sin(sinusoid_table[:, 0::2])  # dim 2
        sinusoid_table[:, 1::2] = np.cos(sinusoid_table[:, 1::2])  # dim 2

        return torch.FloatTensor(sinusoid_table).unsqueeze(0)#(1,N,d)

    def forward(self, x):
        # x(B,N,d)
        return x + self.pos_table[:, :x.size(1)].clone().detach()
```

> MultiHeadAttention：
> 实现图 13，14 的多头 self-attention。

```
class MultiHeadAttention(nn.Module):
    ''' Multi-Head Attention module '''

    def __init__(self, n_head, d_model, d_k, d_v, dropout=0.1):
        super().__init__()

        self.n_head = n_head
        self.d_k = d_k
        self.d_v = d_v

        self.w_qs = nn.Linear(d_model, n_head * d_k, bias=False)
        self.w_ks = nn.Linear(d_model, n_head * d_k, bias=False)
        self.w_vs = nn.Linear(d_model, n_head * d_v, bias=False)
        self.fc = nn.Linear(n_head * d_v, d_model, bias=False)

        self.attention = ScaledDotProductAttention(temperature=d_k ** 0.5)

        self.dropout = nn.Dropout(dropout)
        self.layer_norm = nn.LayerNorm(d_model, eps=1e-6)


    def forward(self, q, k, v, mask=None):

        d_k, d_v, n_head = self.d_k, self.d_v, self.n_head
        sz_b, len_q, len_k, len_v = q.size(0), q.size(1), k.size(1), v.siz

        residual = q


        # Pass through the pre-attention projection: b x lq x (n*dv)
        # Separate different heads: b x lq x n x dv
        q = self.w_qs(q).view(sz_b, len_q, n_head, d_k)
        k = self.w_ks(k).view(sz_b, len_k, n_head, d_k)
        v = self.w_vs(v).view(sz_b, len_v, n_head, d_v)

        # Transpose for attention dot product: b x n x lq x dv
        q, k, v = q.transpose(1, 2), k.transpose(1, 2), v.transpose(1, 2)

        if mask is not None:
            mask = mask.unsqueeze(1)   # For head axis broadcasting.

        q, attn = self.attention(q, k, v, mask=mask)

        #q (sz_b,n_head,N=len_q,d_k)
        #k (sz_b,n_head,N=len_k,d_k)
        #v (sz_b,n_head,N=len_v,d_v)

        # Transpose to move the head dimension back: b x lq x n x dv
        # Combine the last two dimensions to concatenate all the heads tog
        q = q.transpose(1, 2).contiguous().view(sz_b, len_q, -1)

        #q (sz_b,len_q,n_head,N * d_k)
        q = self.dropout(self.fc(q))
        q += residual

        q = self.layer_norm(q)

        return q, attn
```

> 前向传播 Feed Forward Network：

```
class PositionwiseFeedForward(nn.Module):
    ''' A two-feed-forward-layer module '''

    def __init__(self, d_in, d_hid, dropout=0.1):
        super().__init__()
        self.w_1 = nn.Linear(d_in, d_hid) # position-wise
        self.w_2 = nn.Linear(d_hid, d_in) # position-wise
        self.layer_norm = nn.LayerNorm(d_in, eps=1e-6)
        self.dropout = nn.Dropout(dropout)

    def forward(self, x):

        residual = x

        x = self.w_2(F.relu(self.w_1(x)))
        x = self.dropout(x)
        x += residual

        x = self.layer_norm(x)

        return x
```

> EncoderLayer：
> 实现图 26 中的一个 EncoderLayer，具体的结构如图 19 所示。

```
class EncoderLayer(nn.Module):
    ''' Compose with two layers '''

    def __init__(self, d_model, d_inner, n_head, d_k, d_v, dropout=0.1):
        super(EncoderLayer, self).__init__()
        self.slf_attn = MultiHeadAttention(n_head, d_model, d_k, d_v, drop
        self.pos_ffn = PositionwiseFeedForward(d_model, d_inner, dropout=d

    def forward(self, enc_input, slf_attn_mask=None):
        enc_output, enc_slf_attn = self.slf_attn(
            enc_input, enc_input, enc_input, mask=slf_attn_mask)
        enc_output = self.pos_ffn(enc_output)
        return enc_output, enc_slf_attn
```

> DecoderLayer：
> 实现图 28 中的一个 DecoderLayer，具体的结构如图 21 所示。

```
class DecoderLayer(nn.Module):
    ''' Compose with three layers '''

    def __init__(self, d_model, d_inner, n_head, d_k, d_v, dropout=0.1):
        super(DecoderLayer, self).__init__()
        self.slf_attn = MultiHeadAttention(n_head, d_model, d_k, d_v, drop
        self.enc_attn = MultiHeadAttention(n_head, d_model, d_k, d_v, drop
        self.pos_ffn = PositionwiseFeedForward(d_model, d_inner, dropout=d

    def forward(
            self, dec_input, enc_output,
            slf_attn_mask=None, dec_enc_attn_mask=None):
        dec_output, dec_slf_attn = self.slf_attn(
            dec_input, dec_input, dec_input, mask=slf_attn_mask)
        dec_output, dec_enc_attn = self.enc_attn(
            dec_output, enc_output, enc_output, mask=dec_enc_attn_mask)
        dec_output = self.pos_ffn(dec_output)
        return dec_output, dec_slf_attn, dec_enc_attn
```

> Encoder：
> 实现图 28,21 左侧的 Encoder：

```
class Encoder(nn.Module):
    ''' A encoder model with self attention mechanism. '''

    def __init__(
            self, n_src_vocab, d_word_vec, n_layers, n_head, d_k, d_v,
            d_model, d_inner, pad_idx, dropout=0.1, n_position=200):

        super().__init__()

        self.src_word_emb = nn.Embedding(n_src_vocab, d_word_vec, padding_
        self.position_enc = PositionalEncoding(d_word_vec, n_position=n_po
        self.dropout = nn.Dropout(p=dropout)
        self.layer_stack = nn.ModuleList([
            EncoderLayer(d_model, d_inner, n_head, d_k, d_v, dropout=dropo
            for _ in range(n_layers)])
        self.layer_norm = nn.LayerNorm(d_model, eps=1e-6)

    def forward(self, src_seq, src_mask, return_attns=False):

        enc_slf_attn_list = []

        # -- Forward

        enc_output = self.dropout(self.position_enc(self.src_word_emb(src_
        enc_output = self.layer_norm(enc_output)

        for enc_layer in self.layer_stack:
            enc_output, enc_slf_attn = enc_layer(enc_output, slf_attn_mask
            enc_slf_attn_list += [enc_slf_attn] if return_attns else []

        if return_attns:
            return enc_output, enc_slf_attn_list
        return enc_output,
```

> Decoder：
> 实现图 28,21 右侧的 Decoder：

```
class Decoder(nn.Module):
    ''' A decoder model with self attention mechanism. '''


    def forward(self, trg_seq, trg_mask, enc_output, src_mask, return_attn

        dec_slf_attn_list, dec_enc_attn_list = [], []

        # -- Forward
        dec_output = self.dropout(self.position_enc(self.trg_word_emb(trg_
        dec_output = self.layer_norm(dec_output)

        for dec_layer in self.layer_stack:
            dec_output, dec_slf_attn, dec_enc_attn = dec_layer(
                dec_output, enc_output, slf_attn_mask=trg_mask, dec_enc_at
            dec_slf_attn_list += [dec_slf_attn] if return_attns else []
            dec_enc_attn_list += [dec_enc_attn] if return_attns else []

        if return_attns:
            return dec_output, dec_slf_attn_list, dec_enc_attn_list
        return dec_output,
```

> 整体结构：
> 实现图 28,21 整体的 Transformer：

```
class Transformer(nn.Module):
    ''' A sequence to sequence model with attention mechanism. '''

    def __init__(
            self, n_src_vocab, n_trg_vocab, src_pad_idx, trg_pad_idx,
            d_word_vec=512, d_model=512, d_inner=2048,
            n_layers=6, n_head=8, d_k=64, d_v=64, dropout=0.1, n_position=
            trg_emb_prj_weight_sharing=True, emb_src_trg_weight_sharing=Tr

        super().__init__()

        self.src_pad_idx, self.trg_pad_idx = src_pad_idx, trg_pad_idx

        self.encoder = Encoder(
            n_src_vocab=n_src_vocab, n_position=n_position,
            d_word_vec=d_word_vec, d_model=d_model, d_inner=d_inner,
            n_layers=n_layers, n_head=n_head, d_k=d_k, d_v=d_v,
            pad_idx=src_pad_idx, dropout=dropout)

        self.decoder = Decoder(
            n_trg_vocab=n_trg_vocab, n_position=n_position,
            d_word_vec=d_word_vec, d_model=d_model, d_inner=d_inner,
            n_layers=n_layers, n_head=n_head, d_k=d_k, d_v=d_v,
            pad_idx=trg_pad_idx, dropout=dropout)

        self.trg_word_prj = nn.Linear(d_model, n_trg_vocab, bias=False)

        for p in self.parameters():
            if p.dim() > 1:
                nn.init.xavier_uniform_(p)

        assert d_model == d_word_vec, \
        'To facilitate the residual connections, \
         the dimensions of all module outputs shall be the same.'

        self.x_logit_scale = 1.
        if trg_emb_prj_weight_sharing:
            # Share the weight between target word embedding & last dense
            self.trg_word_prj.weight = self.decoder.trg_word_emb.weight
            self.x_logit_scale = (d_model ** -0.5)

        if emb_src_trg_weight_sharing:
            self.encoder.src_word_emb.weight = self.decoder.trg_word_emb.w


    def forward(self, src_seq, trg_seq):

        src_mask = get_pad_mask(src_seq, self.src_pad_idx)
        trg_mask = get_pad_mask(trg_seq, self.trg_pad_idx) & get_subsequen

        enc_output, *_ = self.encoder(src_seq, src_mask)
        dec_output, *_ = self.decoder(trg_seq, trg_mask, enc_output, src_m
        seq_logit = self.trg_word_prj(dec_output) * self.x_logit_scale

        return seq_logit.view(-1, seq_logit.size(2))
```

> 产生 Mask：

```
def get_pad_mask(seq, pad_idx):
    return (seq != pad_idx).unsqueeze(-2)


def get_subsequent_mask(seq):
    ''' For masking out the subsequent info. '''
    sz_b, len_s = seq.size()
    subsequent_mask = (1 - torch.triu(
        torch.ones((1, len_s, len_s), device=seq.device), diagonal=1)).boo
    return subsequent_mask
```

> src_mask = get_pad_mask(src_seq, self.src_pad_idx)
> 用于产生 Encoder 的 Mask，它是一列 Bool 值，负责把标点 mask 掉。
> trg_mask = get_pad_mask(trg_seq, self.trg_pad_idx) & get_subsequent_mask(trg_seq)
> 用于产生 Decoder 的 Mask。它是一个矩阵，如图 24 中的 Mask 所示，功能已在上文介绍。

---

3 Transformer+Detection：引入视觉领域的首创 DETR

> 论文名称：End-to-End Object Detection with Transformers

论文地址：

- 3.1 DETR原理分析：

\color{indianred}{\text{网络架构部分解读:}}

本文的任务是 Object detection，用到的工具是 Transformers，特点是 End-to-end。

目标检测⁺的任务是要去预测一系列的 Bounding Box 的坐标以及 Label， 现代大多数检测器通过定义一些 proposal，anchor 或者 windows，把问题构建成为一个分类和回归问题来间接地完成这个任务。**文章所做的工作，就是将 transformers 运用到了 object detection 领域，取代了现在的模型需要手工设计的工作，并且取得了不错的结果。**在 object detection 上 DETR 准确率和运行时间上和 Faster RCNN 相当；将模型 generalize 到 panoptic segmentation 任务上，DETR 表现甚至还超过了其他的 baseline。DETR 第一个使用 End to End 的方式解决检测问题，解决的方法是把检测问题视作是一个 set prediction problem，如下图 29 所示。

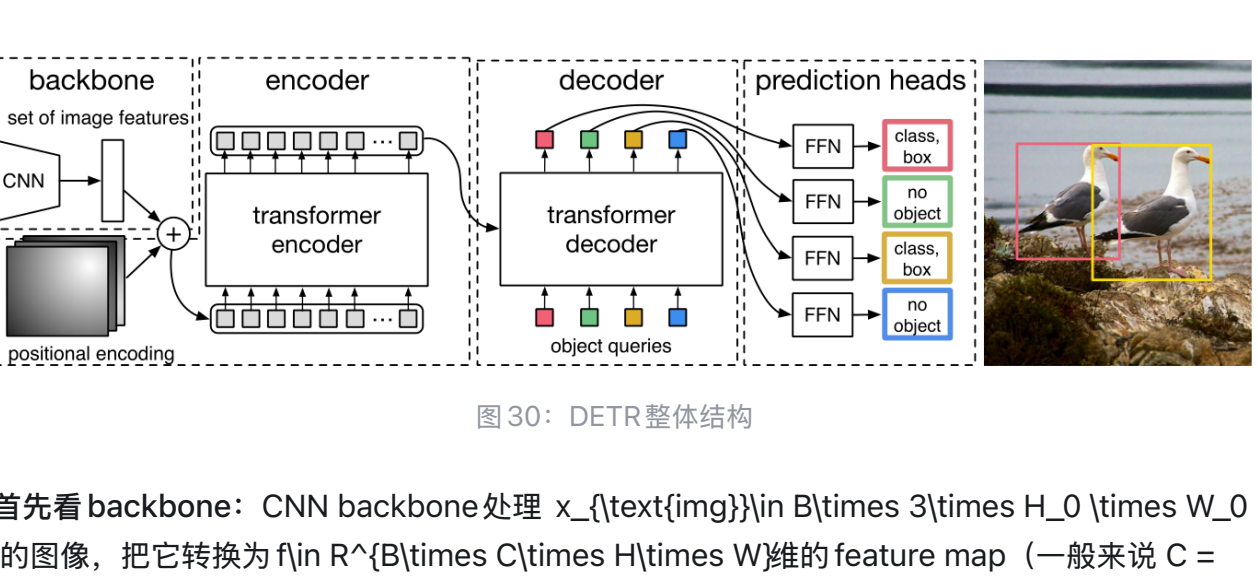

图 29：DETR结合CNN和Transformer的结构，并行实现预测

网络的主要组成是 CNN 和 Transformer，Transformer 借助第 1 节讲到的 self-attention 机制，可以显式地对一个序列中的所有 elements 两两之间的 interactions 进行建模，使得这类 transformer 的结构非常适合带约束的 set prediction 的问题。DETR 的特点是：一次预测，端到端训练，set loss function 和二分匹配。

文章的主要有两个关键的部分。

第一个是用 transformer 的 encoder-decoder 架构一次性生成 N 个 box prediction。其中 N 是一个事先设定的、比远远大于 image 中 object 个数的一个整数。

第二个是设计了 bipartite matching loss，基于预测的 boxex 和 ground truth boxes 的二分图⁺匹配计算 loss 的大小，从而使得预测的 box 的位置和类别更接近于 ground truth。

DETR 整体结构可以分为四个部分：backbone，encoder，decoder 和 FFN，如下图 30 所示，以下分别解释这四个部分：

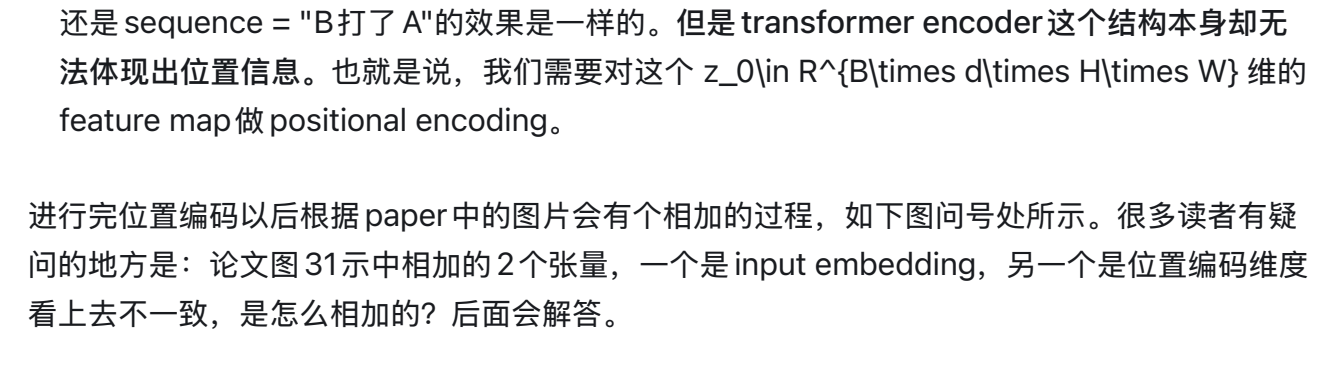

图 30：DETR整体结构

1 首先看 backbone：CNN backbone 处理 x_{\text{img}}\in B\times 3\times H_0 \times W_0 维的图像，把它转换为 f\in R^{B\times C\times H\times W}维的 feature map（一般来说 C = 2048 或 256, H = \frac{H_0}{32}, W = \frac{W_0}{32}），backbone 只做这一件事。

2 再看 encoder：encoder 的输入是 f\in R^{B\times C\times H\times W}维的 feature map，接下来依次进行以下过程：

- **通道数压缩：**先用 1\times 1 convolution 处理，将 channels 数量从 C 压缩到 d，即得到 z_0\in R^{B\times d\times H\times W}维的新 feature map。
- **转化为序列化⁺数据：**将空间的维度（高和宽）压缩为一个维度，即把上一步得到的 z_0\in R^{B\times d\times H\times W}(d=256)维的 feature map 通过 reshape 成(HW,B,256)维的 feature map。
- **位置编码：**在得到了 z_0\in R^{B\times d\times H\times W}维的 feature map 之后，正式输入 encoder 之前，需要进行**Positional Encoding**。这一步在第 2 节讲解 transformer 的时候已经提到过，因为**在 self-attention 中需要有表示位置的信息**，否则你的 sequence = "A打了B" 还是 sequence = "B打了A"的效果是一样的。**但是 transformer encoder 这个结构本身却无法体现出位置信息。**也就是说，我们需要对这个 z_0\in R^{B\times d\times H\times W} 维的 feature map 做 positional encoding。

进行完位置编码以后根据 paper 中的图片会有个相加的过程，如下图问号处所示。很多读者有疑问的地方是：论文图 31 示中相加的 2 个张量，一个是 input embedding，另一个是位置编码维度看上去不一致，是怎么相加的？后面会解答。

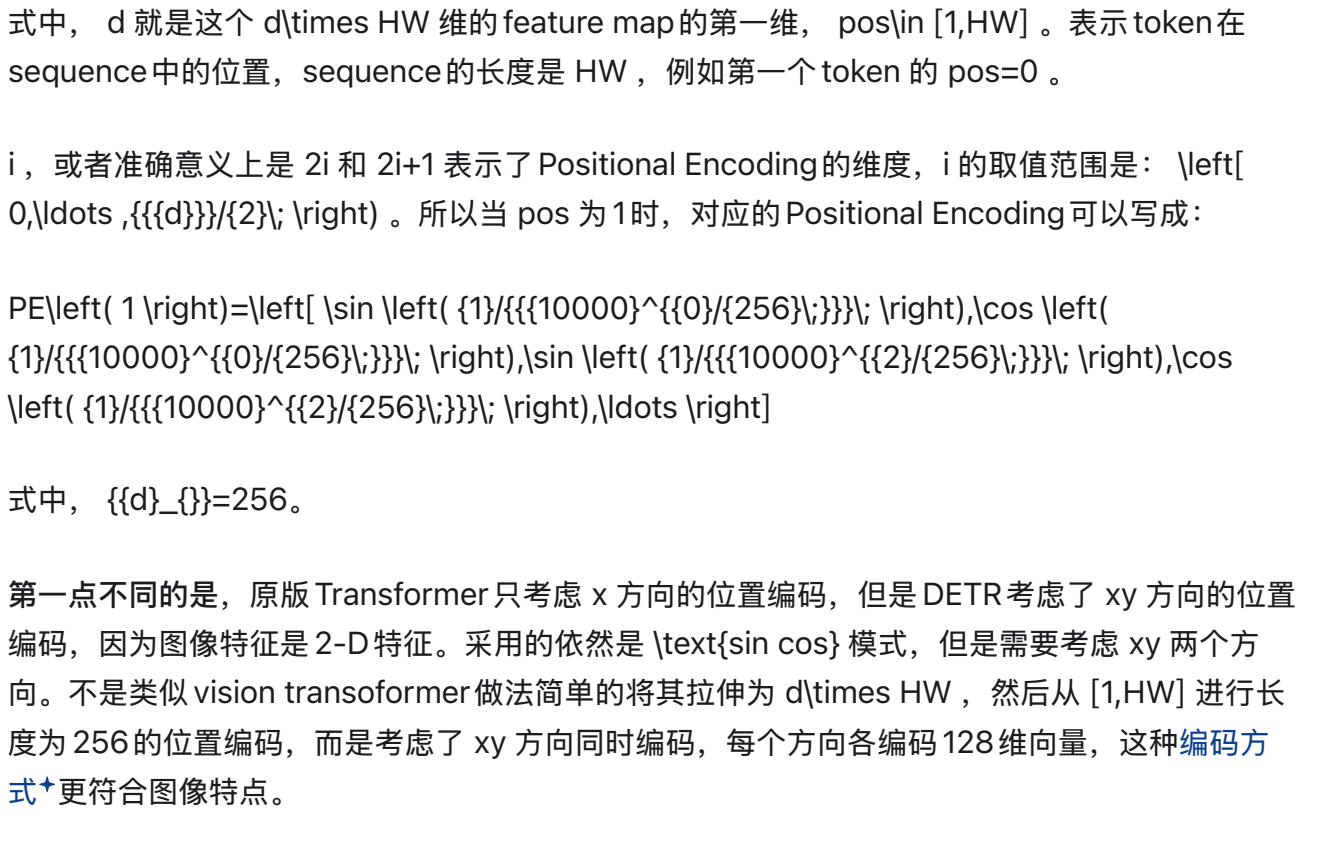

图 31：怎么相加的?

原版 Transformer 和 Vision Transformer (第 4 节讲述)的 Positional Encoding 的表达式为：

\begin{align}PE_{(pos, 2i)} = sin(pos/10000^{2i/d}) \\ PE_{(pos, 2i+1)} = cos(pos/10000^{2i/d}) \end{align}\tag{10}

式中， d 就是这个 d\times HW 维的 feature map 的第一维， pos\in [1,HW] 。表示 token 在 sequence 中的位置，sequence 的长度是 HW，例如第一个 token 的 pos=0 。

i，或者准确意义上是 2i 和 2i+1 表示了 Positional Encoding 的维度，i 的取值范围是： \left[0,\ldots ,{{{d}}}/{2}\; \right) 。所以当 pos 为 1 时，对应的 Positional Encoding 可以写成：

PE\left(1 \right)=\left[\sin \left({1}/{{{10000}^{{0}/{256}\;}}}\; \right),\cos \left({1}/{{{10000}^{{0}/{256}\;}}}\; \right),\sin \left({1}/{{{10000}^{{2}/{256}\;}}}\; \right),\cos \left({1}/{{{10000}^{{2}/{256}\;}}}\; \right),\ldots \right]

式中， {{d}_{}}=256。

第一点不同的是，原版 Transformer 只考虑 x 方向的位置编码，但是 DETR 考虑了 xy 方向的位置编码，因为图像特征是 2-D 特征。采用的依然是 \text{sin cos} 模式，但是需要考虑 xy 两个方向。不是类似 vision transoformer 做法简单的将其拉伸为 d\times HW， 然后从 [1,HW] 进行长度为 256 的位置编码，而是考虑了 xy 方向同时编码，每个方向各编码 128 维向量，这种编码方式⁺更符合图像特点。

Positional Encoding 的输出张量是： (B,d,H,W),d=256 ，其中 d 代表位置编码的长度， H,W 代表张量的位置。意思是说，这个特征图上的任意一个点 (H_1,W_1) 有个位置编码，这个编码的长度是 256，其中，前 128 维代表 H_1 的位置编码，后 128 维代表 W_1 的位置编码。

\begin{align}a)\quad PE_{(pos_x, 2i)} = sin(pos_x/10000^{2i/128}) \\ b)\quad PE_{(pos_x, 2i+1)} = cos(pos_x/10000^{2i/128}) \\c)\quad PE_{(pos_y, 2i)} = sin(pos_y/10000^{2i/128}) \\ d)\quad PE_{(pos_y, 2i+1)} = cos(pos_y/10000^{2i/128}) \end{align}\tag{11}

假设你想计算任意一个位置 (pos_x,pos_y),pos_x\in [1,HW],pos_y\in [1,HW] 的 Positional Encoding，把 pos_x 代入(11)式的 a 式和 b 式可以计算得到**128 维的向量**，它代表 pos_x 的位置编码，再把 pos_y 代入(11)式的 c 式和 d 式可以计算得到**128 维的向量**，它代表 pos_y 的位置编码，把这 2 个 128 维的向量拼接起来，就得到了一个**256 维的向量**，它代表 (pos_x,pos_y) 的位置编码。

计算所有位置的编码，就得到了 (256,H,W) 的张量，代表这个 batch 的位置编码。编码矩阵的维度是 (B,256,H,W)，也把它序列化成维度为 (HW,B,256) 维的张量。

准备与 (HW,B,256) 维的 feature map 相加以后输入 Encoder。

值得注意的是，网上许多解读文章没有搞清楚 "转化为序列化数据"这一步和 "位置编码"的顺序关系，以及变量的 shape 到底是怎样变化的，这里我用一个图 32 表达，终结这个问题。

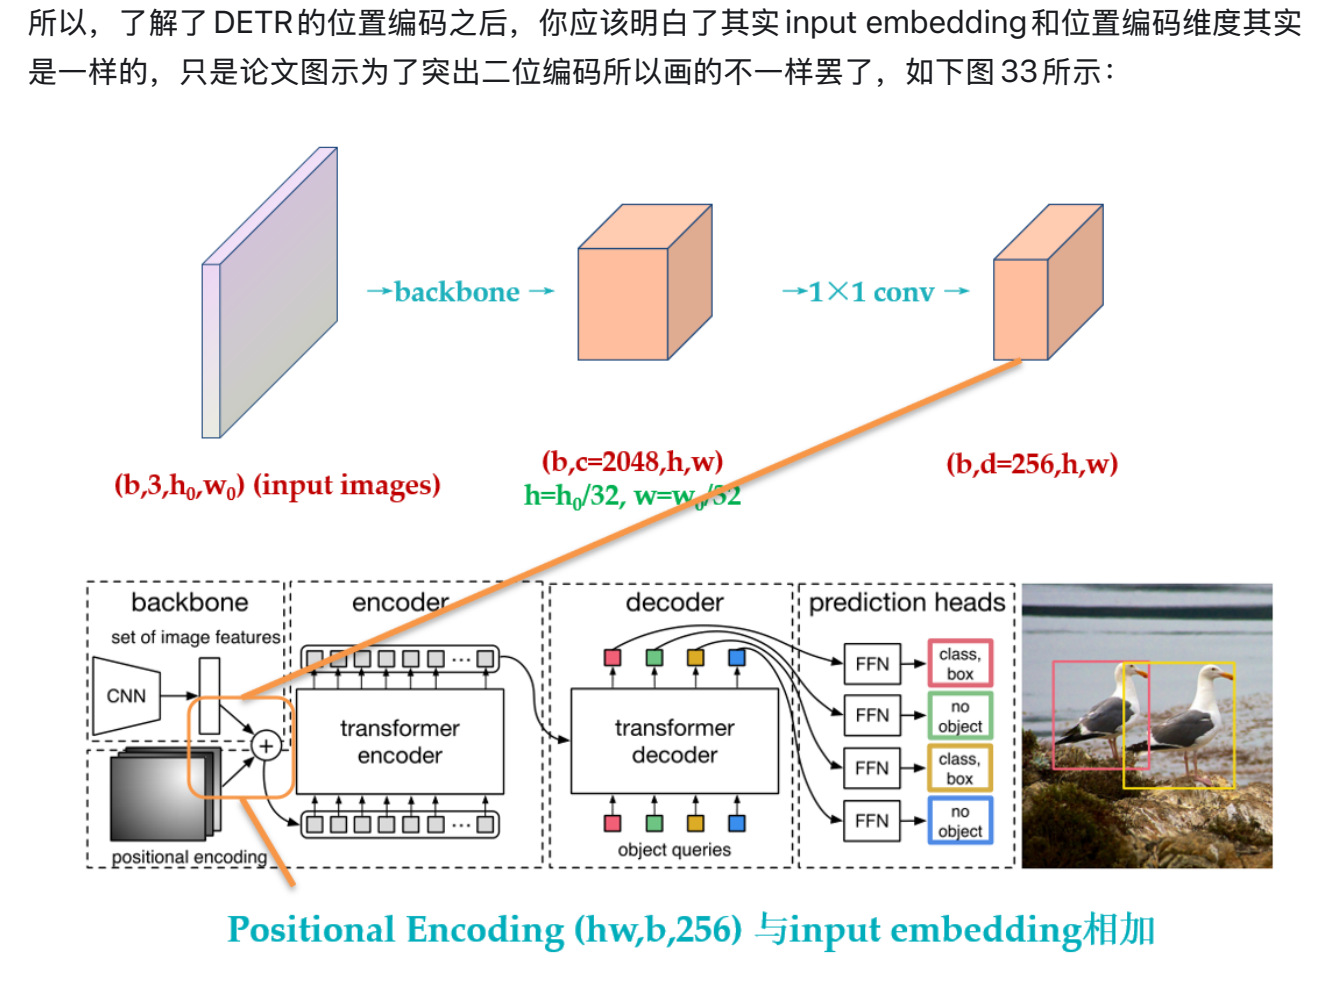
Backbone
Transformer Preprocess
→backbone →
→1×1 conv →
→reshape →
(b,3,h₀,w₀) (input images)
(b,c=2048,h,w)
h=h₀/32, w=w₀/32
(b,d=256,h,w)
(hw,b,256)
Positional Encoding →
(b,d=256,h,w)
→reshape →
(hw,b,256)
where (b,128,h,w) stands for positional encoding of x axis; (b,128,h,w) stands for positional encoding of y axis.
(hw,b,256)
Encoder：不可学习的二维位置编码
Decoder：可学习的位置编码
Serves as the input to Transformer Encoder.

图 32：变量的 shape 的变化，变量一律使用方块表达。

所以，了解了 DETR 的位置编码之后，你应该明白了其实 input embedding 和位置编码维度其实是一样的，只是论文图示为了突出二位编码所以画的不一样罢了，如下图 33 所示：

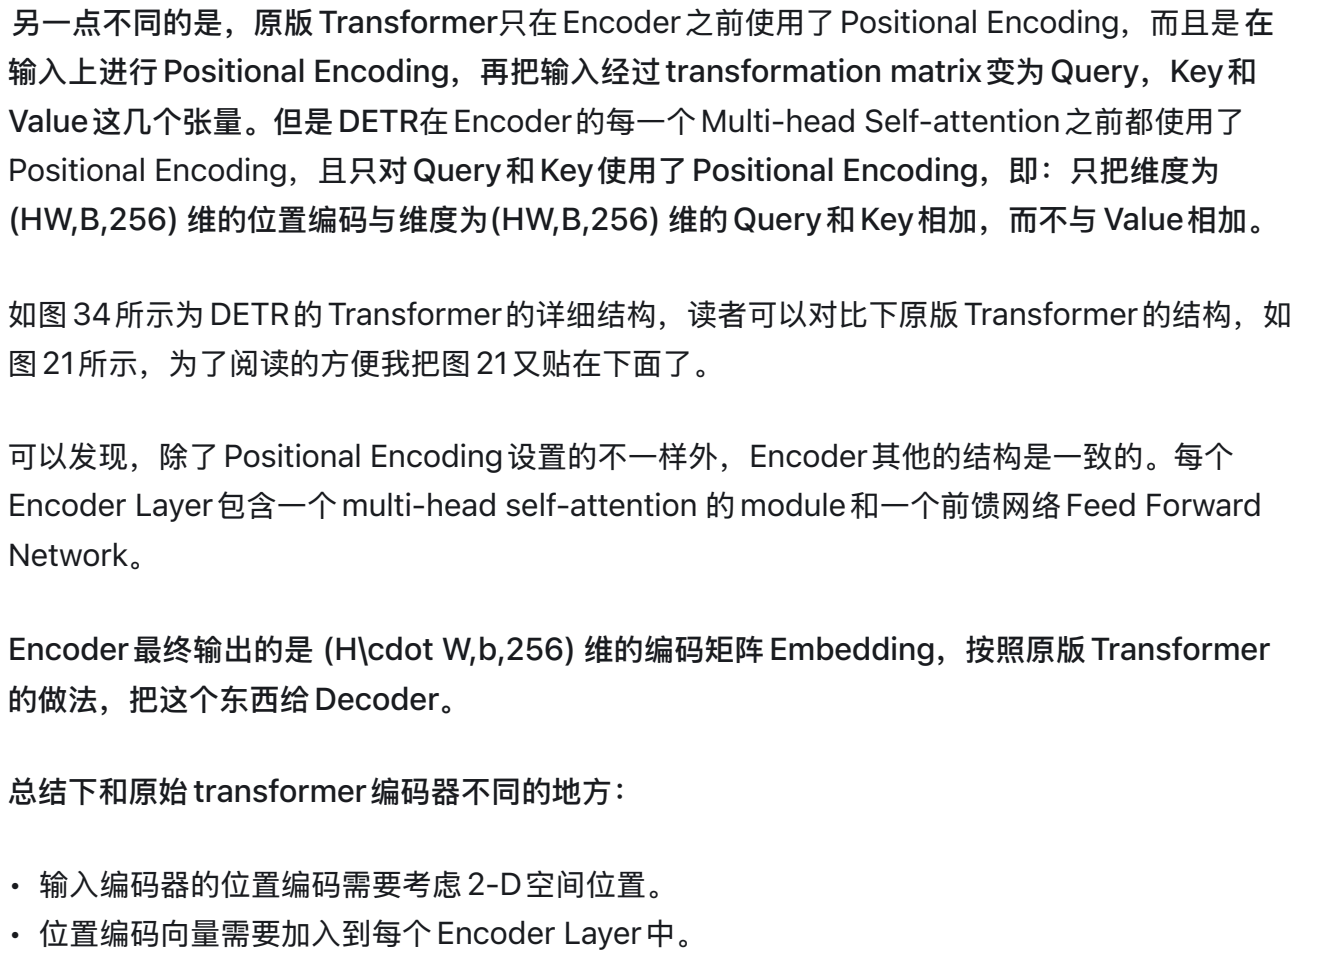

图 33：input embedding与positional embedding的shape是一致的

另一点不同的是，原版 Transformer只在 Encoder 之前使用了 Positional Encoding，而且是**在输入上进行 Positional Encoding，再把输入经过 transformation matrix 变为 Query，Key 和 Value 这几个张量。**但是 DETR 在 Encoder 的每一个 Multi-head Self-attention 之前都使用了 Positional Encoding，且只对 Query 和 Key 使用了 Positional Encoding，即：只把维度为 (HW,B,256) 维的位置编码与维度为 (HW,B,256) 维的 Query 和 Key 相加，而不与 Value 相加。

如图 34 所示为 DETR 的 Transformer 的详细结构，读者可以对比下原版 Transformer 的结构，如图 21 所示，为了阅读的方便我把图 21 又贴在下面了。

可以发现，除了 Positional Encoding 设置的不一样外，Encoder 其他的结构是一致的。每个 Encoder Layer 包含一个 multi-head self-attention 的 module 和一个前馈网络 Feed Forward Network。

Encoder 最终输出的是 (H\cdot W,b,256) 维的编码矩阵 Embedding，按照原版 Transformer 的做法，把这个东西给 Decoder。

总结下和原始 transformer 编码器不同的地方：

- 输入编码器的位置编码需要考虑 2-D 空间位置。
- 位置编码向量需要加入到每个 Encoder Layer 中。
- 在编码器内部位置编码 Positional Encoding 仅仅作用于 Query 和 Key，即只与 Query 和 Key 相加，Value 不做任何处理。

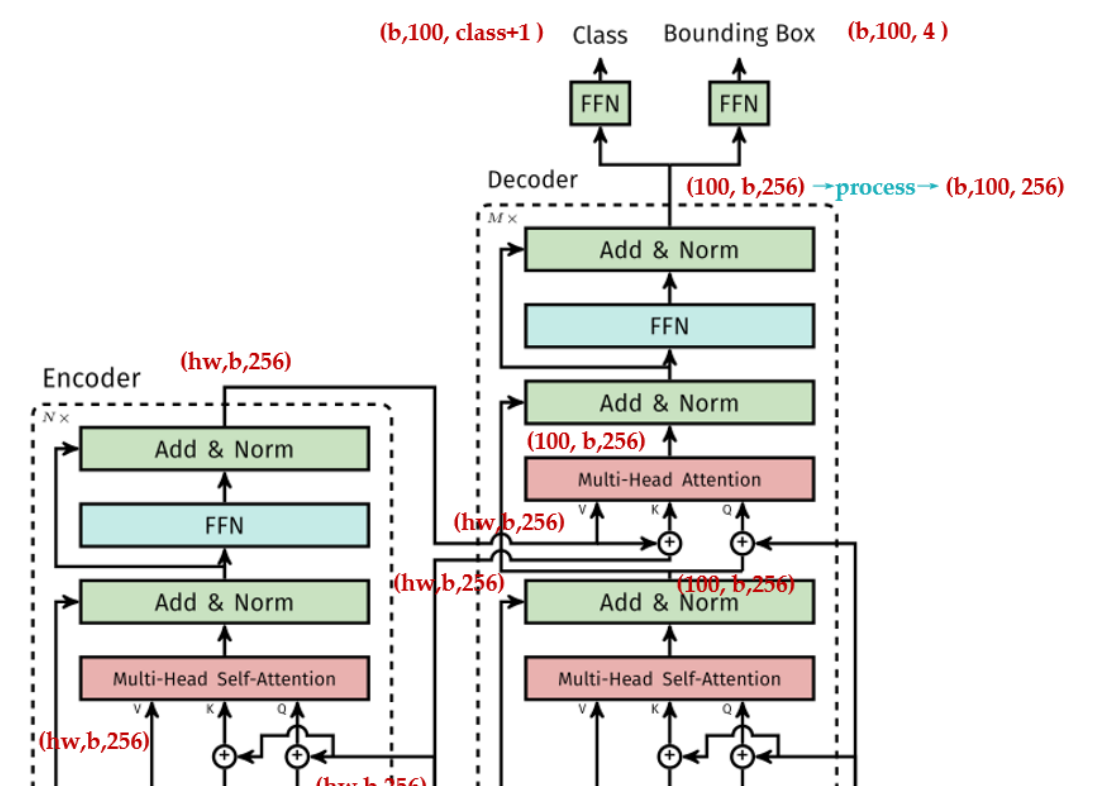

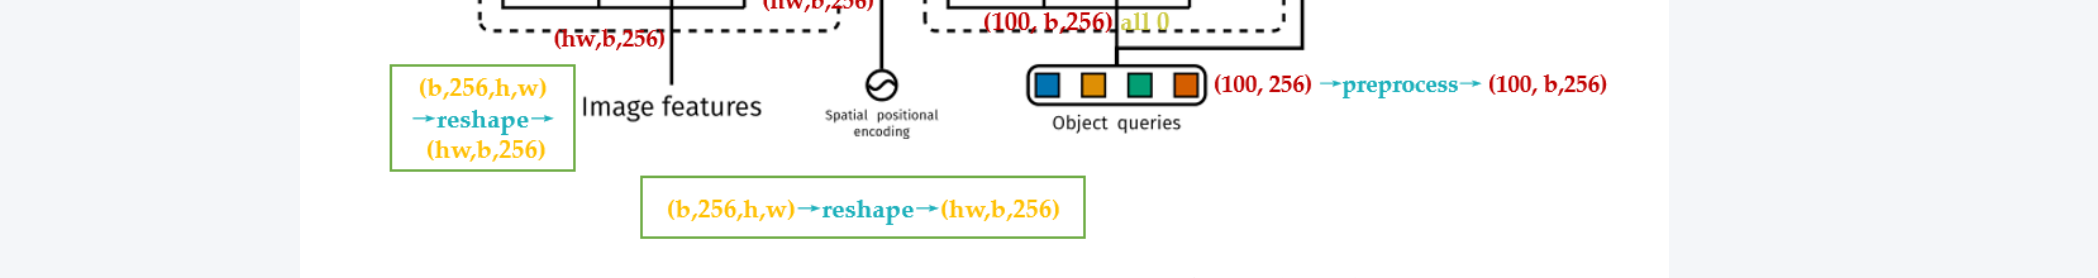
(b,256,h,w)—reshape→(hw,b,256)
Image features
Object queries
(100, 256) →preprocess→ (100, b,256)
(b,256,h,w)—reshape→(hw,b,256)

图34：Transformer详细结构，为了方便理解，我把每个变量的维度标在了图上。

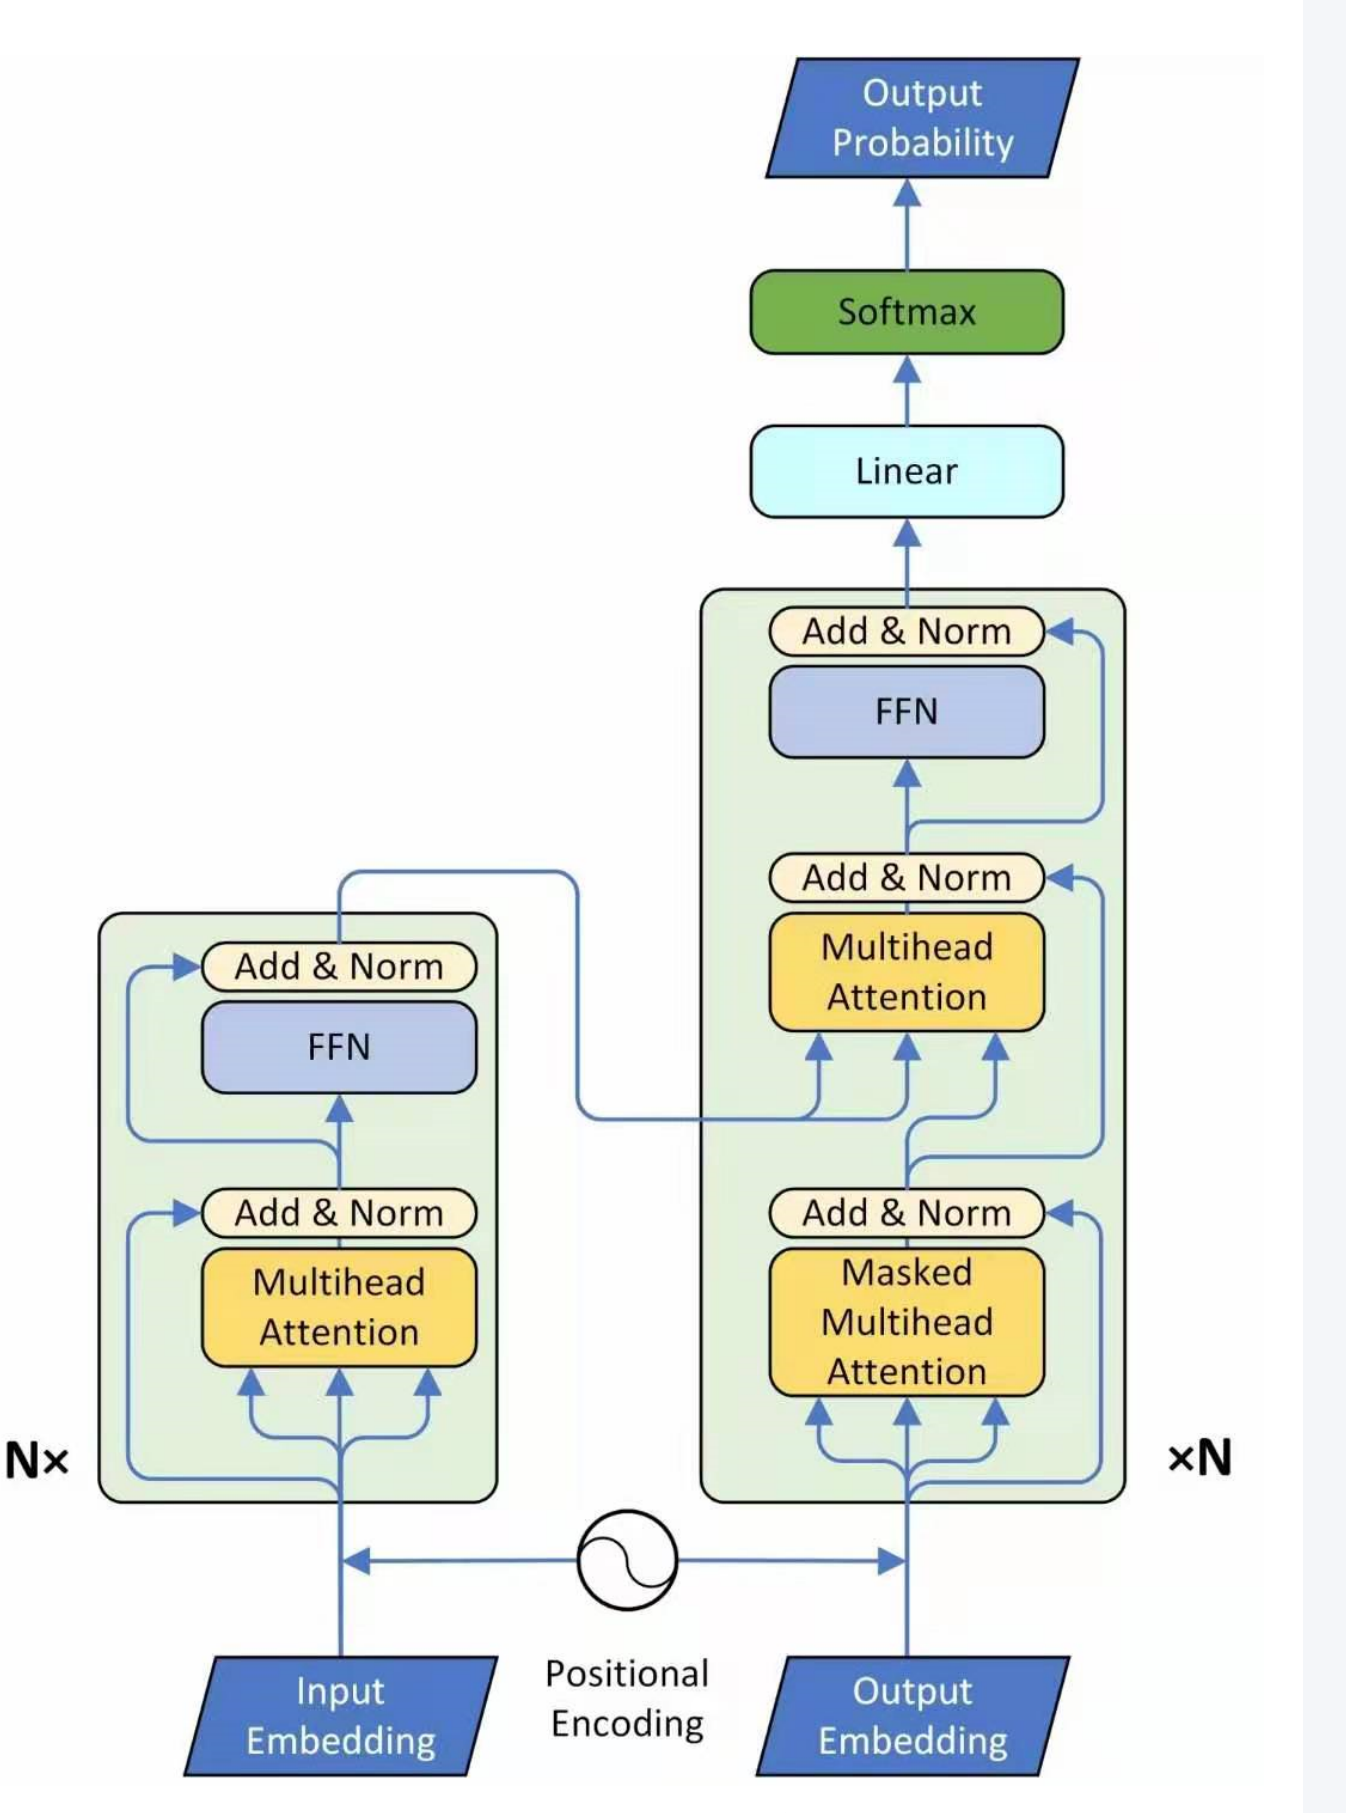

图21：Transformer整体结构

3 再看 decoder：

DETR的Decoder和原版Transformer的decoder是不太一样的，如下图34和21所示。

先回忆下原版Transformer，看下图21的decoder的最后一个框：output probability，代表我们一次只产生一个单词的softmax，根据这个softmax得到这个单词的预测结果。这个过程我们表达为：**predicts the output sequence one element at a time**。

不同的是，DETR的Transformer Decoder是一次性处理全部的object queries，即一次性输出全部的predictions；而不像原始的Transformer是auto-regressive的，从左到右一个词一个词地输出。这个过程我们表达为：**decodes the N objects in parallel at each decoder layer**。

DETR的Decoder主要有两个输入：

1. Transformer Encoder输出的Embedding与 position encoding 之和。
2. Object queries。

其中，Embedding就是上文提到的 (H\cdot W,b,256) 的编码矩阵。这里着重讲一下Object queries。

Object queries是一个维度为 (100,b,256) 维的张量，数值类型是nn.Embedding，说明这个张量是可以学习的，即：我们的Object queries是可学习的。Object queries矩阵内部通过学习建模了100个物体之间的全局关系，例如房间里面的桌子旁边(A类)一般是放椅子(B类)，而不会是放一头大象(C类)，那么在推理时候就可以利用该全局注意力更好的进行解码预测输出。

Decoder的输入一开始也初始化成维度为 (100,b,256) 维的全部元素都为0的张量，和Object queries加在一起之后充当**第1个multi-head self-attention的Query和Key。第一个multi-head self-attention的Value为Decoder的输入**，也就是全0的张量。

到了每个Decoder的第2个multi-head self-attention，它的Key和Value来自Encoder的输出张量，维度为 (hw,b,256)，其中Key值还进行位置编码。Query值一部分来自第1个Add and Norm的输出，维度为 (100,b,256) 的张量，另一部分来自Object queries，充当可学习的位置编码。所以，第2个multi-head self-attention的Key和Value的维度为 (hw,b,256)，而Query的维度为(100,b,256)。

每个Decoder的输出维度为 (1,b,100,256)，送入后面的前馈网络，具体的变量维度的变化见图30。

到这里你会发现：Object queries充当的其实是位置编码的作用，只不过它是可以学习的位置编码，所以，我们对Encoder和Decoder的每个self-attention的Query和Key的位置编码做个归纳，如图35所示，Value没有位置编码：

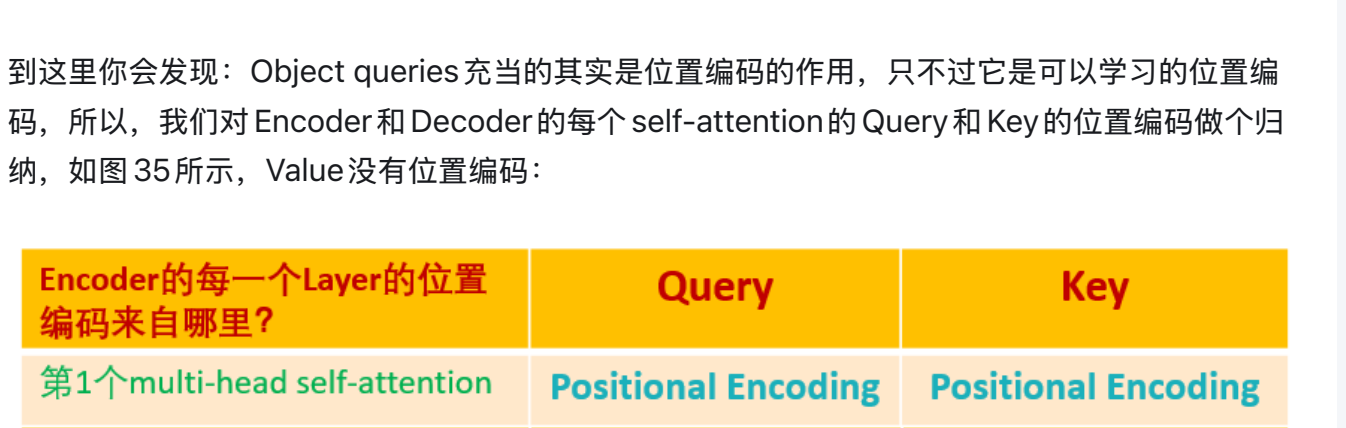

Encoder的每一个Layer的位置编码来自哪里?	Query	Key
第1个multi-head self-attention	Positional Encoding	Positional Encoding
Decoder的每一个Layer的位置编码来自哪里?	**Query**	**Key**
第1个multi-head self-attention	Object Queries	Object Queries
第2个multi-head self-attention	Object Queries	Positional Encoding

图35：Transformer的位置编码来自哪里?

\color{indianred}{\text{损失函数部分解读:}}

得到了Decoder的输出以后，如前文所述，应该是输出维度为 (b,100,256)的张量。接下来要送入2个前馈网络FFN得到class和Bounding Box。它们会得到 N=100 个预测目标，包含类别和Bounding Box，当然这个100肯定是大于图中的目标总数的。如果不够100，则采用背景填充，计算loss时候回归分支分支仅仅计算有物体位置，背景集合忽略。所以，DETR输出张量的维度为输出的张量的维度是 (b,100,\color{crimson}{\text{class}+1}) 和 (b,100,\color{purple}{4})。对应COCO数据集来说， \color{crimson}{\text{class}+1=92}， \color{purple}{4} 指的是每个预测目标归一化的 (c_x,c_y,w,h) 。归一化就是除以图片宽高进行归一化。

到这里我们了解了DETR的网络架构，我们发现，它输出的张量的维度是 **分类分支**：(b,100,\color{crimson}{\text{class}+1}) 和**回归分支**： (b,100,\color{purple}{4})，其中，前者是指100个预测框的类型，后者是指100个预测框的Bounding Box，但是读者可能会有疑问：预测框和真值是怎么一一对应的？换句话说：你怎么知道第47个预测框对应图片里的狗，第88个预测框对应图片里的车？等等。

我们下面就来聊聊这个问题。

相比Faster R-CNN等做法，DETR最大特点是将目标检测问题转化为无序集合预测问题(set prediction)。论文中特意指出Faster R-CNN这种设置一大堆anchor，然后基于anchor进行分类和回归其实属于代理做法即不是最直接做法，**目标检测任务就是输出无序集合**，而Faster R-CNN等算法通过各种操作，并结合复杂后处理最终才得到无序集合属于绕路了，而DETR就比较纯粹了。现在核心问题来了：输出的 (b,100) 个检测结果是无序的，如何和 GT \; \text{Bounding Box} 计算loss？这就需要用到经典的双边匹配算法了，也就是常说的匈牙利算法，该算法广泛应用于最优分配问题。

一幅图片，我们把第 i 个物体的真值表达为 y_i=(c_i,b_i)，其中， c_i 表示它的 \color{crimson}{\text{class}}， b_i 表示它的 \color{purple}{\text{Bounding Box}}。我们定义 \hat y = \{\hat y_i\}_{i=1}^{N} 为网络输出的 N 个预测值。

假设我们已经了解了什么是匈牙利算法(先假装了解了)，对于第 i 个 GT， \sigma(i) 为匈牙利算法得到的与 GT_i 对应的prediction的索引。我举个栗子，比如 i=3,\sigma(i)=18，意思就是：与第3个真值对应的预测值是第18个。

那我能根据 \color{green}{\text{匈牙利算法}}，找到 \color{green}{\text{与每个真值对应的预测值是哪个}}，**那究竟是如何找到呢?**

\begin{equation} \label{eq:matching} \hat{\sigma} = \arg\min_{\sigma\in\Sigma_N} \sum_{i}^{N} L_{match}(y_i, \hat y_{\sigma(i)}), \end{equation} \tag{12}

我们看看这个表达式是甚么意思，对于某一个真值 y_i，假设我们已经找到这个真值对应的预测值 \hat y_{\sigma(i)}，这里的 \Sigma_N 是所有可能的排列，代表**从真值索引到预测值索引的所有的映射**，然后用 L_{match} 最小化 y_i 和 \hat y_{\sigma(i)} 的距离。这个 L_{match} 具体是：

-\mathbb{1}_{\left\{ c_i\neq\varnothing \right\}}\hat p_{\sigma(i)}(c_i) + \mathbb{1}_{\left\{ c_i\neq\varnothing \right\}} L_{box}({b_{i}, \hat b_{\sigma(i)}}) \tag{13}

意思是：假设当前从真值索引到预测值索引的所有的映射为 \sigma，对于图片中的每个真值 i，先找到对应的预测值 \sigma(i)，再看看分类网络的结果 \hat p_{\sigma(i)}(c_i)，取反作为 L_{match} 的第1部分。再计算回归网络的结果 \hat b_{\sigma(i)} 与真值的 \color{purple}{\text{Bounding Box}} 的差异，即 L_{box}({b_{i}, \hat b_{\sigma(i)}})，作为 L_{match} 的第2部分。

所以，可以使得 L_{match} 最小的排列 \hat\sigma 就是我们要找的排列，**即：对于图片中的每个真值 i 来讲， \hat\sigma(i) 就是这个真值所对应的预测值的索引。**

请读者细品这个 寻找匹配的过程，这就是匈牙利算法的过程。是不是与Anchor或Proposal有异曲同工的地方，只是此时我们找的是一对一匹配。

接下来就是使用上一步得到的排列 \hat\sigma，计算匈牙利损失：

L_{\text{Hungarian}}({y, \hat y}) = \sum_{i=1}^N \left[-\log \hat p_{\hat{\sigma}(i)}(c_{i}) + \mathbb{1}_{\left\{ c_i\neq\varnothing \right\}} \ L_{box}{(b_{i}, \hat b_{\hat{\sigma}(i)})}\right] \tag{14}

式中的 L_{box} 具体为：

L_{box}{(b_{i}, \hat b_{\hat{\sigma}(i)})} = \lambda_{\rm iou}L_{iou}({b_{i}, \hat b_{\sigma(i)}})+ \lambda_{\rm L1}||b_{i}- \hat b_{\sigma(i)}||_1 ,\; where \;\lambda_{\rm iou}, \lambda_{\rm L1}\in R \tag{15}

最常用的 L_1 \;loss 对于大小 \color{purple}{\text{Bounding Box}} 会有不同的标度，即使它们的相对误差是相似的。为了缓解这个问题，作者使用了 L_1 \;loss 和广义IoU损耗 L_{iou} 的线性组合，它是比例不变的。

Hungarian意思就是匈牙利，也就是前面的 L_{match}，上述意思是需要计算 M 个 \text{GT}\;\color{purple}{\text{Bounding Box}} 和 N 个输预测出集合两两之间的广义距离，**距离越近表示越可能是最优匹配关系**，也就是两者最密切。广义距离的计算考虑了分类分支和回归分支。

最后，再概括一下DETR的End-to-End的原理，前面那么多段话就是为了讲明白这个事情，如果你对前面的论述还存在疑问的话，把下面一直到Experiments之前的这段话看懂就能解决你的困惑。

DETR是怎么训练的?

训练集里面的任何一张图片，假设第1张图片，我们通过模型产生100个预测框 \text{Predict}\;\color{purple}{\text{Bounding Box}}，假设这张图片有只3个 \text{GT}\;\color{purple}{\text{Bounding Box}}，它们分别是 \color{orange}{\text{Car}},\color{green}{\text{Dog}},\color{darkturquoise}{\text{Horse}}。

(\text{label}_{\color{orange}{\text{Car}}}=3,\text{label}_{\color{green}{\text{Dog}}}=24,\text{label}_{\color{orange}{\color{darkturquoise}{\text{Horse}}}}=75)\\

问题是：我怎么知道这100个预测框哪个是对应 \color{orange}{\text{Car}}，哪个是对应 \color{green}{\text{Dog}}，哪个是对应 \color{darkturquoise}{\text{Horse}}？

我们建立一个 (100,3) 的矩阵，矩阵里面的元素就是 (13) 式的计算结果，举个例子：比如左上角的 (1,1) 号元素的含义是：第1个预测框对应 \color{orange}{\text{Car}}(\text{label}=3) 的情况下的 L_{match} 值。我们用**scipy.optimize** 这个库中的 **linear_sum_assignment** 函数找到最优的匹配，这个过程我们称之为：**"匈牙利算法 (Hungarian Algorithm)"**。

假设 **linear_sum_assignment**做完以后的结果是：第 23 个预测框对应 \color{orange}{\text{Car}}，第 44 个预测框对应 \color{green}{\text{Dog}}，第 95 个预测框对应 \color{darkturquoise}{\text{Horse}}。

现在把第 23,44,95 个预测框挑出来，按照 (14) 式计算 Loss，得到这个图片的Loss。

把所有的图片按照这个模式去训练模型。

训练完以后怎么用?

训练完以后，你的模型学习到了一种能力，即：模型产生的100个预测框，它知道某个预测框该对应什么 \text{Object}，比如，模型学习到：第1个 \text{Predict}\;\color{purple}{\text{Bounding Box}} 对应 \color{orange}{\text{Car}}(\text{label}=3)，第2个 \text{Predict}\;\color{purple}{\text{Bounding Box}} 对应 \color{chocolate}{\text{Bus}}(\text{label}=16)，第3个 \text{Predict}\;\color{purple}{\text{Bounding Box}} 对应 \color{lightskyblue}{\text{Sky}}(\text{label}=21)，第4个 \text{Predict}\;\color{purple}{\text{Bounding Box}} 对应 \color{green}{\text{Dog}}(\text{label}=24)，第5个 \text{Predict}\;\color{purple}{\text{Bounding Box}} 对应 \color{darkturquoise}{\text{Horse}}(\text{label}=75)，第6-100个 \text{Predict}\;\color{purple}{\text{Bounding Box}} 对应 \color{dimgray}{\varnothing }(\text{label}=92)，等等。

以上只是我举的一个例子，意思是说：模型知道了自己的100个预测框每个该做什么事情，即：每个框该预测什么样的 \text{Object}。

为什么训练完以后，模型学习到了一种能力，即：模型产生的100个预测框，它知道某个预测框该对应什么 \text{Object}？

还记得前面说的Object queries吗？它是一个维度为 (100,b,256) 维的张量，初始时元素全为 0。实现方式是**nn.Embedding(num_queries, hidden_dim)**，这里 num_queries=100, hidden_dim=256，它是可训练的。这里的 b 指的是 batch size，我们考虑单张图片，所以假设Object queries是一个维度为 (100,256) 维的张量。我们训练完模型以后，这个张量已经训练完了，**那么此时的Object queries究竟代表什么?**

我们把此时的Object queries**看成100个格子，每个格子是个256维的向量**。训练完以后，这100个格子里面**注入了不同 \text{Object} 的位置信息和类别信息**。**比如第1个格子里面的这个256维的向量代表着 \color{orange}{\text{Car}} 这种 \text{Object} 的位置信息，**这种信息是通过训练，考虑了所有图片的某个位置附近的 \color{orange}{\text{Car}} 编码特征，属于和位置有关的全局 \color{orange}{\text{Car}} 统计信息。

测试时，假设图片中有 \color{orange}{\text{Car}},\color{green}{\text{Dog}},\color{darkturquoise}{\text{Horse}} 三种物体，该图片会输入到编码器中进行特征编码，假设特征没有丢失，Decoder的**Key**和**Value**就是编码器输出的编码向量(如图30所示)，而Query就是Object queries，就是我们的100个格子。

Query可以视作代表不同 \text{Object} 的信息，而Key和Value可以视作代表图像的全局信息。

现在通过注意力模块将**Query**和**Key**计算，然后加权**Value**得到解码器输出。对于第1个格子的**Query**会和**Key**中的所有向量进行计算，目的是查找某个位置附近有没有 \color{orange}{\text{Car}}，如果有那么该特征就会加权输出，对于第3个格子的**Query**会和**Key**中的所有向量进行计算，目的是查找某个位置附近有没有 \color{lightskyblue}{\text{Sky}}，很遗憾，这个没有，所以输出的信息里面没有 \color{lightskyblue}{\text{Sky}}。

整个过程计算完成后就可以把编码向量中的 \color{orange}{\text{Car}},\color{green}{\text{Dog}},\color{darkturquoise}{\text{Horse}} 的编码嵌入信息提取出来，然后后面接 FFN 进行分类和回归就比较容易，因为特征已经对齐了。

发现了吗？Object queries在训练过程中对于 N 个格子会压缩入对应的和位置和类别相关的统计信息，在测试阶段就可以利用该**Query**去和某个图像的编码特征**Key**，**Value**计算，**若图片中刚好有Query想找的特征，比如 \color{orange}{\text{Car}}，则这个特征就能提取出来，最后通过2个 FFN 进行分类和回归**。所以前面才会说Object queries作用非常类似Faster R-CNN中的anchor，这个anchor是可学习的，由于维度比较高，故可以表征的东西丰富，当然维度越高，训练时长就会越长。

这就是DETR的End-to-End的原理，可以简单归结为上面的几段话，你读懂了上面的话，也就明白了DETR以及End-to-End的Detection模型原理。

Experiments：

1. 性能对比：

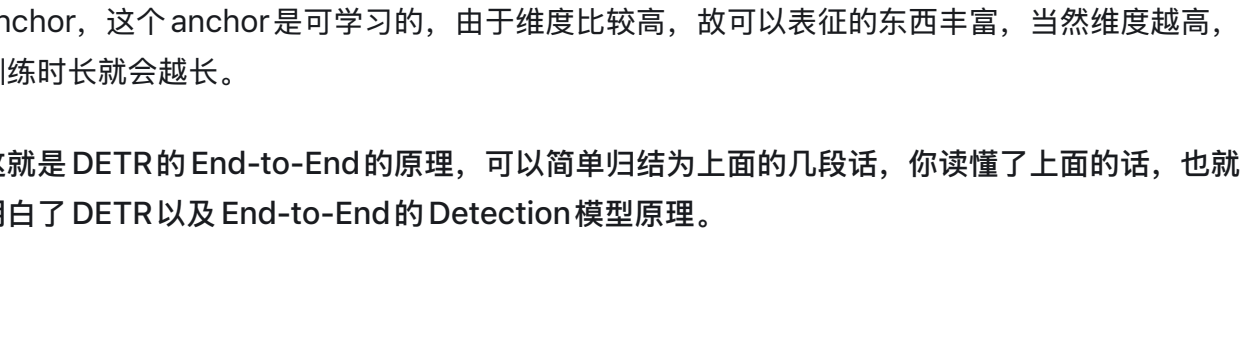

Model	GFLOPS/FPS	#params	AP	AP_{50}	AP_{75}	AP_S	AP_M	AP_L
Faster RCNN-DC5	320/16	166M	39.0	60.5	42.3	21.4	43.5	52.5
Faster RCNN-FPN	180/26	42M	40.2	61.0	43.8	24.2	43.5	52.0
Faster RCNN-R101-FPN	246/20	60M	42.0	62.5	45.9	25.2	45.6	54.6
Faster RCNN-DC5+	320/16	166M	41.1	61.4	44.3	22.9	45.9	55.0
Faster RCNN-FPN+	180/26	42M	42.0	62.1	45.5	26.6	45.4	53.4
Faster RCNN-R101-FPN+	246/20	60M	44.0	63.9	**47.8**	**27.2**	48.1	56.0
DETR	86/28	41M	42.0	62.4	44.2	20.5	45.8	61.1
DETR-DC5	187/12	41M	43.3	63.1	45.9	22.5	47.3	61.1
DETR-R101	152/20	60M	43.5	63.8	46.4	21.9	48.0	61.8
DETR-DC5-R101	253/10	60M	**44.9**	**64.7**	47.7	23.7	**49.5**	**62.3**

图36：DETR与Fast R-CNN的性能对比

2. 编码器层数对比实验：

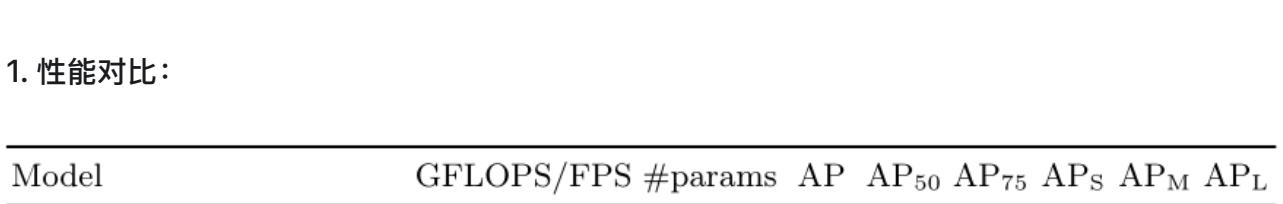

#layers	GFLOPS/FPS	#params	AP	AP_{50}	AP_S	AP_M	AP_L
0	76/28	33.4M	36.7	57.4	16.8	39.6	54.2
3	81/25	37.4M	40.1	60.6	18.5	43.8	58.6
6	86/23	41.3M	40.6	61.6	19.9	44.3	60.2
12	95/20	49.2M	41.6	62.1	19.8	44.9	61.9

图37：编码器数目与模型性能

可以发现，编码器层数越多越好，最后就选择6。

下图38为最后一个Encoder Layer的attention可视化，Encoder已经分离了instances，简化了Decoder的对象提取和定位。

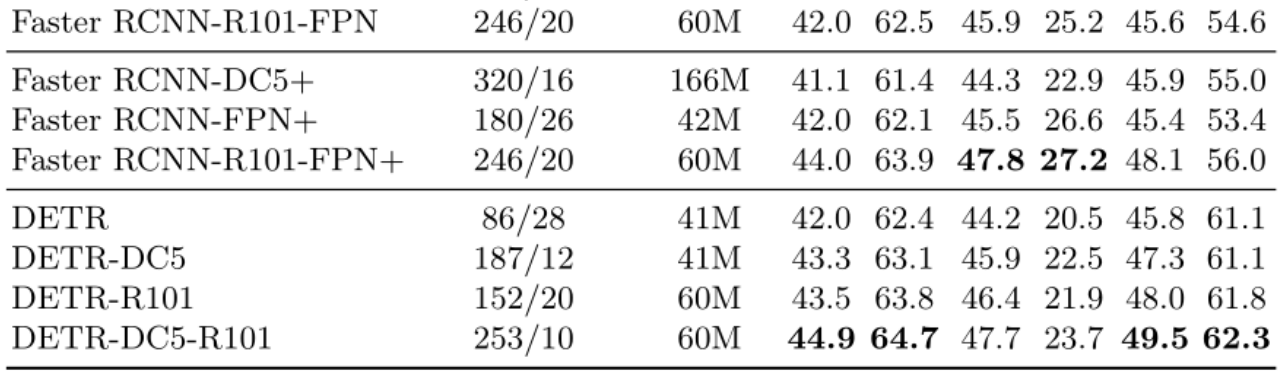

图38：最后一个Encoder Layer的attention可视化

3. 解码器层数对比实验：

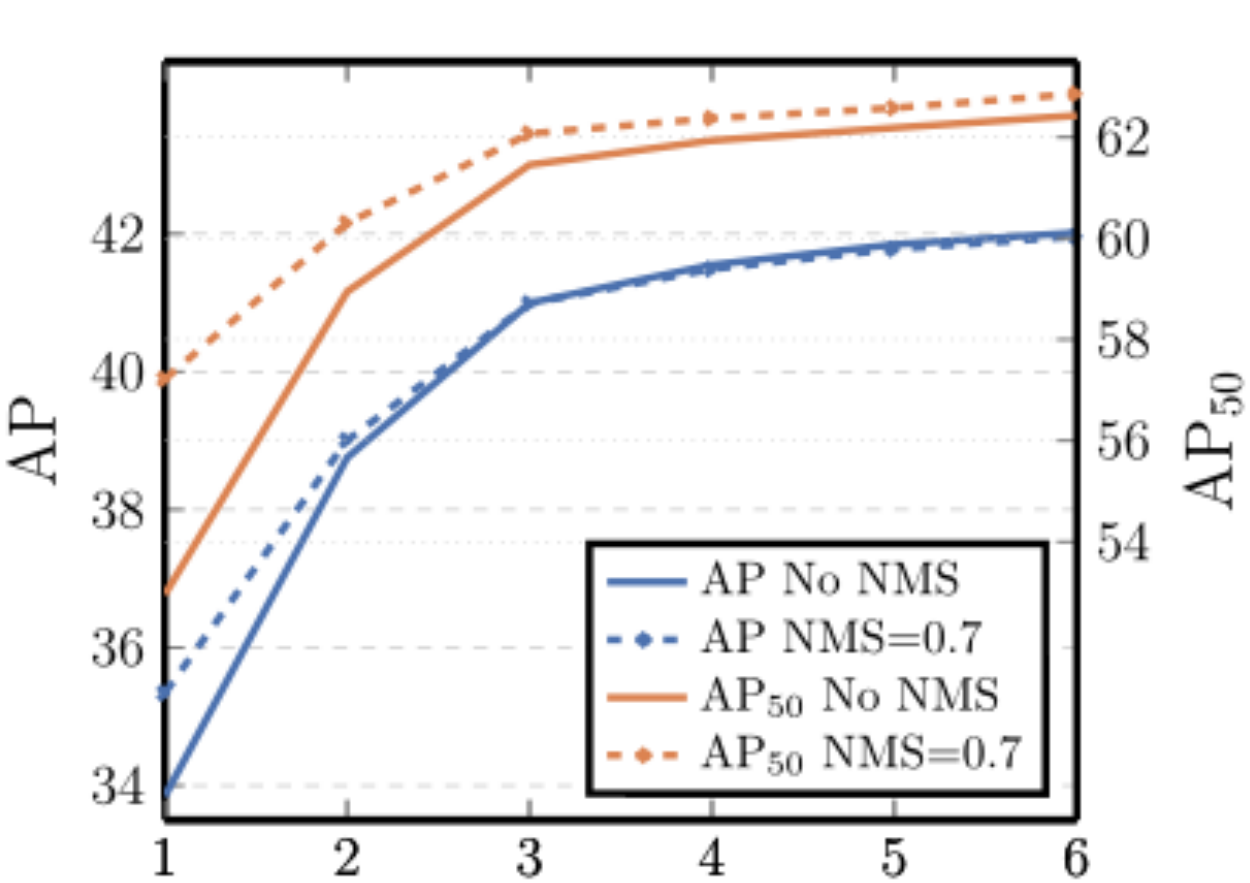

图39：每个Decoder Layer后的AP和AP 50性能。

可以发现，性能随着解码器层数的增加而提升，DETR本不需要NMS，但是作者也进行了，上图中的NMS操作是指DETR的每个解码层都可以输入无序集合，那么将所有解码器无序集合全部保留，然后进行NMS得到最终输出，可以发现性能稍微有提升，特别是AP50。这可以通过以下事实来解释：Transformer的单个Decoder Layer不能计算输出元素之间的任何互相关，因此它易于对同一对象进行多次预测。在第2个和随后的Decoder Layer中，self-attention允许模型抑制重复预测。所以NMS带来的改善随着Decoder Layer的增加而减少。在最后几层，作者观察到AP的一个小损失，因为NMS错误地删除了真实的positive prediction。

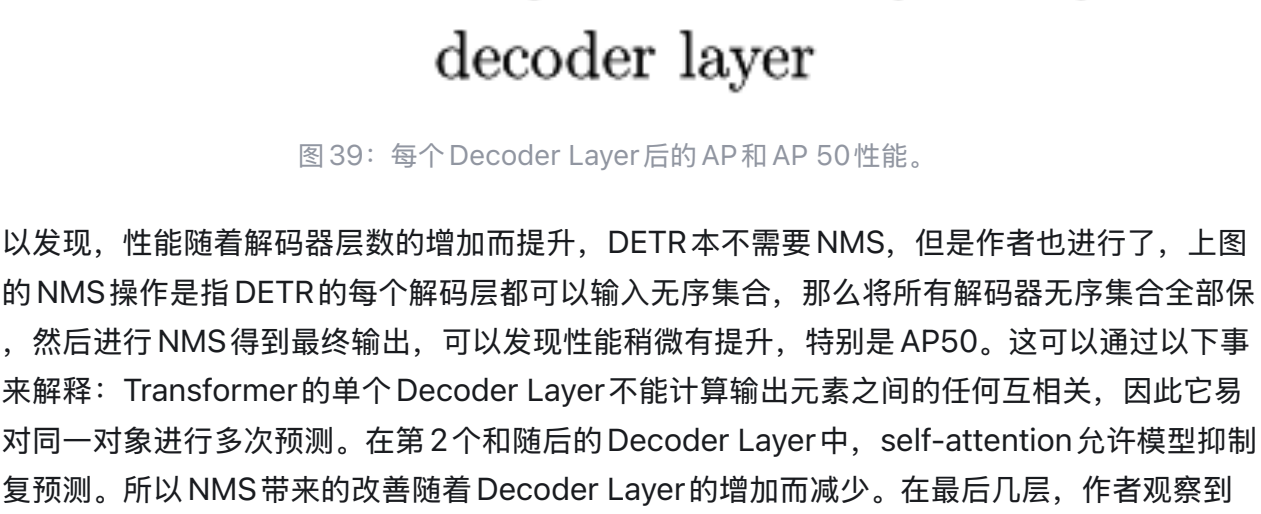

图40：Decoder Layer的attention可视化

类似于可视化编码器注意力，作者在图40中可视化解码器注意力，用不同的颜色给每个预测对象的注意力图着色。观察到，解码器的attention相当局部，这意味着它主要关注对象的四肢，如头部或腿部。我们假设，在编码器通过全局关注分离实例之后，**解码器只需要关注极端来提取类和对象边界。**

- 3.2 DETR代码解读：

分析都注释在了代码中。

> 二维位置编码：
> DETR的二维位置编码：
> 首先构造位置矩阵x_embed和y_embed，这里用到了python函数cumsum，作用是对一个矩阵的元素进行累加，那么累加以后最后一个元素就是所有累加元素的和，省去了求和的步骤，直接用这个和做归一化，对应x_embed[:, :, -1:]和y_embed[:, -1:, :]。
> 这里我想着重强调下代码中一些变量的shape，方便读者掌握作者编程的思路：
> 值得注意的是，tensor_list的类型是NestedTensor，内部自动附加了mask，用于表示动态shape，是pytorch中tensor新特性github.com/pytorch/nest...。全是false。
> x：(b,c,H,W)
> mask：(b,H,W)，全是False。
> not_mask：(b,H,W)，全是True。
> 首先出现的y_embed：(b,H,W)，具体是1,1,1,1,......,2,2,2,2,......3,3,3,3,......
> 首先出现的x_embed：(b,H,W)，具体是1,2,3,4,......,1,2,3,4,......1,2,3,4,......
> self.num_pos_feats = 128
> 首先出现的dim_t = [0,1,2,3,.....,127]
> pos_x：(b,H,W,128)
> pos_y：(b,H,W,128)
> flatten后面的数字指的是：flatten()方法应从哪个轴开始展开操作。
> torch.stack((pos_x[:, :, :, 0::2].sin(), pos_x[:, :, :, 1::2].cos()), dim=4).flatten(3)
> pos_y = torch.stack((pos_y[:, :, :, 0::2].sin(), pos_y[:, :, :, 1::2].cos()), dim=4)
> 这一步执行完以后变成(b,H,W,2,64)通过flatten()方法从第3个轴开始展平，变为：(b,H,W,128)
> torch.cat((pos_y, pos_x), dim=3)之后变为(b,H,W,256)，再最后permute为(b,256,H,W)。
> PositionEmbeddingSine类继承nn.Module类。

```
class PositionEmbeddingSine(nn.Module):

    def forward(self, tensor_list: NestedTensor):
#输入是b,c,h,w
#tensor_list的类型是NestedTensor，内部自动附加了mask，
#用于表示动态shape，是pytorch中tensor新特性https://github.com/pytorch/nestedt
        x = tensor_list.tensors
# 附加的mask，shape是b,h,w 全是false
        mask = tensor_list.mask
        assert mask is not None
        not_mask = ~mask
# 因为图像是2d的，所以位置编码也分为x,y方向
# 1 1 1 1 ..  2 2 2 2... 3 3 3...
        y_embed = not_mask.cumsum(1, dtype=torch.float32)
# 1 2 3 4 ... 1 2 3 4...
        x_embed = not_mask.cumsum(2, dtype=torch.float32)
        if self.normalize:
            eps = 1e-6
            y_embed = y_embed / (y_embed[:, -1:, :] + eps) * self.scale
            x_embed = x_embed / (x_embed[:, :, -1:] + eps) * self.scale

# num_pos_feats = 128
# 0~127 self.num_pos_feats=128,因为前面输入向量是256，编码是一半sin，一半cos
        dim_t = torch.arange(self.num_pos_feats, dtype=torch.float32, devi
        dim_t = self.temperature ** (2 * (dim_t // 2) / self.num_pos_feats

# 输出shape=b,h,w,128
        pos_x = x_embed[:, :, :, None] / dim_t
        pos_y = y_embed[:, :, :, None] / dim_t
        pos_x = torch.stack((pos_x[:, :, :, 0::2].sin(), pos_x[:, :, :, 1:
        pos_y = torch.stack((pos_y[:, :, :, 0::2].sin(), pos_y[:, :, :, 1:
        pos = torch.cat((pos_y, pos_x), dim=3).permute(0, 3, 1, 2)
# 每个特征图的xy位置都编码成256的向量，其中前128是y方向编码，而128是x方向编码
        return pos
# b,n=256,h,w
```

作者定义了一种数据结构：NestedTensor，里面打包存了两个变量：x 和mask。

> NestedTensor：
> 里面打包存了两个变量：x 和mask。
> to()函数：把变量移到GPU中。

> Backbone：

```
class BackboneBase(nn.Module):

    def __init__(self, backbone: nn.Module, train_backbone: bool, num_chan
        super().__init__()
        for name, parameter in backbone.named_parameters():
            if not train_backbone or 'layer2' not in name and 'layer3' not
                parameter.requires_grad_(False)
        if return_interm_layers:
            return_layers = {"layer1": "0", "layer2": "1", "layer3": "2", '
        else:
            return_layers = {'layer4': "0"}

#作用的模型：定义BackboneBase时传入的nn.Moduleclass的backbone，返回的layer：来自
        self.body = IntermediateLayerGetter(backbone, return_layers=return_
        self.num_channels = num_channels

    def forward(self, tensor_list: NestedTensor):
#BackboneBase的输入是一个NestedTensor
#xs中间层的输出，
        xs = self.body(tensor_list.tensors)
        out: Dict[str, NestedTensor] = {}
        for name, x in xs.items():
            m = tensor_list.mask
            assert m is not None
#F.interpolate上下采样，调整mask的size
#to(torch.bool)  把mask转化为Bool型变量
            mask = F.interpolate(m[None].float(), size=x.shape[-2:]).to(to
            out[name] = NestedTensor(x, mask)
        return out


class Backbone(BackboneBase):
    """ResNet backbone with frozen BatchNorm."""
    def __init__(self, name: str,
                 train_backbone: bool,
                 return_interm_layers: bool,
                 dilation: bool):
#根据name选择backbone, num_channels, return_interm_layers等，传入BackboneBas
        backbone = getattr(torchvision.models, name)(
            replace_stride_with_dilation=[False, False, dilation],
            pretrained=is_main_process(), norm_layer=FrozenBatchNorm2d)
        num_channels = 512 if name in ('resnet18', 'resnet34') else 2048
        super().__init__(backbone, train_backbone, num_channels, return_in
```

> 把Backbone和之前的PositionEmbeddingSine连在一起：
> Backbone完以后输出(b,c,h,w)，再经过PositionEmbeddingSine输出(b,H,W,256)。

```
class Joiner(nn.Sequential):
    def __init__(self, backbone, position_embedding):
        super().__init__(backbone, position_embedding)

    def forward(self, tensor_list: NestedTensor):
        xs = self[0](tensor_list)
        out: List[NestedTensor] = []
        pos = []
        for name, x in xs.items():
            out.append(x)
            # position encoding
            pos.append(self[1](x).to(x.tensors.dtype))

        return out, pos

def build_backbone(args):
#position_embedding是个nn.module
    position_embedding = build_position_encoding(args)
    train_backbone = args.lr_backbone > 0
    return_interm_layers = args.masks
#backbone是个nn.module
    backbone = Backbone(args.backbone, train_backbone, return_interm_layer
#nn.Sequential在一起
    model = Joiner(backbone, position_embedding)
    model.num_channels = backbone.num_channels
    return model
```

> Transformer的一个Encoder Layer：

```
class TransformerEncoderLayer(nn.Module):

    def __init__(self, d_model, nhead, dim_feedforward=2048, dropout=0.1,
                 activation="relu", normalize_before=False):
        super().__init__()
        self.self_attn = nn.MultiheadAttention(d_model, nhead, dropout=drop
        # Implementation of Feedforward model
        self.linear1 = nn.Linear(d_model, dim_feedforward)
        self.dropout = nn.Dropout(dropout)
        self.linear2 = nn.Linear(dim_feedforward, d_model)

        self.norm1 = nn.LayerNorm(d_model)
        self.norm2 = nn.LayerNorm(d_model)
        self.dropout1 = nn.Dropout(dropout)
        self.dropout2 = nn.Dropout(dropout)

        self.activation = _get_activation_fn(activation)
        self.normalize_before = normalize_before

    def with_pos_embed(self, tensor, pos: Optional[Tensor]):
        return tensor if pos is None else tensor + pos

    def forward_post(self,
                     src,
                     src_mask: Optional[Tensor] = None,
                     src_key_padding_mask: Optional[Tensor] = None,
                     pos: Optional[Tensor] = None):
    # 和标准做法有点不一样，src加上位置编码得到q和k，但是v依然还是src，
    # 也就是v和qk不一样
        q = k = self.with_pos_embed(src, pos)
        src2 = self.self_attn(q, k, value=src, attn_mask=src_mask,
                              key_padding_mask=src_key_padding_mask)[0]
#Add and Norm
        src = src + self.dropout1(src2)
        src = self.norm1(src)
#FFN
        src2 = self.linear2(self.dropout(self.activation(self.linear1(src)
#Add and Norm
        src = src + self.dropout2(src2)
        src = self.norm2(src)
        return src

    def forward_pre(self, src,
                    src_mask: Optional[Tensor] = None,
                    src_key_padding_mask: Optional[Tensor] = None,
                    pos: Optional[Tensor] = None):
        src2 = self.norm1(src)
        q = k = self.with_pos_embed(src2, pos)
        src2 = self.self_attn(q, k, value=src2, attn_mask=src_mask,
                              key_padding_mask=src_key_padding_mask)[0]
        src = src + self.dropout1(src2)
        src2 = self.norm2(src)
        src2 = self.linear2(self.dropout(self.activation(self.linear1(src2
        src = src + self.dropout2(src2)
        return src

    def forward(self, src,
                src_mask: Optional[Tensor] = None,
                src_key_padding_mask: Optional[Tensor] = None,
                src_key_padding_mask: Optional[Tensor] = None,
                pos: Optional[Tensor] = None):
        if self.normalize_before:
            return self.forward_pre(src, src_mask, src_key_padding_mask, po
        return self.forward_post(src, src_mask, src_key_padding_mask, pos)
```

> 有了一个Encoder Layer的定义，再看 Transformer的整个Encoder:

```
class TransformerEncoder(nn.Module):
    def __init__(self, encoder_layer, num_layers, norm=None):
        super().__init__()
        # 编码器copy6份
        self.layers = _get_clones(encoder_layer, num_layers)
        self.num_layers = num_layers
        self.norm = norm

    def forward(self, src,
                mask: Optional[Tensor] = None,
                src_key_padding_mask: Optional[Tensor] = None,
                pos: Optional[Tensor] = None):
        # 内部包括6个编码器，顺序运行
        # src是图像特征输入，shape=hxw,b,256
        output = src
        for layer in self.layers:
            # 第一个编码器输入来自图像特征，后面的编码器输入来自前一个编码器输出
            output = layer(output, src_mask=mask,
                           src_key_padding_mask=src_key_padding_mask, pos=p
        return output
```

> Object Queries：可学习的位置编码：
> 注释中已经注明了变量的shape的变化过程，最终输出的是与 Positional Encoding维度相同的位置编码，维度是(b,H,W,256)，只是现在这个位置编码是可学习的了。

```
class PositionEmbeddingLearned(nn.Module):
    """
    Absolute pos embedding, learned.
    """
    def __init__(self, num_pos_feats=256):
        super().__init__()
#这里使用了nn.Embedding，这是一个矩阵类，里面初始化了一个随机矩阵，矩阵的长是字典的大小
# 向量的维度根据你想要表示的元素的复杂度而定。类实例化之后可以根据字典中元素的下标来查找
        self.row_embed = nn.Embedding(50, num_pos_feats)
        self.col_embed = nn.Embedding(50, num_pos_feats)
        self.reset_parameters()

    def reset_parameters(self):
        nn.init.uniform_(self.row_embed.weight)
        nn.init.uniform_(self.col_embed.weight)

#输入依旧是NestedTensor
    def forward(self, tensor_list: NestedTensor):
        x = tensor_list.tensors
        h, w = x.shape[-2:]
        i = torch.arange(w, device=x.device)
        j = torch.arange(h, device=x.device)

#x_emb：(w, 128)
#y_emb：(h, 128)
        x_emb = self.col_embed(i)
        y_emb = self.row_embed(j)
        pos = torch.cat([
            x_emb.unsqueeze(0).repeat(h, 1, 1),#(1,w,128) → (h,w,128)
            y_emb.unsqueeze(1).repeat(1, w, 1),#(h,1,128) → (h,w,128)
        ], dim=-1).permute(2, 0, 1).unsqueeze(0).repeat(x.shape[0], 1, 1,
#(h,w,256) → (256,h,w) → (1,256,h,w) → (b,256,h,w)
        return pos


def build_position_encoding(args):
    N_steps = args.hidden_dim // 2
    if args.position_embedding in ('v2', 'sine'):
        # TODO find a better way of exposing other arguments
        position_embedding = PositionEmbeddingSine(N_steps, normalize=True
    elif args.position_embedding in ('v3', 'learned'):
        position_embedding = PositionEmbeddingLearned(N_steps)
    else:
        raise ValueError(f"not supported {args.position_embedding}")

    return position_embedding
```

> Transformer的一个Decoder Layer：
> 注意变量的命名：
> object queries(query_pos)
> Encoder的位置编码(pos)
> Encoder的输出(memory)

```
    def forward_post(self, tgt, memory,
                     tgt_mask: Optional[Tensor] = None,
                     memory_mask: Optional[Tensor] = None,
                     tgt_key_padding_mask: Optional[Tensor] = None,
                     memory_key_padding_mask: Optional[Tensor] = None,
                     pos: Optional[Tensor] = None,
                     query_pos: Optional[Tensor] = None):

#query,key的输入是object queries(query_pos) + Decoder的输入(tgt),shape都是(10
#value的输入是Decoder的输入(tgt),shape = (100,b,256)
        q = k = self.with_pos_embed(tgt, query_pos)

#Multi-head self-attention
        tgt2 = self.self_attn(q, k, value=tgt, attn_mask=tgt_mask,
                              key_padding_mask=tgt_key_padding_mask)[0]

#Add and Norm
        tgt = tgt + self.dropout1(tgt2)
        tgt = self.norm1(tgt)

#query的输入是上一个attention的输出(tgt) + object queries(query_pos)
#key的输入是Encoder的位置编码(pos) + Encoder的输出(memory)
#value的输入是Encoder的输出(memory)
        tgt2 = self.multihead_attn(query=self.with_pos_embed(tgt, query_po
                                   key=self.with_pos_embed(memory, pos),
                                   value=memory, attn_mask=memory_mask,
                                   key_padding_mask=memory_key_padding_mas

#Add and Norm
        tgt = tgt + self.dropout2(tgt2)
        tgt = self.norm2(tgt)

#FFN
        tgt2 = self.linear2(self.dropout(self.activation(self.linear1(tgt)
        tgt = tgt + self.dropout3(tgt2)
        tgt = self.norm3(tgt)
        return tgt

    def forward_pre(self, tgt, memory,
                    tgt_mask: Optional[Tensor] = None,
                    memory_mask: Optional[Tensor] = None,
                    tgt_key_padding_mask: Optional[Tensor] = None,
                    memory_key_padding_mask: Optional[Tensor] = None,
                    pos: Optional[Tensor] = None,
                    query_pos: Optional[Tensor] = None):
        tgt2 = self.norm1(tgt)
        q = k = self.with_pos_embed(tgt2, query_pos)
        tgt2 = self.self_attn(q, k, value=tgt2, attn_mask=tgt_mask,
                              key_padding_mask=tgt_key_padding_mask)[0]
        tgt = tgt + self.dropout1(tgt2)
        tgt2 = self.norm2(tgt)
        tgt2 = self.multihead_attn(query=self.with_pos_embed(tgt2, query_p
                                   key=self.with_pos_embed(memory, pos),
                                   value=memory, attn_mask=memory_mask,
                                   key_padding_mask=memory_key_padding_mas
        tgt = tgt + self.dropout2(tgt2)
        tgt2 = self.norm3(tgt)
        tgt2 = self.linear2(self.dropout(self.activation(self.linear1(tgt2
        tgt = tgt + self.dropout3(tgt2)
        return tgt

    def forward(self, tgt, memory,
                tgt_mask: Optional[Tensor] = None,
                memory_mask: Optional[Tensor] = None,
                tgt_key_padding_mask: Optional[Tensor] = None,
                memory_key_padding_mask: Optional[Tensor] = None,
                pos: Optional[Tensor] = None,
                query_pos: Optional[Tensor] = None):
        if self.normalize_before:
            return self.forward_pre(tgt, memory, tgt_mask, memory_mask,
                                    tgt_key_padding_mask, memory_key_paddi
        return self.forward_post(tgt, memory, tgt_mask, memory_mask,
                                 tgt_key_padding_mask, memory_key_padding_
```

> 有了一个Decoder Layer的定义，再看 Transformer的整个Decoder:

```
class TransformerDecoder(nn.Module):

#值得注意的是：在使用TransformerDecoder时需要传入的参数有：
# tgt：Decoder的输入，memory：Encoder的输出，pos：Encoder的位置编码的输出，query_
    def forward(self, tgt, memory,
                tgt_mask: Optional[Tensor] = None,
                memory_mask: Optional[Tensor] = None,
                tgt_key_padding_mask: Optional[Tensor] = None,
                memory_key_padding_mask: Optional[Tensor] = None,
                pos: Optional[Tensor] = None,
                query_pos: Optional[Tensor] = None):
        output = tgt

# Decoder输入的tgt:(100, b, 256)
        intermediate = []

        for layer in self.layers:
            output = layer(output, memory, tgt_mask=tgt_mask,
                           memory_mask=memory_mask,
                           tgt_key_padding_mask=tgt_key_padding_mask,
                           memory_key_padding_mask=memory_key_padding_mask
                           pos=pos, query_pos=query_pos)
            if self.return_intermediate:
                intermediate.append(self.norm(output))

        if self.norm is not None:
            output = self.norm(output)
            if self.return_intermediate:
                intermediate.pop()
                intermediate.append(output)

        if self.return_intermediate:
            return torch.stack(intermediate)

        return output.unsqueeze(0)
```

> 然后是把Encoder和Decoder拼在一起，即总的 Transformer结构的实现：
> 此处考虑到字数限制，省略了代码。

> 实现了Transformer，还剩后面的FFN：

```
class MLP(nn.Module):
    """ Very simple multi-layer perceptron (also called FFN)"""

    def __init__(self, input_dim, hidden_dim, output_dim, num_layers):
        super().__init__()
        self.num_layers = num_layers
        h = [hidden_dim] * (num_layers - 1)
        self.layers = nn.ModuleList(nn.Linear(n, k) for n, k in zip([input_

    def forward(self, x):
        for i, layer in enumerate(self.layers):
            x = F.relu(layer(x)) if i < self.num_layers - 1 else layer(x)
        return x
```

> 匈牙利匹配HungarianMatcher类：
> 这个类的目的是计算从targets到predictions的一种最优排列。
> predictions比targets的数量多，但我们要进行1-to-1 matching，所以多的predictions将与\varnothing 匹配。
> 这个函数整体在构建(13)式，cost_class，cost_bbox，cost_giou，对应的就是(13)式中的几个损失函数，它们的维度都是(b,100,m)。
> m包含了这个batch内部所有的 \text{GT}\,\color{purple}{\text{Bounding Box}} 。

```
# pred_logits:[b,100,92]
# pred_boxes:[b,100,4]
# targets是个长度为b的list，其中的每个元素是个字典，共包含：labels-长度为(m,)的Ten
# detr分类输出，num_queries=100，shape是(b,100,92)
        bs, num_queries = outputs["pred_logits"].shape[:2]

        # We flatten to compute the cost matrices in a batch
        out_prob = outputs["pred_logits"].flatten(0, 1).softmax(-1)  # [ba
        out_bbox = outputs["pred_boxes"].flatten(0, 1)  # [batch_size * nu

# 准备分类target shape=(m,)里面存储的是类别索引，m包括了整个batch内部的所有gt bbox
        # Also concat the target labels and boxes
        tgt_ids = torch.cat([v["labels"] for v in targets])# (m,)[3,6,7,9,
# 准备bbox target shape=(m,4)，已经归一化了
        tgt_bbox = torch.cat([v["boxes"] for v in targets])# (m,4)

#(100b,92)->(100b, m)，对于每个预测结果，把目前gt里面有的所有类别值提取出来，其余值不
#对应上述公式，类似于nll loss，但是更加简单
        # Compute the classification cost. Contrary to the loss, we don't u
        # but approximate it in 1 - proba[target class].
        # The 1 is a constant that doesn't change the matching, it can be o
#行：取每一行；列：只取tgt_ids对应的m列
        cost_class = -out_prob[:, tgt_ids]# (100b, m)

        # Compute the L1 cost between boxes, 计算out_bbox和tgt_bbox两两之间的
        cost_bbox = torch.cdist(out_bbox, tgt_bbox, p=1)# (100b, m)

        # Compute the giou cost betwen boxes, 额外多计算一个giou loss (100b,
        cost_giou = -generalized_box_iou(box_cxcywh_to_xyxy(out_bbox), box_

#得到最终的广义距离(100b, m)，距离越小越可能是最优匹配
        # Final cost matrix
        C = self.cost_bbox * cost_bbox + self.cost_class * cost_class + se
#(100b, m)--> (b, 100, m)
        C = C.view(bs, num_queries, -1).cpu()

#计算每个batch内部有多少物体，后续计算时按照单张图片进行匹配，没必要batch级别匹配，徒
        sizes = [len(v["boxes"]) for v in targets]
#匈牙利最优匹配，返回匹配索引
#enumerate(C.split(sizes, -1))]：(b,100,image1,image2,image3,...)
        indices = [linear_sum_assignment(c[i]) for i, c in enumerate(C.spl
        return [(torch.as_tensor(i, dtype=torch.int64), torch.as_tensor(j,
```

> 在得到匹配关系后算loss就水到渠成了。loss_labels计算分类损失，loss_boxes计算回归损失，包含 \text{L_1 loss, iou loss} 。

代码中的其他结构:

SmoothedValue:

一种自定义的数据结构，属于object类。它是基于deque类型的双向队列，通过update(value)进行更新。

MetricLogger:

一种自定义的数据结构，属于object类。它是字典，通过update(dict)进行更新。通过add_meter(name, meter)函数添加键值。

log_every(data_loader, print_freq, header)打印一些中间结果。

总结:

本文介绍的是Transformer的基础，包含什么是Attention，什么是Transformer，以及在检测上的应用。其实在DETR之前已经有人尝试过把self-attention机制或者 Transformer应用在视觉任务上面，但是关注不多。DETR的出现使得这个模型开始广泛应用在各种视觉任务上面，我也会在这个专栏的后续多多解读这些经典工作。

参考文献:

- code:
- video:

第1小节的部分插图和文字稿来自李宏毅老师PPT (如下链接) [侵删]。

- blog:

编辑于 2022-08-28 12:31

Transformer 计算机视觉 注意力机制

豆包AI工作任务模式–各类文件智能整理优化
从资料管理到内容生成，支持在本地电脑整理文件、处理文档，优化表格与PPT，多类型办公需求均可高效满足。 查看详情
豆包 的广告

未登录用户

168 条评论 默认 最新

评论内容由作者筛选后展示

CW不要無聊的風格
吾以為，以下三點剖析得甚是精闢：
1. pos encoding為何採用相加的形式；
2. 最後在模型使用時關於query key value之間關係的解讀；
3. 對於可視化encoder和decoder注意力結果的解讀：前者趨向於全局，而後者在前者基礎上更傾向於局部
相當精彩！受益匪淺，感恩！
2021-01-08 回复 69

科技猛兽 作者
谢谢~
2021-01-08 回复 喜欢

查看全部 6 条回复 ›

nobody
讲真，这篇讲的是最好的。赞一个
2021-07-29 回复 14

TheSource
斗宗强者!!!!!!
2021-01-29 回复 14

科技猛兽 作者
2021-01-29 回复 1

兜率工
博主您好，图二里第二层的filter (蓝色的三角形)看了5个vector 吧
2021-11-07 回复 13

林陵别
Detr中position encoding的posx和posy的取值范围应该是[1,W]和[1,H]吧，为什么统一是[1,HW]
2021-02-27 回复 9

展开其他 3 条回复 ›

方圆几里
COCO数据集的类别数+1不是等于81嘛?
2021-05-15 回复 6

是我
感谢大佬分享，看完豁然开朗！不过关于DETR有个问题，如果他的N个object query在训练完之后，每个都有了自己对应的目标，比如car\sky\horse等，但是如果测试图中，有好多同一目标该怎么办？这时候的输出(N，class+1)与(N,4)该怎么输出多个同一目标?
2021-03-10 回复 4

科技猛兽 作者
"N个object query在训练完之后，每个都有了自己对应的目标"只是一种便于理解的方式，实际上也可能是多个query都能找到同样类型的object。比如第49,65个query都可以对应Car。

但anyway，还是query个数多一点比较好，像Deformable DETR就用了N=300。
2021-03-10 回复 1

查看全部 6 条回复 ›

光之喵
佬，图14multi-head self-attention，我看代码里都是在特征维度进行的拼接，而图里是在patch维度进行的拼接，是由什么不一样吗
2022-06-04 回复 3

爱学术的大猴哥
作者，你好，你写的这个解释是我见过写过的最好的博客。但是关于DETR文章的解读，也就是DERT是怎么训练的这里我想请教一个地方，文章里说到“模型训练完之后，知道每个预测框应该预测什么样的目标”，如果这么说是不是不太恰当，如果说第一个框是用来预测car的，此时输入图像上存在多辆car的话也只能测出一辆了。但是实际情况并不是这样，因此我认为在Ouery Object中，每一个格子都蕴含了所有的目标信息和类别信息。
2021-07-14 回复 3

展开其他 3 条回复 ›

Sophia W
牛哇，请问大佬用啥画图呀？图画的也太清楚和好看了吧
2021-11-13 回复 2

科技猛兽 作者
PPT~
2021-11-13 回复 2

查看被折叠评论

点击查看全部评论 ›

未登录用户

推荐阅读

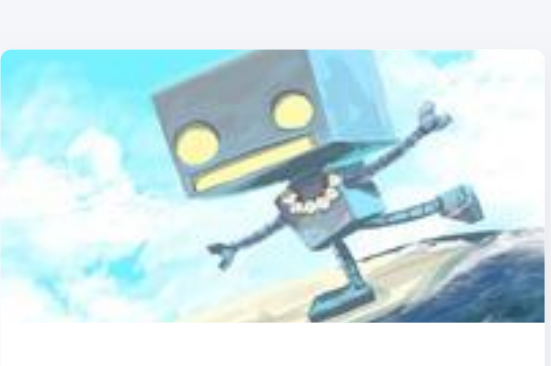
Vision Transformer 超详细解读 (原理分析+代码解读) (八)
科技猛兽 发表于 Trans...

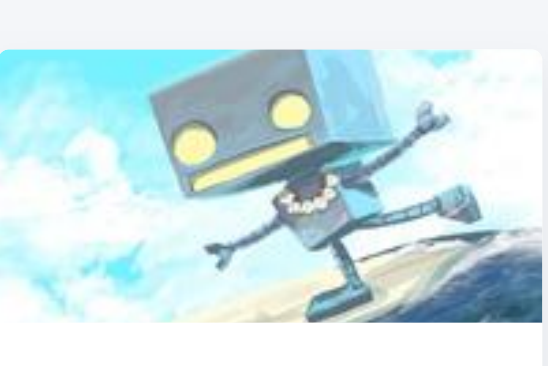
Vision Transformer 超详细解读 (原理分析+代码解读) (十四)
科技猛兽 发表于 Trans...

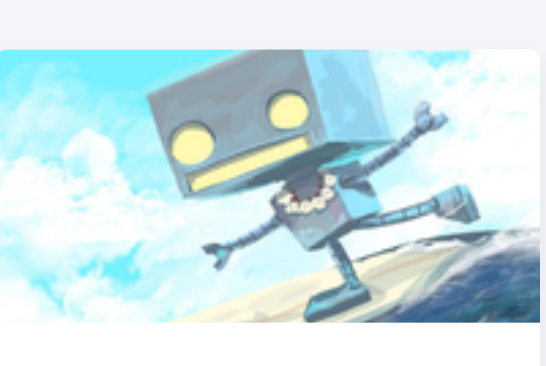
Vision Transformer 超详细解读 (原理分析+代码解读) (二十五)
科技猛兽 发表于 Trans...

登录即可查看 超5亿 专业优质内容
超 5 千万创作者的优质提问、专业回答、深度文章和精彩视频尽在知乎。
立即登录/注册